

Skriptum zur Vorlesung

Optimierung

Christian Bargetz

Sommersemester 2025

Letzte Änderung: 30. Januar 2026

Institut für Mathematik der Universität Innsbruck

Inhaltsverzeichnis

1	Geometrie linearer Ungleichungen	1
1.1	Polyeder und Polytope	1
1.2	Ecken, Kanten und Seitenflächen	7
1.3	Lösbarkeit von linearen Ungleichungssystemen	10
1.4	Extrema linearer Abbildungen auf Polyedern	15
1.5	Literatur und Ausblick	16
1.6	Aufgaben	17
2	Der Simplexalgorithmus	25
2.1	Basislösungen	25
2.2	Der Simplexschritt	26
2.2.1	Fall 1: $c_K^T - c_B^T A_B^{-1} A_K \geq 0$	28
2.2.2	Fall 2: $c_K^T - c_B^T A_B^{-1} A_K$ hat eine negative Komponente	29
2.3	Zusammenfassung und Erfolgsgarantie	33
2.4	Bestimmung einer zulässigen Basislösung	39
2.5	Literatur und Ausblick	41
2.6	Aufgaben	41
3	Konvexe Funktionen und deren Minima	45
3.1	Konvexe Funktionen	45
3.2	Optimalitätsbedingungen	49
3.3	Literatur und Ausblick	53
3.4	Aufgaben	53
4	Nichtlineare Optimierung ohne Nebenbedingungen	59
4.1	Abstiegsverfahren	60
4.1.1	Gradientenverfahren mit Liniensuche	60
4.1.2	Subgradientenverfahren	62
4.2	Newton-Verfahren	66
4.3	Literatur und Ausblick	69
4.4	Aufgaben	69
5	Verfahren zur konvexen Optimierung mit Nebenbedingungen	73
5.1	Projektionsverfahren	73
5.2	Straffunktionen und Penalty-Verfahren	83
5.3	Literatur und Ausblick	87
5.4	Aufgaben	87

6	Dualität	93
6.1	Dualität in linearen Programmen	93
6.2	Lagrange-Dualität	97
6.3	Literatur und Ausblick	99
6.4	Aufgaben	100
7	Kombinatorische Optimierung	101
7.1	Lösbarkeit ganzzahliger linearer Ungleichungssysteme	101
7.2	Branch and Bound	104
7.3	Literatur und Ausblick	107
8	Innere Punkte Verfahren: ein Ausblick	109
8.1	Ausblick und Literatur	115

1 Geometrie linearer Ungleichungen

In diesem Kapitel betrachten wir Lösungsmengen von Ungleichungen in $\mathbb{R}^n$ und bezeichnen mit $\langle \cdot, \cdot \rangle$ das Standardskalarprodukt auf $\mathbb{R}^n$ und mit $\| \cdot \|$, sofern nicht explizit anders erwähnt, die euklidische Norm.

1.1 Polyeder und Polytope

Wir starten mit den grundlegenden Begriffen, die sofort eine geometrische Interpretation der Lösungsmenge von linearen Ungleichungssystemen ermöglichen.

Definition 1.1.1. Für $v \in \mathbb{R}^n$ und $a \in \mathbb{R}$ nennt man die Menge

$$H_{v,a} := \{x \in \mathbb{R}^n : \langle x, v \rangle \leq a\}$$

den durch v und a definierten *Halbraum*. Ein *Polyeder* ist eine Menge, die sich als endlicher Durchschnitt von Halbräumen darstellen lässt. Ein *Polytop* ist ein beschränktes Polyeder.

Bemerkung 1.1.2. 1. Zu gegebenem $v \in \mathbb{R}^n$ und $a \in \mathbb{R}$ kann man die beiden Halbräume

$$H_{v,a} = \{x \in \mathbb{R}^n : \langle x, v \rangle \leq a\} \quad \text{und} \quad H_{-v,-a} = \{x \in \mathbb{R}^n : \langle x, v \rangle \geq a\}$$

betrachten. Ersteren nennt man manchmal, insbesondere im Fall $a = 0$, den negativen Halbraum und zweiten den positiven Halbraum zu v und a .

2. Da Halbräume offensichtlich konvex sind und Durchschnitte konvexer Mengen wieder konvex sind, ist jedes Polyeder eine konvexe Menge. In der Geometrie wird manchmal eine andere Definition von Polyeder verwendet, die auch nicht-konvexe Polyeder erlaubt.
3. Wir betrachten das System

$$\begin{array}{ccccccccc} a_{11}x_1 & + & a_{12}x_2 & + & \dots & + & a_{1n}x_n & \leq & b_1 \\ a_{21}x_1 & + & a_{22}x_2 & + & \dots & + & a_{2n}x_n & \leq & b_2 \\ \vdots & & \vdots & & \ddots & & \vdots & & \vdots \\ a_{n1}x_1 & + & a_{n2}x_2 & + & \dots & + & a_{nn}x_n & \leq & b_n, \end{array}$$

das wir im Folgenden meist in Matrixschreibweise als $Ax \leq b$ schreiben. Jede der obigen Ungleichungen definiert einen Halbraum und damit ist die Lösungsmenge des Systems ein Durchschnitt von Halbräumen und folglich ein Polyeder.

1 Geometrie linearer Ungleichungen


Beispiel 1.1.3. Die Menge

$$\Delta_n = \left\{ x \in \mathbb{R}^{n+1} : \sum_{i=1}^{n+1} x_i = 1, x_i \geq 0 \right\}$$

nennt man *n-dimensionalen Standardsimplex*. Wir prüfen nach, dass es sich dabei um ein Polytop handelt. Es gilt offensichtlich

$$\Delta_n = \left\{ x \in \mathbb{R}^{n+1} : \mathbf{1}^\top x \leq 1 \right\} \cap \left\{ x \in \mathbb{R}^{n+1} : -\mathbf{1}^\top x \leq -1 \right\} \cap \bigcap_{i=1}^{n+1} \{ x \in \mathbb{R}^{n+1} : x_i \geq 0 \}$$

und damit ist Δ_n der Durchschnitt von endlich vielen Halbräumen.



Wie wiederholen nun eine Reihe von Begriffen aus der konvexen Geometrie, die bereits aus früheren Lehrveranstaltungen bekannt sind.

Definition 1.1.4. Es sei $A \in \text{Mat}_{m,n}(\mathbb{R})$ und $b \in \mathbb{R}^m$. Wir bezeichnen mit

$$P(A, b) := \{ x \in \mathbb{R}^n : Ax \leq b \}$$

das durch A und b definierte Polyeder.

Definition 1.1.5. Eine Menge $C \subset \mathbb{R}^n$ ist *konvex*, falls für $x, y \in C$ und $\lambda \in [0, 1]$ stets $\lambda x + (1 - \lambda)y \in C$ gilt. Für $x_1, \dots, x_m \in \mathbb{R}^n$ und $\lambda_1, \dots, \lambda_m \in [0, 1]$ nennt man die Linearkombination $\sum_{i=1}^m \lambda_i x_i$ eine *Konvexkombination* falls $\sum_{i=1}^m \lambda_i = 1$. Für eine Menge $A \subset \mathbb{R}^n$ bezeichnen wir die kleinste konvexe Menge, die A enthält als die *konvexe Hülle von A*. Genauer,

$$\text{Konv}(A) = \bigcap \{ C : A \subset C, C \text{ konvex} \},$$

d.h. die konvexe Hülle von A ist der Durchschnitt aller konvexer Mengen, die A enthalten.

Satz 1.1.6. Für eine Menge $A \subset \mathbb{R}^n$ ist

$$\text{Konv}(A) = \left\{ \sum_{i=1}^k \lambda_i x_i : x_i \in A, k \in \mathbb{N}, \lambda_i \in [0, 1], \sum_{i=1}^k \lambda_i = 1 \right\},$$

d.h. die konvexe Hülle einer Menge ist die Menge aller Konvexkombinationen von Elementen von A .

Beweis. Übung (Aufgabe (1.3)). □

Beispiel 1.1.7. Wir können das n -dimensionale Standardsimplex Δ_n auch als die konvexe Hülle einer endlichen Menge darstellen. Es gilt

$$\Delta_n = \text{Konv}\{e_1, \dots, e_{n+1}\},$$

wobei e_i den i -ten Standardbasisvektor bezeichnet. Wir betrachten eine Konvexkombination

$$\sum_{i=1}^{n+1} \lambda_i e_i = (\lambda_1, \dots, \lambda_{n+1}), \quad \sum_{i=1}^{n+1} \lambda_i = 1, \quad \lambda_i \in [0, 1]$$

und bemerken, dass die Menge dieser Konvexkombinationen gerade Δ_n entspricht.

Satz 1.1.8. *Eine Menge P ist genau dann ein Polytop wenn es die konvexe Hülle von endlich vielen Punkten ist, d.h. falls es $x_1, \dots, x_k \in \mathbb{R}^n$ mit*

$$P = \text{Konv}(\{x_1, \dots, x_k\})$$

gibt.

Wir bekommen diesen Satz als Spezialfall eines entsprechenden Satzes für Polyeder. Für diesen allgemeineren Satz brauchen wir aber noch eine zusätzliche geometrische Vorbereitung.

Definition 1.1.9. Eine Menge $C \subset \mathbb{R}^n$ nennt man *Kegel*, falls $tx \in C$ für alle $x \in C$ und alle $t \in [0, \infty)$. Ein Kegel, der als Durchschnitt endlich vieler Halbräume, deren begrenzende Hyperebenen den Nullpunkt enthalten, dargestellt werden kann heißt *polyedrischer Kegel*. Mit

$$\text{KK}(A) = \bigcap \{C : A \subset C, C \text{ konvexer Kegel}\}$$

bezeichnen wir den kleinsten konvexen Kegel, der A enthält.

Bemerkung 1.1.10. Analog zur Darstellung

$$\text{Konv}(A) = \left\{ \sum_{i=1}^m \lambda_i x_i : m \in \mathbb{N}, x_i \in A, \lambda_i \geq 0, \sum_{i=1}^m \lambda_i = 1 \right\}$$

kann man zeigen dass

$$\text{KK}(A) = \left\{ \sum_{i=1}^m \lambda_i x_i : m \in \mathbb{N}, x_i \in A, \lambda_i \geq 0 \right\}$$

gilt. Der Beweis verbleibt als Übung.

Beispiel 1.1.11. Wir betrachten ein paar einfache Beispiele für Kegel.

1 Geometrie linearer Ungleichungen

1. Die Menge

$$\{(x, y, z) \in \mathbb{R}^3 : x^2 + y^2 \leq z^2, z \geq 0\}$$

ist ein Kegel, aber kein polyedrischer Kegel.

2. Für eine konvexe Menge $P \subset \mathbb{R}^n$ betrachten wir den Kegel

$$C_P := \overline{\text{KK}(P \times \{1\})} = \overline{\{(tx, t) \in \mathbb{R}^{n+1} : x \in P, t \geq 0\}}.$$

Wir überprüfen, dass die Menge C_P genau dann ein polyedrischer Kegel ist, wenn P ein Polyeder ist. Angenommen wir haben $P = P(A, b)$. Wir definieren

$$\tilde{A} = \begin{pmatrix} A & -b \\ 0 & -1 \end{pmatrix}$$

und stellen fest, dass

$$\tilde{A} \begin{pmatrix} x \\ \xi \end{pmatrix} \leq 0 \Leftrightarrow Ax \leq b\xi, \xi \geq 0 \Leftrightarrow A(x/t) \leq b, t \geq 0,$$

d.h. $C_P = P(\tilde{A}, 0)$. Ist umgekehrt C_P ein polyedrischer Kegel, d.h. insbesondere ein Polyeder, so bilden wir den Durchschnitt mit den Halbräumen $\{x_{n+1} \leq 1\}$ und $\{x_{n+1} \geq 1\}$ und erhalten somit P als Durchschnitt von Halbräumen, d.h. P ist ein Polyeder.

Satz 1.1.12. Eine Menge $P \subset \mathbb{R}^n$ ist genau dann ein Polyeder, falls es endlich viele Punkte $x_1, \dots, x_k \in \mathbb{R}^n$ und $y_1, \dots, y_m \in \mathbb{R}^n$ mit

$$P = \text{Konv}\{x_1, \dots, x_k\} + \text{KK}\{y_1, \dots, y_m\} \quad (1.1)$$

gibt.

Um diesen Satz zu beweisen brauchen wir einen entsprechenden Darstellungssatz für polyedrische Kegel.

Satz 1.1.13. Es sei $C \subset \mathbb{R}^n$ ein polyedrischer Kegel. Dann gibt es eine endliche Menge $\{x_1, \dots, x_m\} \subset \mathbb{R}^n$ mit $C = \text{KK}(\{x_1, \dots, x_m\})$.

Beweis. Angenommen C ist ein polyedrischer Kegel. Dann gibt es $A \in \text{Mat}_{m,n}(\mathbb{R})$ mit $C = P(A, 0)$. Wir zeigen nun, dass die Lösungen $x_1, \dots, x_k \in C$ der linearen Gleichungssysteme $Bx = \pm e_j$, B eine Untermatrix von

$$\begin{pmatrix} A \\ I \end{pmatrix},$$

die aus n linear unabhängigen Zeilen besteht, eine endliche Erzeugendenmenge des Kegels bilden, d.h. $C = \text{KK}\{x_1, \dots, x_k\}$.

Wir starten mit dem einfachen Fall $C = \{x \in \mathbb{R}^n : Ax = 0\}$. In diesem Fall können wir aus A und I durch Auswahl geeigneter Zeilen Untermatrizen A' und I' so auswählen, dass $C = \{x \in \mathbb{R}^n : A'x = 0\}$ und die Matrix

$$\begin{pmatrix} A' \\ I' \end{pmatrix}$$

invertierbar ist. Damit bilden die (eindeutigen) Lösungen der linearen Gleichungssysteme

$$\begin{pmatrix} A' \\ I' \end{pmatrix} x = \begin{pmatrix} 0 \\ \pm e_i \end{pmatrix}$$

für $i = 1, \dots, n - \text{Rang } A$ ein endliches Erzeugendensystem von C . Wir bemerken, dass die Beziehung $n - \text{Rang } A = \dim C = \dim \text{Span}_{\mathbb{R}}(C)$ gilt.

Die Aussage für den Fall, dass C kein Untervektorraum ist, zeigen wir mittels Induktion über die Dimension $\dim \text{Span}_{\mathbb{R}}(C)$ des Spans von C . Da C kein Untervektorraum ist, können wir Zeilen von A so auswählen, dass diese eine Matrix

$$\begin{pmatrix} A' \\ a \end{pmatrix}$$

aus linear unabhängigen Zeilen bilden und

$$\{x \in \mathbb{R}^n : A'x = 0, ax \leq 0\} \subset C$$

gilt. Nach Konstruktion gibt es also ein x_j mit $A'x_j = 0$ und $ax_j = -1$. Wir fixieren $z \in C$ und setzen

$$\mu := \min \left\{ \frac{A_i z}{A_i x_j} : i = 1, \dots, m, A_i x_j < 0 \right\}.$$

Da $z \in C$ gilt $A_i z \leq 0$ und folglich ist $\mu \geq 0$. Wir wählen nun ein l in dem das Minimum angenommen wird, d.h. $\mu = \frac{A_l z}{A_l x_1}$ und setzen $z' := z - \mu x_j$. Wegen

$$A_l z' = A_l z - \frac{A_l z}{A_l x_j} A_l x_j = 0 \quad \text{und} \quad A_l x_j \neq 0$$

ist $C' = C \cap \{x \in \mathbb{R}^n : A_l x = 0\}$ ein Kegel mit $\dim_{\mathbb{R}} \langle C' \rangle \leq \dim_{\mathbb{R}} \langle C \rangle - 1$. Nach Induktionsannahme gibt es also ein endliches Erzeugendensystem das aus manchen der $x_1, \dots, x_k$ besteht. Also gibt es $\lambda_1, \dots, \lambda_k \geq 0$ mit

$$z' = \sum_{i=1}^k \lambda_i x_i \quad \text{und daher} \quad z = \sum_{i=1}^k \lambda_i x_i + \mu x_k,$$

d.h. $C \subset \text{KK}\{x_1, \dots, x_k\}$. Da alle $x_i \in C$, gilt auch die umgekehrte Inklusion und damit $C = \text{KK}\{x_1, \dots, x_k\}$ □

1 Geometrie linearer Ungleichungen

Beweis von Satz 1.1.12. Wir zeigen nur, dass jedes Polyeder $P \subset \mathbb{R}^n$ eine Darstellung der Form (1.1) hat, die andere Implikation verbleibt als Übung (siehe Aufgabe (1.8)). Wir haben also ein Polyeder $P \subset \mathbb{R}^n$ gegeben und betrachten den abgeschlossenen Kegel

$$C_P := \overline{\text{KK}(P \times \{1\})} \subset \mathbb{R}^{n+1}$$

von dem wir in Beispiel 1.1.11 gesehen haben, dass es sich um einen polyedrischen Kegel handelt. Nach Satz 1.1.13 erhalten wir $z_1, \dots, z_p \in \mathbb{R}^{n+1}$ die diesen Kegel erzeugen. Wir wählen aus diesen Punkten jene $x'_1, \dots, x'_k$ aus deren letzte Koordinate nicht Null ist – nach Konstruktion muss es mindestens einen solchen Erzeuger geben und durch Skalierung, falls notwendig, können wir ohne Einschränkung der Allgemeinheit annehmen, dass die letzte Koordinate all dieser Vektoren 1 ist. Die verbleibenden Elemente bezeichnen wir als $y'_1, \dots, y'_m$. Wir bezeichnen mit $x_1, \dots, x_k \in \mathbb{R}^n$ und $y_1, \dots, y_m \in \mathbb{R}^n$ jene Elemente, die wir durch Weglassen der letzten Komponente aus $x'_1, \dots, x'_k$ bzw. $y'_1, \dots, y'_m$ erhalten. Sei nun $z \in P$ und damit $z' = (z, 1) \in C_P$. Wir erhalten also $\rho_1, \dots, \rho_p \geq 0$ mit

$$z' = \sum_{i=1}^p \rho_i z_i = \sum_{i=1}^k x'_i \lambda_i + \sum_{i=1}^m \mu_i y'_i,$$

wobei in der zweiten Summe nur z_i auftreten, deren letzte Koordinate verschwindet. Da die letzte Koordinate aller x'_i und die von z' 1 ist, gilt

$$z = \sum_{i=1}^k \lambda_i x_i + \sum_{i=1}^m \mu_i y_i \quad \text{und} \quad \lambda_1, \dots, \lambda_k, \mu_1, \dots, \mu_m \geq 0, \quad \sum_{i=1}^k \lambda_i = 1,$$

d.h. $P = \text{Konv}(\{x_1, \dots, x_k\}) + \text{KK}(\{y_1, \dots, y_m\})$. □

Beispiel 1.1.14. Wir starten mit dem linearen Ungleichungssystem

$$\begin{aligned} x + y &\leq 1 \\ x &\geq 0 \\ y &\geq 0, \end{aligned}$$

das wir in

$$\begin{pmatrix} 1 & 1 \\ -1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} \leq \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

umschreiben. Wir verwenden, die in Beispiel 1.1.11 gesehene Konstruktion, um einen Kegel zu bekommen, dessen Schnitt mit der Ebene $z = 1$ gerade der Lösungsmenge des obigen Systems entspricht. Dieser Kegel wird durch das Ungleichungssystem

$$\begin{pmatrix} 1 & 1 & -1 \\ -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} \leq \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

beschrieben. Durch Lösen der linearen Gleichungssysteme, die wir erhalten, indem wir auf der linken Seite eine Matrix setzen, die aus 3 linear unabhängigen Zeilen der Matrix

$$\begin{pmatrix} 1 & 1 & -1 \\ -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

besteht und auf der rechten Seite jeweils einen der Vektoren $\pm e_i$ setzen, erhalten wir als im Kegel liegende Lösungen

$$\begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \quad \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} \quad \text{und} \quad \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}.$$

Dies entspricht gerade den Punkten $(0, 0)$, $(1, 0)$, $(0, 1)$ in der Ebene. Deren konvexe Hülle bildet gerade die Lösungsmenge des ursprünglichen Ungleichungssystems.

Aus Satz 1.1.12 erhalten wir unmittelbar die folgende Charakterisierung von unbeschränkten Polyedern.

Korollar 1.1.15. *Ein Polyeder P ist genau dann unbeschränkt, wenn es einen Halbstrahl $v + \mathbb{R}_+ u$ enthält.*

1.2 Ecken, Kanten und Seitenflächen

Analog zur konvexen Hülle betrachten wir auch die affine Hülle einer Teilmenge des euklidischen Raums. In der linearen Algebra wurde die Dimension eines affinen Unterraums als die Dimension des dazu parallelen Untervektorraums definiert. Wir verwenden und diese beiden Konzepte, um von der Dimension von konvexen Mengen sprechen zu können.

Definition 1.2.1. Es sei $A \subset \mathbb{R}^n$ eine beliebige Teilmenge. Die *affine Hülle* von A ist der kleinste affine Unterraum, der A enthält, d.h.

$$\text{Aff}(A) = \bigcap \{M \subset \mathbb{R}^n : A \subset M, M \text{ affiner Unterraum}\}.$$

Für eine konvexe Menge $C \subset \mathbb{R}^n$ definieren wir die *Dimension* von C als

$$\dim C = \dim(\text{Aff}(C)),$$

d.h. als die Dimension der affinen Hülle.

1 Geometrie linearer Ungleichungen

Definition 1.2.2. Es sei $P \subset \mathbb{R}^n$ ein Polyeder. Eine lineare Ungleichung $a^\top x \leq b$ mit $a \in \mathbb{R}^n$ und $b \in \mathbb{R}$ heißt *gültig (für P)*, falls sie von allen Elementen von P erfüllt wird, d.h. falls $a^\top x \leq b$ für alle $x \in P$ gilt. Für eine gültige lineare Ungleichung $a^\top x \leq b$ nennt man die Menge $\{x \in P: a^\top x = b\}$ eine *Seitenfläche von P* . Eine Seitenfläche der Dimension Null nennt man *Ecke von P* und eine Seitenfläche der Dimension Eins *Kante von P* . Eine Seitenfläche der Dimension $\dim(P) - 1$ nennt man *Facette*.


Bemerkung 1.2.3. Da jedes $x \in P$ immer die Ungleichung $0^\top x \leq 0$ erfüllt, ist

$$P = \{x \in P: 0^\top x = 0\}$$

immer eine Seitenfläche von sich selber. Andererseits erfüllen auch alle $x \in P$ die Ungleichung $0^\top x \leq 1$ und folglich ist auch die leere Menge

$$\emptyset = \{x \in P: 0^\top x = 1\}$$

immer eine Seitenfläche von P .



Definition 1.2.4. Es sei $C \subset \mathbb{R}^n$ eine konvexe Menge. Ein Punkt $z \in C$ heißt *Extremalpunkt von C* , falls für alle $x, y \in C$ und $t \in [0, 1]$ mit $z = tx + (1 - t)y$ stets $z = x$ oder $z = y$ gilt. Wir bezeichnen mit $\text{Ext}(C)$ die Menge der Extremalpunkte von C .

Satz 1.2.5. Es sei $P \subset \mathbb{R}^n$ ein Polyeder. Ein Punkt $z \in P$ ist genau dann ein Extremalpunkt von P wenn er eine Ecke von P ist.

Beweis. Angenommen $z \in P$ ist eine Ecke. Dann gibt es $a \in \mathbb{R}^n \setminus \{0\}$ und ein $b \in \mathbb{R}$ mit $a^\top x \leq b$ für alle $x \in P$ und $\{z\} = \{x \in P: a^\top x = b\}$. Es seien nun $x, y \in P$ und $t \in [0, 1]$ mit $z = tx + (1 - t)y$. Nach Voraussetzung ist $a^\top x \leq b$ und $a^\top y \leq b$ sowie

$$b = a^\top z = ta^\top x + (1 - t)a^\top y \leq b.$$

Folglich muss $a^\top x = b$ oder $a^\top y = b$ gelten, d.h. $x = z$ oder $y = z$.

Für die andere Implikation sei z ein Extremalpunkt von P und wir betrachten eine Matrix $A \in \text{Mat}_{m,n}(\mathbb{R})$ und $b \in \mathbb{R}^m$ mit

$$P = \{x \in \mathbb{R}^n: Ax \leq b\}.$$

Wir setzen $I := \{i: A_{i-}z = b_i\}$ und $J := \{i: A_{i-}z < b_i\}$. Wir bezeichnen mit A_I die Matrix, die aus den Zeilen A_{i-} mit $i \in I$ besteht. Wir zeigen, dass $\text{Rang } A_I = n$ gilt. Ist $\text{Rang } A_I < n$, so können wir ein $0 \neq y \in \mathbb{R}^n$ mit $A_I y = 0$ finden. Wir wählen ein

$$\varepsilon \leq \min \left\{ \frac{b_j - A_{j-}z}{|A_{j-}y|} : j \in J \right\}, \quad \text{setzen} \quad z_{1,2} = z \pm \varepsilon y$$

und stellen fest, dass damit $Az_1 \leq b$ und $Az_2 \leq b$ gilt, d.h. $z_1, z_2 \in P$. Da aber darüber hinaus $z = \frac{1}{2}(z_1 + z_2)$ gilt, kann z kein Extrempunkt sein. Also muss $\text{Rang } A_I = n$ gelten. Wir setzen nun $a^T = \sum_{i \in I} A_{i-}$ und $c := \sum_{i \in I} b_i$. Damit gilt

$$a^T x = \sum_{i \in I} A_{i-}x \leq \sum_{i \in I} b_i = c,$$

für alle $x \in P$, d.h. die Ungleichung $a^T x \leq c$ ist gültig für P . Da die Matrix A_I vollen Rang hat gibt es genau ein $y \in \mathbb{R}^n$ mit $A_I y = b_I$, wobei b_I aus den b_i mit $i \in I$ besteht. Damit ist aber z das eindeutig bestimmte Element von P mit $a^T v = c$. $\square$

Der obige Beweis zeigt, dass $z \in P(A, b) \subset \mathbb{R}^n$ genau dann eine Ecke ist, wenn die Matrix A_I , die aus den Zeilen A_{i-} mit $A_{i-}z = b_i$ besteht, vollen Spaltenrang hat, d.h. wir haben folgendes Korollar.

Korollar 1.2.6. *Sei $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $P = P(A, b)$ das dadurch definierte Polyeder. Ein Punkt $z \in \mathbb{R}^n$ ist genau dann eine Ecke von P , wenn $Az \leq b$ gilt und es n linear unabhängige Zeilen $A_{i_1-}, \dots, A_{i_n-}$ mit $A_{i_k}x = b_{i_k}$ gibt.*

Damit ist für die Existenz einer Ecke die Bedingung $\text{Rang } A = n$ notwendig. Wir zeigen nun, dass diese Bedingung auch hinreichend ist.

Satz 1.2.7. *Ein nichtleeres Polyeder $P = P(A, b) \subset \mathbb{R}^n$ mit $A \in \text{Mat}_{m,n}(\mathbb{R})$ und $b \in \mathbb{R}^m$ besitzt genau dann eine Ecke wenn es keine Geraden enthält. Dies ist genau dann der Fall, wenn $\text{Rang } A = n$ ist.*

Beweis. Angenommen P enthält eine Gerade $z + \mathbb{R}w$ mit $w \neq 0$, d.h.

$$b \geq A(z + \lambda w) = Az + \lambda Aw$$

für alle $\lambda \in \mathbb{R}$. Gäbe es nun ein $(Aw)_i \neq 0$ so können wir durch Wahl von λ mit dem gleichen Vorzeichen wie $(Aw)_i$ den Ausdruck $(Az)_i + \lambda(Aw)_i$ beliebig groß machen, also muss $Aw = 0$ sein. Damit ist aber mit jedem $v \in P$ auch $v + w \in P$ und $v - w \in P$. Wegen $v = \frac{1}{2}(v + w) + \frac{1}{2}(v - w)$ kann es sich bei v nach Satz 1.2.5 um keine Ecke handeln. Die obige Rechnung zeigt auch, dass P genau dann eine Gerade enthält wenn $Ax = 0$ eine nicht-triviale Lösung hat, d.h. genau dann wenn $\text{Rang } A < n$ ist.

Wir nehmen nun also an, dass P keine Geraden enthält und wählen einen Punkt $z \in P$. Ist z eine Ecke, so sind wir fertig. Ansonsten wählen wir ein $w \in \mathbb{R}^n \setminus \{0\}$ mit $z \pm w \in P$. Da P keine Geraden enthält, gibt es ein $\lambda \in \mathbb{R}$ sowie A_{i_1-} und b_{i_1}

1 Geometrie linearer Ungleichungen

mit $A_{i_1-}(z + \lambda w) = b_{i_1}$. Wir setzen $z_1 := z + \lambda w$ und falls es sich dabei nicht um eine Ecke handelt, wählen wir ein $w_1 \in \mathbb{R}^n \setminus \{0\}$ mit $z_1 \pm w_1 \in P$. Analog zu vorher finden wir wieder $\lambda_1 \in \mathbb{R}$ sowie A_{i_2-} und b_{i_2} mit $A_{i_2-}(z_1 + \lambda_1 w_1) = b_{i_2}$ und setzen $z_2 = z_1 + \lambda_1 w_1$. Nach Konstruktion gilt auch $A_{i_1-}z_2 = b_{i_1}$. Induktiv erhalten wir z_k mit $A_{i_1-}z_k = b_{i_1}, \dots, A_{i_k-}z_k = b_{i_k}$ so, dass es kein w_k mit

$$A_{i_1-}w_k = \dots = A_{i_k-}w_k = 0$$

und $z_k \pm w_k \in P$ gibt. Nach Konstruktion gibt es also kein $w' \in \mathbb{R}^n$ mit $z_k \pm w' \in P$, d.h. nach Satz 1.2.5 ist z_k eine Ecke von P . $\square$

1.3 Lösbarkeit von linearen Ungleichungssystemen

Wir betrachten das lineare Ungleichungssystem

$$Ax \leq b \tag{1.2}$$

für eine Matrix $A \in \text{Mat}_{m,n}(\mathbb{R})$ und eine Spalte $b \in \mathbb{R}^m$. Unser Ziel ist es, eine äquivalente aber einfachere Darstellungsform dieses Problems zu finden. Wir erinnern uns an das Standardsimplex

$$\begin{aligned} \Delta_n &= \{(x_1, \dots, x_{n+1}) \in \mathbb{R}^{n+1} : x_1 + \dots + x_{n+1} = 1, x_i \geq 0 \text{ für } 1 \leq i \leq n+1\} \\ &= \{x \in \mathbb{R}^{n+1} : \mathbf{1}^\top x = 1, x \geq 0\} \end{aligned}$$

und suchen nun für die Lösungsmenge von (1.2) eine äquivalente Darstellung, die analog zum Standardsimplex durch ein lineares Gleichungssystem und Positivitätsbedingungen für die Variablen gegeben ist.

In einem ersten Schritt bringen wir (1.2) auf ein System mit Positivitätsbedingungen. Dazu setzen wir

$$x^+ := \max\{x, 0\} \quad \text{und} \quad x^- := \max\{-x, 0\},$$

wobei wir das Maximum komponentenweise betrachten. Damit transformiert sich das obige Ungleichungssystem auf

$$Ax \leq b \quad \Leftrightarrow \quad A(x^+ - x^-) \leq b \quad \Leftrightarrow \quad (A \quad -A) \begin{pmatrix} x^+ \\ x^- \end{pmatrix} \leq b.$$

Also ist (1.2) äquivalent zu

$$\tilde{A}y \leq b, \quad y \geq 0 \quad \text{mit} \quad \tilde{A} = (A \quad -A), \tag{1.3}$$

wobei die Äquivalenz durch

$$y = \begin{pmatrix} x^+ \\ x^- \end{pmatrix} \quad \text{und} \quad x = \begin{pmatrix} y_1 - y_{n+1} \\ \vdots \\ y_n - y_{2n} \end{pmatrix}$$

1.3 Lösbarkeit von linearen Ungleichungssystemen

gegeben ist.

In einem nächsten Schritt wollen wir nun die Ungleichungen, bis auf die Positivitätsbedingungen, durch Gleichungen ersetzen. Dazu bemerken wir, dass aus der Ungleichung $(Ay)_i \leq b_i$ folgt, dass $s_i := b_i - (Ay)_i \geq 0$ und $(Ay)_i + s_i = b_i$ ist. Also ist 1.3 äquivalent zu

$$\bar{A}z = b, \quad z \geq 0 \quad \text{mit} \quad \bar{A} := (A \quad -A \quad I_m) \quad (1.4)$$

wobei die Äquivalenz durch

$$z = \begin{pmatrix} y \\ b - \tilde{A}y \end{pmatrix} \quad \text{und} \quad y = \begin{pmatrix} z_1 \\ \vdots \\ z_{2n} \end{pmatrix}$$

gegeben ist.

Definition 1.3.1. Ein lineares Programm der Form

$$\min \left\{ c^T x : Ax = b, x \geq 0 \right\}$$

mit $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$ nennt man lineares Programm in *Standardform*.

Wir führen diese Operationen nun in einem Beispiel durch.


Beispiel 1.3.2. Wir betrachten das Polyeder P in $\mathbb{R}^2$, das durch das System

$$\begin{aligned} x + y &\leq 1 \\ x - y &\leq 1 \\ -x + y &\leq 1 \\ -x - y &\leq 1 \end{aligned}$$

definiert ist. Wir haben also

$$A = \begin{pmatrix} 1 & 1 \\ 1 & -1 \\ -1 & 1 \\ -1 & -1 \end{pmatrix} \quad \text{und} \quad b = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}.$$

Wir skizzieren das Polyeder und erhalten das folgende Bild.



1 Geometrie linearer Ungleichungen

Um alle Variablen positiv zu erhalten, betrachten wir also die Matrix

$$\tilde{A} = \begin{pmatrix} 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \\ -1 & 1 & 1 & -1 \\ -1 & -1 & 1 & 1 \end{pmatrix}$$

und die äquivalente Lösungsmenge

$$\tilde{P} = \{x \in \mathbb{R}^4 : \tilde{A}x \leq b, x \geq 0\},$$

die sich leider nicht mehr einfach skizzieren lässt. Um das System nun in Standardform zu bringen fügen wir nun die vier „Schlupfvariablen“ hinzu, d.h. wir erhalten

$$\bar{A} = \begin{pmatrix} 1 & 1 & -1 & -1 & 1 & 0 & 0 & 0 \\ 1 & -1 & -1 & 1 & 0 & 1 & 0 & 0 \\ -1 & 1 & 1 & -1 & 0 & 0 & 1 & 0 \\ -1 & -1 & 1 & 1 & 0 & 0 & 0 & 1 \end{pmatrix}$$

und das Polyeder

$$\bar{P} = \{z \in \mathbb{R}^8 : \bar{A}z = b, z \geq 0\}.$$

Die Abbildung

$$P \rightarrow \bar{P}, \quad \begin{pmatrix} x \\ y \end{pmatrix} \mapsto \begin{pmatrix} x^+ \\ y^+ \\ x^- \\ y^- \\ 1 - x^+ - y^+ + x^- + y^- \\ 1 - x^+ + y^+ + x^- - y^- \\ 1 + x^+ - y^+ - x^- + y^- \\ 1 + x^+ + y^+ - x^- - y^- \end{pmatrix},$$

wobei $x^+ = \max\{x, 0\}$, $x^- = \max\{-x, 0\}$ und y^+ , y^- analog, ist eine Bijektion mit Umkehrabbildung

$$\bar{P} \rightarrow P, \quad \begin{pmatrix} z_1 \\ z_2 \\ z_3 \\ z_4 \\ z_5 \\ z_6 \\ z_7 \\ z_8 \end{pmatrix} \mapsto \begin{pmatrix} z_1 - z_3 \\ z_2 - z_4 \end{pmatrix}.$$

Wie man sieht ist die Darstellung einerseits einfacher geworden, da wir, abgesehen von den Nicht-Negativitätsbedingungen, nur Gleichungen haben. Andererseits hat dies dazu geführt, dass wir das an-sich zweidimensionale Polyeder jetzt als Teilmenge des $\mathbb{R}^8$ beschreiben, d.h. die Anzahl der Variablen hat sich massiv erhöht.

1.3 Lösbarkeit von linearen Ungleichungssystemen

Nehmen wir nun an, dass wir das Minimum der linearen Abbildung

$$f: \mathbb{R}^2 \rightarrow \mathbb{R}, \quad \begin{pmatrix} x \\ y \end{pmatrix} \mapsto 2x + y = c^\top \begin{pmatrix} x \\ y \end{pmatrix} \quad \text{mit} \quad c = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

auf P suchen. Um das lineare Programm

$$\min\{c^\top x: Ax \leq b\}$$

in äquivalentes Programm in Standardform zu bringen müssen wir also c durch ein passendes $\bar{c} \in \mathbb{R}^8$ ersetzen. Als Hintereinanderausführung der obigen Umkehrabbildung mit f erhalten wir gerade $z \mapsto \bar{c}^\top z$ mit

$$\bar{c}^\top = (2 \quad 1 \quad -2 \quad -1 \quad 0 \quad 0 \quad 0 \quad 0).$$

Hier fällt insbesondere auf, dass die Zielfunktion auf den Schlupfvariablen verschwindet. Dies ist nicht überraschend, da wir diese Variablen ja gerade als die Differenz des tatsächlichen Variablenwerts zum größtmöglichen Variablenwert gewählt haben und sie daher für das eigentliche Problem keine Rolle spielen.

Wenn wir allgemein ein lineares Programm

$$\min\{c^\top x: Ax \leq b\}$$

in Standardform bringen wollen, sehen wir analog zum obigen Beispiel

$$\bar{c}^\top = (c^\top \quad -c^\top \quad 0_m),$$

da

$$\bar{c}^\top \begin{pmatrix} x^+ \\ x^- \\ b - Ax^+ + Ax^- \end{pmatrix} = c^\top x^+ - c^\top x^- = c^\top (x^+ - x^-) = c^\top x$$

gilt.

Da sich die Menge $\{x \in \mathbb{R}^n: Ax = b\}$ durch (gemeinsame) Zeilenumformungen von A und b nicht ändert, können wir, zumindest im Fall, dass $Ax = b$ Lösungen hat, ohne Einschränkung der Allgemeinheit davon ausgehen, dass die Zeilen der Matrix A linear unabhängig sind.

Zum Abschluss dieses Abschnitts wollen wir noch das Lemma von Farkas beweisen, das charakterisiert wann ein System linearer Ungleichungen in Standardform eine Lösung besitzt. Dazu wollen wir folgenden Trennungssatz (ohne Beweis) wiederholen, der in der Funktionalanalysis (für beliebige normierte Räume statt $\mathbb{R}^n$) manchmal als geometrische Version von Hahn-Banach bezeichnet wird.

Satz 1.3.3. *Es sei $C \subset \mathbb{R}^n$ eine abgeschlossene konvexe Menge. Zu jedem Punkt $x_0 \in \mathbb{R}^n \setminus C$ gibt es ein $z \in \mathbb{R}^n$ mit*

$$z^\top x_0 > \sup\{z^\top x: x \in C\}.$$

1 Geometrie linearer Ungleichungen

Beweis. Siehe Analysis 4 (oder Lineare Algebra 2). $\square$

Mit diesem technischen Hilfsmittel in der Hand, können wir nun den folgenden Alternativsatz beweisen.

Satz 1.3.4 (Lemma von Farkas). *Es sei $A \in \text{Mat}_{m,n}(\mathbb{R})$ und $b \in \mathbb{R}^m$. Es besitzt genau eines der Systeme*

$$(i) \quad Ax = b, \quad x \geq 0$$

$$(ii) \quad A^T y \geq 0, \quad b^T y < 0$$

eine Lösung.

Beweis. Interpretiert man das Produkt Ax als Linearkombination der Spalten von A , so sieht man dass das System (i) genau dann eine Lösung hat, wenn

$$b = Ax = \sum_{j=1}^n A_{-j} x_j$$

mit $x_j \geq 0$ gilt. Dies bedeutet aber gerade, dass b im von den Spalten von A erzeugten Kegel liegt, d.h. genau dann wenn $b \in \text{KK}(\{A_{-i} : 1 \leq i \leq m\})$. Da es sich dabei um eine abgeschlossene konvexe Menge handelt, hat nach Satz 1.3.3 das System (i) also genau dann keine Lösung wenn es ein $z \in \mathbb{R}^n$ mit

$$z^T b > \sup \left\{ z^T x : x \in \text{KK}(\{A_{-i} : 1 \leq i \leq m\}) \right\}$$

gibt. Insbesondere erhalten wir, dass $z^T(\lambda A_{-i}) < z^T b$ für alle $\lambda > 0$ und folglich

$$z^T A_{-i} < \frac{z^T b}{\lambda}$$

für alle $\lambda > 0$, woraus wir $z^T A_{-i} \leq 0$ schließen können, indem wir $\lambda \rightarrow \infty$ betrachten. Wir setzen nun $y := -z$ und erhalten aus der obigen Ungleichung, dass $y^T x \geq 0$ für alle $x \in \text{KK}(\{A_{-i} : 1 \leq i \leq m\})$ und folglich

$$A^T y = (y^T A)^T \geq 0$$

und

$$b^T y = y^T b > 0 = \max \left\{ y^T x : x \in \text{KK}(\{A_{-i} : 1 \leq i \leq m\}) \right\},$$

d.h. das System (ii) hat eine Lösung. Wir haben also gezeigt, dass das System (ii) eine Lösung hat wenn (i) keine Lösung hat. Umgekehrt folgt aus der Existenz einer Lösung von (ii), dass wir b und den von den Spalten von A erzeugten Kegel durch eine Hyperebene trennen können, also hat in diesem Fall nach obigen Überlegungen (i) keine Lösung. $\square$

1.4 Extrema linearer Abbildungen auf Polyedern

Wir betrachten das Verhalten linearer Abbildungen auf Polyedern.

Satz 1.4.1. *Es sei $P = \text{Konv}(\{x_1, \dots, x_k\}) + \text{KK}(\{y_1, \dots, y_m\})$ ein Polyeder und*

$$f: \mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto c^\top x$$

mit $c \in \mathbb{R}^n$ eine lineare Abbildung. Dann ist f genau dann auf P nach unten unbeschränkt, wenn es ein y_j mit $c^\top y_j < 0$ gibt.

Beweis. Angenommen es gibt ein y_j mit $c^\top y_j < 0$, so ist nach Konstruktion für jedes $\lambda \geq 0$ auch $x_i + \lambda y_j \in P$ sowie

$$f(x_i + \lambda y_j) = c^\top x_i + \lambda c^\top y_j \rightarrow -\infty$$

für $\lambda \rightarrow \infty$. Also ist f auf P unbeschränkt.

Da jedes $x \in P$ eine Darstellung der Form

$$x = \sum_{i=1}^k \lambda_i x_i + \sum_{j=1}^m \mu_j y_j \quad \text{mit} \quad \sum_{i=1}^k \lambda_i = 1, \quad \lambda_1, \dots, \lambda_k, \mu_1, \dots, \mu_m \geq 0$$

und

$$\sum_{i=1}^k \lambda_i c^\top x_i$$

beschränkt ist, kann f nur nach unten unbeschränkt sein, wenn $c^\top y_j < 0$ für mindestens ein y_j . $\square$

Bemerkung 1.4.2. Ersetzt man c durch $-c$ erhält man aus dem obigen Satz, dass eine lineare Abbildung auf einem Polyeder $P = \text{Konv}(\{x_1, \dots, x_k\}) + \text{KK}(\{y_1, \dots, y_m\})$ genau dann nach oben unbeschränkt ist, wenn es ein y_j mit $c^\top y_j > 0$ gibt.

Satz 1.4.3. *Es seien $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $P = P(A, b) \subset \mathbb{R}^n$ ein Polyeder mit mindestens einer Ecke und $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine lineare Abbildung, d.h. $f(x) = c^\top x$ für ein $c \in \mathbb{R}^n$. Ist f auf P unten beschränkt, so gibt es eine Ecke $v \in P$ mit*

$$f(v) = \min\{f(z) : z \in P\}$$

d.h. die lineare Funktion f nimmt ihr Minimum in einer Ecke an.

Beweis. Wir verwenden die Darstellung

$$P = \text{Konv}(\{x_1, \dots, x_k\}) + \text{KK}(\{y_1, \dots, y_m\}).$$

Da f auf P nach unten beschränkt ist, gilt nach Satz 1.4.1, dass $c^\top y_j \geq 0$ für alle $j = 1, \dots, m$. Da jedes $z \in P$ eine Darstellung der Form

$$z = \sum_{i=1}^k \lambda_i x_i + \sum_{j=1}^m \mu_j y_j, \quad \lambda_1, \dots, \lambda_k, \mu_1, \dots, \mu_m \geq 0, \quad \sum_{i=1}^k \lambda_i = 1$$

1 Geometrie linearer Ungleichungen

hat, erhalten wir

$$c^T z = \sum_{i=1}^k \lambda_i c^T x_i + \sum_{j=1}^m \mu_j c^T y_j \geq \sum_{i=1}^k \lambda_i c^T x_i$$

und somit

$$\begin{aligned} \inf\{c^T z : z \in P\} &= \inf\{c^T z : z \in \text{Konv}(\{x_1, \dots, x_k\})\} \\ &= \min\{c^T z : z \in \text{Konv}(\{x_1, \dots, x_k\})\}, \end{aligned}$$

da $\text{Konv}(\{x_1, \dots, x_k\})$ kompakt und f als lineare Abbildung stetig ist. Es gibt daher ein $v \in P$ mit

$$f(v) = \inf\{f(z) : z \in P\} = \min\{f(z) : z \in P\}.$$

Wir müssen also nur noch zeigen, dass es auch eine Ecke mit dieser Eigenschaft gibt. Zuerst bemerken wir, dass für alle $z \in P$ die Ungleichung $c^T z \geq c^T v =: -d$ erfüllt ist. In anderen Worten, die Ungleichung $-c^T z \leq d$ ist zulässig für P und

$$v \in P' := P \cap \{x \in \mathbb{R}^n : -c^T x = d\}. \quad (1.5)$$

Insbesondere nimmt die Funktion f ihr Maximum auf P in allen Punkten von P' an. Wir können nun das Verfahren am Ende des Beweises von Satz 1.2.7 anwenden um eine Ecke von P' zu finden. Wegen (1.5) ist dies auch eine Ecke von P und damit haben wir eine Ecke gefunden, in der f das Maximum annimmt. $\square$

Diese Sätze besagen gerade, dass wenn f auf P nach unten beschränkt ist und P mindestens eine Ecke hat, das Minimum in einer Ecke angenommen wird. Diese Informationen bilden die Grundlage des sogenannten Simplexalgorithmus, den wir in Kapitel 2 behandeln werden.

1.5 Literatur und Ausblick

Die Definition von Polyedern als Durchschnitte von abgeschlossenen Halbräumen wird in der Literatur manchmal auch als H -Polyeder und die als konvexe Hülle von endlichen vielen Punkten als V -Polyeder bezeichnet. Der Beweis der Äquivalenz dieser beiden Definition basiert im wesentlichen auf den in Kapitel 1 von [15] präsentierten Beweisen.

Der Beweis von Satz 1.1.13 basiert auf dem Beweis von Lemma 3.12 in [8, S. 60].

Eine detailliertere Einführung in die lineare Optimierung und ihre Anwendungen findet sich beispielsweise im Buch [3]. Eine ausführliche Darstellung der verwendeten Polyedertheorie findet sich in [5].

1.6 Aufgaben

(1.1) OPERATIONEN MIT KONVEXEN MENGEN: Wir betrachten eine Folge $\{C_k\}_{k \in \mathbb{N}}$ konvexer Mengen $C_k \subset \mathbb{R}^n$.

- Zeigen Sie, dass der Durchschnitt $\bigcap_{k=1}^{\infty} C_k$ eine konvexe Menge ist.
- Geben Sie zwei konvexe Mengen an, deren Vereinigung nicht konvex ist.
- Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ eine lineare Abbildung. Zeigen Sie, dass $f(C_m)$ eine konvexe Menge ist.
- Es sei $0 \neq f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine lineare Abbildung. Zeigen Sie, dass für $a \in \mathbb{R}$ die Mengen

$$H_f(a) = \{x \in \mathbb{R}^n : f(x) = a\} \quad (\text{Hyperebene})$$

und

$$H_{f,-}(a) = \{x \in \mathbb{R}^n : f(x) \leq a\} \quad (\text{Halbraum})$$

konvex sind.

- Schließen Sie aus dem Obigen, dass Polyeder (endliche Durchschnitte von Halbräumen) konvex sind.

(1.2) KONVEXE MENGE UND KONVEXKOMBINATIONEN: Es sei $C \subset \mathbb{R}^n$ eine beliebige Menge. Eine Linearkombination der Form

$$\sum_{k=1}^m \lambda_k x_k \quad \text{mit} \quad \lambda_k \in [0, 1], \quad x_k \in C, \quad \text{und} \quad \sum_{k=1}^m \lambda_k = 1$$

nennt man Konvexkombination (von Elementen von C). Zeigen Sie, dass C genau dann konvex ist, wenn die Menge C alle Konvexkombinationen von Elementen von C enthält.

(1.3) KONVEXE HÜLLE: Es sei $A \subset \mathbb{R}^n$ eine beliebige Menge. Zeigen Sie, dass die konvexe Hülle die folgenden Eigenschaften hat:

- $A \subset \text{Konv}(A)$.
- $\text{Konv}(A)$ ist die kleinste konvexe Menge, die A enthält, d.h. für jede konvexe Menge C mit $A \subset C$ gilt $\text{Konv}(A) \subset C$.
- Die konvexe Hülle hat die Darstellung

$$\text{Konv}(A) = \left\{ \sum_{k=1}^m \lambda_k a_k : \lambda_k \in [0, 1], \sum_{k=1}^m \lambda_k = 1, a_k \in A, m \in \mathbb{N} \right\}$$

Hinweise: (1) Die rechte Menge ist konvex und enthält A . (2) Was bedeutet die Tatsache, dass $\text{Konv}(A)$ konvex ist und A enthält für Konvexkombinationen von Elementen von A ?

1 Geometrie linearer Ungleichungen

(1.4) KONVEXE MENGEN: Welche der folgenden Mengen sind konvex?

- a) Die Einheitskreisscheibe $\{(x, y) \in \mathbb{R}^2 : x^2 + y^2 \leq 1\}$.
- b) Der Einheitskreis $\{(x, y) \in \mathbb{R}^2 : x^2 + y^2 = 1\}$.
- c) Ein beliebiger linearer Unterraum von $\mathbb{R}^n$.
- d) Ein beliebiger affiner Unterraum von $\mathbb{R}^n$.
- e) Die Menge $\{(x, y) \in \mathbb{R}^2 : x^{1/2} + y^{1/2} \leq 1\}$.

Skizzieren Sie die obigen Mengen.

(1.5) POLYEDER: Welche der folgenden Mengen sind Polyeder?

- a) $\{(x, y, z) \in \mathbb{R}^3 : \max\{|x|, |y|, |z|\} \leq 1\}$
- b) $\{(x, y, z) \in \mathbb{R}^3 : x^2 + y^2 \leq 1\}$
- c) $\{(x, y, z) \in \mathbb{R}^3 : xy \geq 0, x + y \geq 1\}$
- d) $\{(x, y, z) \in \mathbb{R}^3 : \max\{|x|, |y|\} \leq z\}$

Bestimmen Sie für die Polyeder unter diesen Mengen eine Darstellung sowohl als endlicher Durchschnitt von Halbräumen als auch als Summe

$$\text{Konv}(\{x_1, \dots, x_k\}) + \text{KK}(\{y_1, \dots, y_k\}).$$

Skizzieren Sie die Polyeder.

(1.6) KONVEXE KEGEL UND KONISCHE LINEARKOMBINATIONEN: Es sei $A \subset \mathbb{R}^n$ eine beliebige Menge. Zeigen, Sie dass

$$\text{KK}(A) = \left\{ \sum_{i=1}^k \lambda_i x_i : m \in \mathbb{N}, x_i \in A, \lambda_i \geq 0 \right\}.$$

Die Linearkombinationen mit positiven Koeffizienten werden manchmal als konische Linearkombinationen bezeichnet.

(1.7) ERZEUGENDENSYSTEM POLYEDRISCHER KEGELS: Wir betrachten die durch die folgenden Matrizen A und B als $C_1 = P(A, 0)$ und $C_2 = P(B, 0)$ gegebenen polyedrischen Kegel.

$$A = \begin{pmatrix} 1 & -1 & -1 \\ 0 & -1 & 0 \\ -2 & 1 & 0 \\ -1 & 1 & -1 \end{pmatrix} \quad \text{und} \quad B = \begin{pmatrix} 1 & 0 & 0 \end{pmatrix}$$

Bestimmen Sie $x_1, \dots, x_m \in \mathbb{R}^3$ und $y_1, \dots, y_k \in \mathbb{R}^3$ mit $C_1 = \text{KK}\{x_1, \dots, x_m\}$ und $C_2 = \text{KK}\{y_1, \dots, y_k\}$.

- (1.8) DARSTELLUNG POLYEDRISCHER KEGEL: Es seien $y_1, \dots, y_m \in \mathbb{R}^n$ und wir wollen zeigen, dass die Menge $C := \text{KK}(\{y_1, \dots, y_m\})$ ein polyedrischer Kegel ist.

a) Zeigen Sie, dass die Menge

$$P := \left\{ (x, \lambda) \in \mathbb{R}^{n+m} : x = \sum_{i=1}^m \lambda_i y_i, \lambda_1, \dots, \lambda_m \geq 0 \right\}$$

ein polyedrischer Kegel ist, dessen Bild unter der Projektion

$$\pi: \mathbb{R}^{n+m} \rightarrow \mathbb{R}^n, (x, z) \mapsto x$$

die Menge C ist, d.h. $\pi(P) = C$.

- b) Es sei $P(A, 0)$ ein polyedrischer Kegel. Zeigen Sie, dass dessen Projektion auf die Hyperebene $\{x \in \mathbb{R}^d : x_k = 0\}$ durch $P(B, 0)$ gegeben ist, wenn die Matrix B wie folgt aus den Zeilen von A erstellt wird:

- i. Alle Zeilen A_{i-} mit $A_{ik} = 0$ werden übernommen.
- ii. Ist $A_{ik} > 0$ und $A_{jk} < 0$, so fügen wir die Zeile $A_{ik}A_{j-} - A_{jk}A_{i-}$ zu B hinzu.
- iii. Die Zeilen e_k^T und $-e_k^T$ werden hinzugefügt.

Hinweis: Die Zeilen von B sind positive Linearkombinationen von Zeilen von A .

- c) Schließen Sie aus (a) und (b), dass es sich bei $\text{KK}(\{y_1, \dots, y_m\})$ um einen polyedrischen Kegel handelt.

- (1.9) AFFINE HÜLLE EINER MENGE: Es sei $A \subset \mathbb{R}^n$ eine beliebige Menge. Zeigen Sie, dass

$$\text{Aff}(A) = \left\{ \sum_{i=1}^m \lambda_i x_i : m \in \mathbb{N}, x_i \in A, \lambda_i \in \mathbb{R} \text{ und } \sum_{i=1}^m \lambda_i = 1 \right\}.$$

Was bedeutet die obige Charakterisierung geometrisch?

- (1.10) POLYTOPE UND EXTREMALPUNKTE: Zeigen Sie, dass jedes Polytop die konvexe Hülle seiner Ecken ist.

1 Geometrie linearer Ungleichungen

(1.11) POLYTOP DER DOPPELT STOCHASTISCHEN MATRIZEN:

Eine Matrix $A \in \text{Mat}_{n,n}(\mathbb{R})$ heißt *doppelt stochastisch*, falls alle Einträge nicht-negativ sind und

$$\sum_{i=1}^n a_{ij} = \sum_{j=1}^n a_{ij} = 1 \quad \text{für alle } 1 \leq i, j \leq n$$

gilt. Eine Matrix $A \in \text{Mat}_{n,n}(\{0, 1\})$ heißt *Permutationsmatrix*, falls in jeder Zeile und in jeder Spalte genau ein Eintrag Eins ist.

- a) Zeigen Sie, dass eine Konvexkombination doppelt stochastischer Matrizen eine doppelt stochastische Matrix ist.
- b) Zeigen Sie, dass die Menge

$$P = \{A \in \text{Mat}_{n,n}(\mathbb{R}) : A \text{ doppelt stochastisch}\}$$

ein Polytop ist.

- c) Zeigen Sie, dass die Ecken von P Permutationsmatrizen sind.
- d) Zeigen Sie, dass eine Matrix genau dann doppelt stochastisch ist, wenn sie Konvexkombination von Permutationsmatrizen ist.

(1.12) DUALES POLYEDER: Es sei $A \subset \mathbb{R}^n$ eine Menge. Wir betrachten die Menge

$$A^\circ := \{y \in \mathbb{R}^n : \langle x, y \rangle \leq 1 \text{ für alle } x \in A\}.$$

- a) Zeigen Sie, dass A° eine konvexe Menge ist.
- b) Zeigen Sie, dass $A^\circ = \text{Konv}(A)^\circ$ ist.
- c) Zeigen Sie, dass P° ein Polyeder ist, falls P ein Polytop ist.
- d) Zeigen Sie, dass $A^{\circ\circ} := (A^\circ)^\circ = A$, falls A konvex und abgeschlossen ist.
Hinweis: geometrische Version von Hahn-Banach
- e) Verwenden Sie die obigen Beobachtungen und einen geeigneten Satz der Vorlesung, um ein Verfahren anzugeben wie man zu $x_1, \dots, x_k \in \mathbb{R}^n$ eine Matrix $A \in \text{Mat}_{n,n}(\mathbb{R})$ und ein $b \in \mathbb{R}^m$ mit $\text{Konv}(\{x_1, \dots, x_k\}) = P(A, b)$ finden kann.

- (1.13) LINEARES PROGRAMM UND STANDARDFORM: Wir betrachten das lineare Programm

$$\min\{c^T x : Ax \leq b, x \geq 0\}$$

mit

$$A = \begin{pmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \\ 10 & 1 & 4 \\ \frac{1}{15} & \frac{1}{36} & \frac{1}{24} \\ 0 & 1 & 0 \end{pmatrix}, \quad b = \begin{pmatrix} -3 \\ -5 \\ -4 \\ 100 \\ 1 \\ 25 \end{pmatrix}, \quad \text{und} \quad c = \begin{pmatrix} -500 \\ -100 \\ -250 \end{pmatrix}$$

Geben Sie ein äquivalentes lineares Programm in Standardform an, d.h. verwenden Sie die in der Vorlesung besprochenen Transformationen, um obiges Programm in Standardform zu bringen.

- (1.14) TOPOLOGISCHE EIGENSCHAFTEN VON KONVEXEN HÜLLEN UND KONVEXEN KEGELN:

- a) Es sei $K \subset \mathbb{R}^n$ eine kompakte Menge. Zeigen Sie, dass $\text{Konv}(K)$ kompakt ist.
Hinweis: Carathéodory (Lineare Algebra 2)
- b) Es sei $K = \{(x, y) \in \mathbb{R}^2 : 0 \leq x \leq 1, 0 \leq y \leq \sqrt{x}\}$. Zeigen Sie, dass K kompakt ist aber $\text{KK}(K)$ nicht abgeschlossen ist.
- c) Es sei $P \subset \mathbb{R}^n$ ein unbeschränktes Polyeder. Zeigen Sie, dass der konvexe Kegel

$$\text{KK}(P \times \{1\}) \subset \mathbb{R}^{n+1}$$

nicht abgeschlossen ist.

- d) Geben Sie ein Beispiel einer abgeschlossenen Menge $A \subset \mathbb{R}^n$ deren konvexe Hülle nicht abgeschlossen ist.

- (1.15) LÖSUNGSRAUM EINER MATRIX EINMAL ANDERS BETRACHTET: Es sei $A \in \text{Mat}_{m,n}(\mathbb{R})$ eine Matrix mit $\text{Rang } A = k$. Wir interessieren uns für den Lösungsraum

$$L(A, 0) = \{x \in \mathbb{R}^n : Ax = 0\}.$$

- a) Es sei A' eine Teilmatrix von A , die aus k linear unabhängigen Zeilen besteht. Argumentieren Sie, dass falls $k < n$ ist, eine Teilmatrix I' von I_n so existiert, dass die Matrix

$$B := \begin{pmatrix} A' \\ I' \end{pmatrix}$$

invertierbar ist.

- b) Zeigen Sie, dass $B^{-1}e_j$ für $j > k$ eine Lösung von $Ax = 0$ ist und dass $\{B^{-1}e_j : j > k\}$ eine Basis von $L(A, 0)$ ist.

1 Geometrie linearer Ungleichungen

- c) Sei $b \in \mathbb{R}^m$, $k = m < n$ und $P \in \text{Mat}_{m,m}(\mathbb{R})$ eine invertierbare Matrix und eine m -elementige Menge $J \subset \{1, \dots, n\}$ mit $(PA)_{-j} = e_{i_j}$, $i_j \in \{1, \dots, m\}$ für alle $j \in J$ und $\{i_j : j \in J\} = \{1, \dots, m\}$. Zeigen Sie, dass z mit

$$z_j = \begin{cases} (Pb)_{i_j} & \text{für } j \in J \\ 0 & \text{sonst} \end{cases}$$

eine Lösung von $Ax = b$ ist.

- (1.16) REDUNDANTE UNGLEICHUNGEN IN LINEAREN PROGRAMMEN: wir betrachten das Ungleichungssystem

$$Ax \leq b \quad \text{mit } A = \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 1 & 2 \\ 3 & 2 \\ 1 & 0 \end{pmatrix} \quad \text{und } b = \begin{pmatrix} 0 \\ 0 \\ 2 \\ 4 \\ 1 \end{pmatrix}$$

Welche der obigen Ungleichungen sind redundant, d.h. welche können weggelassen werden, ohne dass sich die durch das Ungleichungssystem definierte Menge ändert?

Bonus: Geben Sie ein (allgemeines) Verfahren an, mit dem überprüft werden kann, ob eine Ungleichung redundant ist.

- (1.17) MEHR ZU SEITENFLÄCHEN UND ECKEN VON POLYEDERN: Es sei $P \subset \mathbb{R}^n$ ein Polyeder, das mindestens eine Ecke hat.

- a) Zeigen Sie, dass jede nichtleere Seitenfläche von P eine Ecke enthält.
b) Wir betrachten eine Darstellung

$$P = \text{Konv}(\{x_1, \dots, x_k\}) + \text{KK}(\{y_1, \dots, y_m\})$$

mit $x_1, \dots, x_k, y_1, \dots, y_m \in \mathbb{R}^n$. Zeigen Sie, dass jede Ecke von P in der Menge $\{x_1, \dots, x_k\}$ enthalten ist.

- c) Wir betrachten das algebraische Innere

$$P^{a\circ} = \{x \in P : \forall z \in \mathbb{R}^n \exists r > 0 \forall |t| < r : x + tv \in P\}$$

von P . Zeigen Sie, dass $P^{a\circ} = P^\circ$ ist.

- d) Verwenden Sie (c) um zu zeigen, dass Sie falls P nichtleeres Inneres hat $v_1, \dots, v_k$ und $a_1, \dots, a_k$ mit $P = \bigcap_{i=1}^k H_{v_i, a_i}$ so wählen können, dass $P_i := \{x \in \mathbb{R}^n : \langle v_i, x \rangle = a_i\} \cap P$ ein Polyeder ist, das in der Hyperebene $\{x \in \mathbb{R}^n : \langle v_i, x \rangle = a_i\}$ nicht-leeres Inneres hat. Schließen Sie daraus, dass P_i eine Facette ist.

- (1.18) EINE PROGRAMMIERAUFGABE ZU AUFWÄRMEN: Die folgenden beiden Unteraufgaben können in einer Programmiersprache Ihrer Wahl gelöst werden. Für eine bessere Vergleichbarkeit empfehle ich Ihnen Python zu verwenden. Im Sinne einer besseren Präsentierbarkeit verzichten Sie bitte auf die Verwendung von Programmiersprachen wie „Whitespace“.

- a) Schreiben Sie eine Funktion, die als Eingabe eine Matrix $A \in \text{Mat}_{m,n}(\mathbb{R})$ und einen Vektor $b \in \mathbb{R}^m$ akzeptiert und Vektoren

$$x_1, \dots, x_k \quad \text{sowie} \quad y_1, \dots, y_m$$

mit

$$P(A, b) = \text{Konv}(\{x_1, \dots, x_k\}) + \text{KK}(\{y_1, \dots, y_m\})$$

zurück gibt.

- b) Schreiben Sie eine Funktion, die als Eingabe eine Matrix $A \in \text{Mat}_{m,n}(\mathbb{R})$ und zwei Vektoren $b \in \mathbb{R}^m$ sowie $c \in \mathbb{R}^n$ akzeptiert und als Ausgabe $\bar{A} \in \text{Mat}_{m,2n+m}(\mathbb{R}^n)$, $b \in \mathbb{R}^m$ und $\bar{c} \in \mathbb{R}^{2n+m}$ so zurück gibt, dass

$$\min\{\bar{c}^\top z : \bar{A}z = b, z \geq 0\}$$

ein lineares Programm ist, das zum linearen Programm

$$\min\{c^\top x : Ax \leq b\}$$

äquivalent ist.

Testen Sie Ihre Programme an den Beispielen der Vorlesung und an einem weiteren von Ihnen gewählten Testbeispiel.

- (1.19) LINEARES PROGRAMM IN STANDARDFORM BRINGEN: Wir suchen das Minimum der Funktion $f(x, y) = x + y$ auf der Menge, die durch die Ungleichungen

$$\begin{array}{ll} x \geq -1 & x + y \leq 3 \\ y \leq 2 & x - y \leq 1 \end{array}$$

gegeben ist.

- Formulieren Sie obiges Problem als lineares Programm und bringen Sie dieses auf Standardform.
- Skizzieren Sie den zulässigen Bereich und bestimmen Sie die Ecken.
- Berechnen Sie die Werte der Zielfunktion in den Ecken.

2 Der Simplexalgorithmus

Wir haben in Kapitel 1 gesehen, dass lineare Abbildungen auf Polyedern ihr Minimum in einer Ecke annehmen, sofern sie nach unten beschränkt sind. Das Ziel dieses Kapitels, ist es einen Algorithmus anzugeben, mit dem dieses Minimum gefunden werden kann. Der hier besprochene Simplexalgorithmus basiert wesentlich auf den geometrischen Ideen des vorigen Kapitels.

2.1 Basislösungen

Wir betrachten ein lineares Programm

$$\min \left\{ c^T x : Ax = b, x \geq 0 \right\}$$

in Standardform mit $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Wir treffen in diesem Abschnitt folgende zwei Annahmen:

1. Das lineare Gleichungssystem $Ax = b$ hat zumindest eine Lösung $x \geq 0$.
2. Die Zeilen der Matrix A sind linear unabhängig, d.h. $\text{Rang } A = m$.

Wir setzen $N = \{1, \dots, n\}$ bezeichnen mit A_B zu $B \subset N$ die Untermatrix von A , die aus den Spalten mit Index in B besteht, d.h.

$$A_B = (a_{ij})_{1 \leq i \leq m, j \in B}.$$

Eine Teilmenge $B \subset N$, nennt man *Basismenge*, falls die Matrix A_B invertierbar ist. Die Menge $K = N \setminus B$ nennt man zugehörige *Nichtbasismenge*.

Bemerkung 2.1.1. Ein Grund für die Bezeichnung *Basismenge* ist, dass die Spalten von A_B eine Basis des Spaltenraums von A bilden.

Für $x \in \mathbb{R}^n$ und eine Basismenge $B \subset N$ mit $K = N \setminus B$ setzen wir analog

$$x_B = (x_i)_{i \in B} \quad \text{und} \quad x_K = (x_i)_{i \in K}.$$

Eine Lösung $x \in \mathbb{R}^n$ von $Ax = b$ heißt *Basislösung* zur Basis B , falls $x_K = 0$ ist. Sie heißt *zulässige Basislösung*, falls $x_K = 0$ und $x_B \geq 0$ ist.

Satz 2.1.2. Sei $A \in \text{Mat}_{m,n}(\mathbb{R})$ und $b \in \mathbb{R}^m$. Jede Ecke des Polyeders

$$\{x \in \mathbb{R}^n : Ax = b, x \geq 0\}$$

ist eine zulässige Basislösung zu einer Basis $B \subset N$. Umgekehrt ist jede zulässige Basislösung eine Ecke dieses Polyeders.

2 Der Simplexalgorithmus

Beweis. Dies ist genau die Aussage von Korollar 1.2.6. $\square$

Bemerkung 2.1.3. Auch wenn jede zulässige Basislösung einer Ecke und jede Ecke einer zulässigen Basislösung entspricht, ist die entsprechende Zuordnung nicht notwendigerweise eindeutig. Hat man eine zulässige Basislösung $x \in \mathbb{R}^n$ zu einer Basis B mit $x_j = 0$ für ein $j \in B$, kann es sein, dass es sich auch um eine Basislösung zu einer anderen Basis handelt. In diesem Fall entsprechen beide Basislösungen der gleichen Ecke des Polyeders.

Beispiel 2.1.4. Wir betrachten das lineare Programm in Standardform aus Beispiel 1.3.2, d.h. wir haben

$$A = \begin{pmatrix} 1 & 1 & -1 & -1 & 1 & 0 & 0 & 0 \\ 1 & -1 & -1 & 1 & 0 & 1 & 0 & 0 \\ -1 & 1 & 1 & -1 & 0 & 0 & 1 & 0 \\ -1 & -1 & 1 & 1 & 0 & 0 & 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} \quad \text{und} \quad c = \begin{pmatrix} 2 \\ 1 \\ -2 \\ -1 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}.$$

Die Menge $B = \{1, 2, 7, 8\}$ ist eine Basismenge, da die Matrix

$$A_B = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 1 & -1 & 0 & 0 \\ -1 & 1 & 1 & 0 \\ -1 & -1 & 0 & 1 \end{pmatrix}$$

invertierbar ist. Die zugehörige Basislösung

$$x = (1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 2 \ 2)^T$$

ist zulässig, da

$$x_K = (0 \ 0 \ 0 \ 0)^T \quad \text{und} \quad x_B = (1 \ 0 \ 2 \ 2)^T \geq 0$$

ist. x ist aber auch eine zulässige Basislösung zu $B' = \{1, 6, 7, 8\}$. Dies entspricht genau dem in Bemerkung 2.1.3 angesprochenen Phänomen der möglichen Nichteindeutigkeit.

Es seien $B, B' \subset N$ zwei Basismengen. Die Basismengen heißen *benachbart*, falls sie sich genau um ein Element unterscheiden.

2.2 Der Simplexschritt

Sei $x \in \mathbb{R}^n$ eine zulässige Basislösung zur Basis $B \subset N = \{1, \dots, n\}$. Aus

$$b = Ax = A_B x_B + A_K x_K = A_B x_B$$

und der Invertierbarkeit von A_B erhalten wir, dass $x_B = A_B^{-1}b$. Ist darüber hinaus $z \in \mathbb{R}^n$ ein zulässiger Punkt, so gilt

$$b = Az = A_B z_B + A_K z_K$$

und folglich

$$z_B = A_B^{-1}b - A_B^{-1}A_K z_K = x_B - A_B^{-1}A_K z_K. \quad (2.1)$$

Für $c \in \mathbb{R}^n$ ist damit also

$$\begin{aligned} c^\top z &= c_B^\top z_B + c_K^\top z_K = c_B^\top (x_B - A_B^{-1}A_K z_K) + c_K^\top z_K \\ &= c^\top x + (c_K^\top - c_B^\top A_B^{-1}A_K) z_K, \end{aligned} \quad (2.2)$$

d.h. der Wert der Zielfunktion in z unterscheidet sich vom Wert der Zielfunktion in x genau um $(c_K^\top - c_B^\top A_B^{-1}A_K) z_K$.

Wir betrachten nun die Blockmatrix

$$\begin{pmatrix} A & b \\ c^\top & 0 \end{pmatrix},$$

die wir durch Spaltenvertauschungen auf die Form

$$\begin{pmatrix} A_B & A_K & b \\ c_B^\top & c_K^\top & 0 \end{pmatrix},$$

bringen können. Mittels Gauß-Algorithmus wollen wir nun A_B auf die Einheitsmatrix transformieren und die Einträge darunter eliminieren, d.h.

$$\begin{pmatrix} A_B & A_K & b \\ c_B^\top & c_K^\top & 0 \end{pmatrix} \rightsquigarrow \begin{pmatrix} I_n & A_B^{-1}A_K & A_B^{-1}b \\ c_B^\top & c_K^\top & 0 \end{pmatrix} \rightsquigarrow \begin{pmatrix} I_n & A_B^{-1}A_K & A_B^{-1}b \\ 0 & c_K^\top - c_B^\top A_B^{-1}A_K & -c_B^\top A_B^{-1}b \end{pmatrix}.$$

Wir betrachten nun die Einträge dieser Matrix etwas genauer. In der Spalte ganz rechts steht oberhalb x_B , aus dem wir durch Ergänzen mit Null die zu B gehörige zulässige Basislösung x erhalten, und unterhalb $-c^\top x$, d.h. das negative des Werts der Zielfunktion in x . In der letzten Zeile des mittleren Blocks steht $c_K^\top - c_B^\top A_B^{-1}A_K$, aus dem wir nach obigen Überlegungen ablesen können, wie sich der Wert der Zielfunktion ändert, wenn wir von x auf einen anderen zulässigen Punkt wechseln. Man kann also aus dieser Matrix die wichtigsten Informationen zur Basis B ablesen. Daher arbeitet man oft mit diesen Matrizen und nennt

$$\frac{I_m \mid A_B^{-1}A_K \mid A_B^{-1}b}{0 \mid c_K^\top - c_B^\top A_B^{-1}A_K \mid -c_B^\top A_B^{-1}b},$$

bis auf Spaltenvertauschungen, *Simplextableau zur Basis B*.

2 Der Simplexalgorithmus

Beispiel 2.2.1. Wir arbeiten mit dem linearen Programm aus Beispiel 2.1.4 und der Basismenge $B = \{1, 2, 7, 8\}$ weiter. Wir starten mit dem Tableau

$$\begin{array}{cccccccc|c} 1 & 1 & -1 & -1 & 1 & 0 & 0 & 0 & 1 \\ 1 & -1 & -1 & 1 & 0 & 1 & 0 & 0 & 1 \\ -1 & 1 & 1 & -1 & 0 & 0 & 1 & 0 & 1 \\ -1 & -1 & 1 & 1 & 0 & 0 & 0 & 1 & 1 \\ \hline 2 & 1 & -2 & -1 & 0 & 0 & 0 & 0 & 0 \end{array}$$

und verwenden Gauß-Elimination um in den Spalten aus B die entsprechenden Standardbasisvektoren zu erhalten damit bekommen wir

$$\begin{array}{cccccccc|c} 1 & 0 & -1 & 0 & \frac{1}{2} & \frac{1}{2} & 0 & 0 & 1 \\ 0 & 1 & 0 & -1 & \frac{1}{2} & -\frac{1}{2} & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 2 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 2 \\ \hline 2 & 1 & -2 & -1 & 0 & 0 & 0 & 0 & 0 \end{array}$$

Wir setzen nur die Gauß-Elimination fort, um in den zu B gehörigen Spalten auch in der letzten Zeile Null zu erreichen. Damit kommen wir zum Simplextableau

$$\begin{array}{cccccccc|c} 1 & 0 & -1 & 0 & \frac{1}{2} & \frac{1}{2} & 0 & 0 & 1 \\ 0 & 1 & 0 & -1 & \frac{1}{2} & -\frac{1}{2} & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 2 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 2 \\ \hline 0 & 0 & 0 & 0 & -\frac{3}{2} & -\frac{1}{2} & 0 & 0 & -2 \end{array}$$

zur Basis $B = \{1, 2, 7, 8\}$.

Da wir ein Minimum der Zielfunktion suchen, legen die obigen Überlegungen nahe, dass wir überprüfen, ob der Vektor $c_K^\top - c_B^\top A_B^{-1} A_K$ eine negative Komponente hat.

2.2.1 Fall 1: $c_K^\top - c_B^\top A_B^{-1} A_K \geq 0$

Ist $c_K^\top - c_B^\top A_B^{-1} A_K \geq 0$ stoppen wir, denn der folgende Satz zeigt, dass wir ein Minimum gefunden haben.

Satz 2.2.2. Ist $c_K^\top - c_B^\top A_B^{-1} A_K \geq 0$ und x eine zulässige Basislösung zur Basis B , so nimmt die lineare Abbildung

$$z \mapsto c^\top z$$

ihr Minimum in x an.

Beweis. Wir haben in (2.2) gesehen, dass jeder zulässige Punkt $z \in \mathbb{R}^n$ die Gleichung

$$c^\top z = c^\top x + (c_K^\top - c_B^\top A_B^{-1} A_K) z_K$$

gilt. Zusammen mit $z_K \geq 0$ und $c_K^\top - c_B^\top A_B^{-1} A_K \geq 0$ folgt daraus $c^\top z \geq c^\top x$, d.h. das Minimum wird in x angenommen. $\square$

2.2.2 Fall 2: $c_K^\top - c_B^\top A_B^{-1} A_K$ hat eine negative Komponente

Sei $k \in K$ der zu einer negativen Komponente von $c_K^\top - c_B^\top A_B^{-1} A_K$ gehörige Spaltenindex.

Wir suchen nun also einen zulässigen Punkt z mit $z_k \geq 0$. Da die Zielfunktion nach Satz 1.4.3 ihr Minimum, sofern ein solches existiert, in einer Ecke annimmt, wollen wir in Anbetracht von Satz 2.1.2 eine zu B benachbarte Basis B' mit $k \in B'$ finden. Wir müssen also einen geeigneten Index $j \in B$ wählen und können dann $B' = B \cup \{k\} \setminus \{j\}$ setzen. Aus (2.1) und der Annahme, dass z eine zu B' gehörende zulässige Basislösung ist, erhalten wir

$$0 = z_j = x_j - (A_B^{-1} A_K)_{jk} z_k = x_j - (A_B^{-1} A_K)_{j-} z_K,$$

woraus wir, da nach Voraussetzung x und z zulässige Punkte sind, damit insbesondere $x_j, z_k \geq 0$, die Bedingung $(A_B^{-1} A_K)_{jk} \geq 0$ erhalten. Ist $(A_B^{-1} A_K)_{jk} = 0$, bilden die Vektoren e_b mit $b \neq k$ zusammen mit $(A_B^{-1} A_K)_{-k}$ keine Basis und folglich kann auch die Familie $(A_i)_{i \in B \cup \{k\} \setminus \{j\}}$ keine Basis des Spaltenraums von A sein. Folglich müssen wir $(A_B^{-1} A_K)_{jk} > 0$ voraussetzen.

Fall 2a: $(A_B^{-1} A_K)_{jk} \leq 0$ für alle $j \in B$

In diesem Fall stoppen wir, da nach dem folgenden Satz die Zielfunktion auf dem zulässigen Bereich nicht nach unten beschränkt ist, d.h. es gibt kein Minimum.

Satz 2.2.3. *Gilt für eine Basis $B \subset N$ und ein $k \in K$ mit $c_k - c_B^\top A_B^{-1} A_{-k} < 0$, dass $(A_B^{-1} A_K)_{jk} \leq 0$ für alle $j \in B$, so ist die lineare Abbildung*

$$z \mapsto c^\top z$$

auf dem Polyeder

$$\{x \in \mathbb{R}^n : Ax = b, x \geq 0\}$$

nach unten unbeschränkt.

Beweis. Für $\lambda \geq 0$ betrachten wir

$$z_{\lambda,B} = x_B - \lambda A_B^{-1} A_{-k}, \quad z_{\lambda,k} = \lambda \quad \text{und} \quad z_{\lambda,K \setminus \{k\}} = 0.$$

Dafür ist

$$Az_\lambda = A_B z_{\lambda,B} + A_{-k} \lambda = b - \lambda A_{-k} = b \quad \text{und} \quad z_{\lambda,B} = x_B - \lambda A_B^{-1} A_{-k} \geq 0,$$

da $x_B \geq 0$, $\lambda \geq 0$ und $A_B^{-1} A_{-k} \leq 0$. Dies bedeutet, dass z_λ für jedes $\lambda \geq 0$ ein zulässiger Punkt ist. Nach (2.2) gilt

$$c^\top z_\lambda = c^\top x + (c_k - c_B^\top A_B^{-1} A_{-k}) \lambda \rightarrow -\infty$$

für $\lambda \rightarrow \infty$, da $(c_k - c_B^\top A_B^{-1} A_{-k}) < 0$ ist, d.h. die Zielfunktion ist auf dem zulässigen Bereich nach unten unbeschränkt. $\square$

Fall 2b: Es gibt ein j mit $(A_B^{-1}A_K)_{jk} > 0$

Um im nächsten Schritt eine zulässige Basislösung zu erhalten (siehe unten), wählen wir

$$j \in \operatorname{argmin} \left\{ \frac{x_j}{(A_B^{-1}A_K)_{jk}} : (A_B^{-1}A_K)_{jk} > 0 \right\} \quad (2.3)$$

und $B' = B \cup \{k\} \setminus \{j\}$ sowie $K' = K \cup \{j\} \setminus \{k\}$.

Um diesen Schritt durchzuführen müssen wir nun also das Simplextableau zur Basis B' bestimmen. Dies wollen wir nun auf möglichst effiziente Art und Weise erreichen, d.h. wir wollen insbesondere $A_{B'}^{-1}$ nicht direkt berechnen. Wir verwenden nun wieder Gauß-Elimination, um in der k -ten Spalte den j -ten Standardbasisvektor zu erhalten. Genauer gesagt dividieren wir zuerst die j -te Zeile durch $(A_B^{-1}A_K)_{jk} > 0$ und eliminieren dann alle anderen Einträge der k -ten Spalte, indem wir von der i -ten Zeile, $i \neq j$ das $\frac{(A_B^{-1}A_K)_{ik}}{(A_B^{-1}A_K)_{jk}}$ -fache der j -ten Zeile des ursprünglichen Tableaus abziehen. In anderen Worten wir multiplizieren den oberen Teil des Tableaus (oberhalb der vertikalen Linie) von links mit der Matrix

$$E := \begin{pmatrix} 1 & \cdots & 0 & -\frac{(A_B^{-1}A_K)_{1k}}{(A_B^{-1}A_K)_{jk}} & 0 & \cdots & 0 \\ 0 & 1 & 0 & -\frac{(A_B^{-1}A_K)_{2k}}{(A_B^{-1}A_K)_{jk}} & 0 & \cdots & 0 \\ 0 & 0 & \ddots & \vdots & 0 & \cdots & 0 \\ 0 & \cdots & 0 & \frac{1}{(A_B^{-1}A_K)_{jk}} & 0 & \cdots & 0 \\ 0 & \cdots & \cdots & \vdots & 1 & 0 & 0 \\ 0 & \cdots & \cdots & \vdots & \cdots & 1 & 0 \\ 0 & \cdots & \cdots & -\frac{(A_B^{-1}A_K)_{nk}}{(A_B^{-1}A_K)_{jk}} & \cdots & 0 & 1 \end{pmatrix},$$

wobei die von Null und Eins verschiedenen Einträge in der j -ten Spalte stehen. Da wir durch die Multiplikation mit E in der k -ten Spalte den Standardbasisvektor e_j erzeugt haben und die Spalten in $B \setminus \{j\}$ sich nicht dadurch nicht ändern (da sie in der j -ten Zeile einen Nuller stehen haben), ist $EA_B^{-1}A_{B'} = I_n$ und folglich erhalten wir $EA_B^{-1} = A_{B'}^{-1}$. Schließlich eliminieren wir noch den Eintrag in der letzten Zeile der k -ten Spalte. Damit erhalten wir bis auf Spaltenvertauschungen das Tableau

$$\begin{array}{c|cc} I_m & A_{B'}^{-1}A_{K'} & A_{B'}^{-1}b \\ \hline 0 & c_{K'}^T - c_{B'}^T A_{B'}^{-1}A_{K'} & -c_{B'}^T A_{B'}^{-1}b \end{array},$$

d.h. ein Tableau zur Basis B' . Wir müssen noch nachprüfen, dass $z_{B'} := A_{B'}^{-1}b \geq 0$ ist, um zu zeigen, dass $z_{B'}$ und $z_{K'} := 0$ eine zulässige Basislösung definieren. Nach Konstruktion ist $z_{B'} = EA_B^{-1}b$, d.h.

$$z_k = \frac{x_j}{(A_B^{-1}A_K)_{jk}} \geq 0 \quad \text{und} \quad z_i = x_i - x_j \frac{(A_B^{-1}A_K)_{ik}}{(A_B^{-1}A_K)_{jk}} \quad \text{für } i \in B' \setminus \{k\}.$$

Wir haben

$$x_i - x_j \frac{(A_B^{-1}A_K)_{ik}}{(A_B^{-1}A_K)_{jk}} \geq 0 \Leftrightarrow \frac{x_i}{(A_B^{-1}A_K)_{ik}} \geq \frac{x_j}{(A_B^{-1}A_K)_{jk}}$$

und die rechte Ungleichung ist nach (2.3) erfüllt.

Beispiel 2.2.4. Wir setzen Beispiel 2.2.1 fort. Wir haben das Simplextableau

$$\begin{array}{cccccccc|c} 1 & 0 & -1 & 0 & \frac{1}{2} & \frac{1}{2} & 0 & 0 & 1 \\ 0 & 1 & 0 & -1 & \frac{1}{2} & -\frac{1}{2} & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 2 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 2 \\ \hline 0 & 0 & 0 & 0 & -\frac{3}{2} & -\frac{1}{2} & 0 & 0 & -2 \end{array}$$

zur Basis $B = \{1, 2, 7, 8\}$. Wir suchen nun einen negativen Eintrag in der letzten Zeile (links der vertikalen Linie), d.h. z.B. $-\frac{3}{2}$ und setzen daher $k = 5$. Als nächstes betrachten wir

$$\frac{x_1}{(A_B^{-1}A_K)_{15}} = 2, \quad \frac{x_2}{(A_B^{-1}A_K)_{25}} = 0, \quad (A_B^{-1}A_K)_{75} = 0 \quad \text{und} \quad \frac{x_8}{(A_B^{-1}A_K)_{85}} = 2.$$

Damit wählen wir $j = 2$ und erhalten $B' = \{1, 5, 7, 8\}$. Wir dividieren also die zweite Zeile durch $\frac{1}{2}$ und eliminieren die anderen Einträge in der fünften Spalten. Damit erhalten wir das Tableau

$$\begin{array}{cccccccc|c} 1 & -1 & -1 & 1 & 0 & 1 & 0 & 0 & 1 \\ 0 & 2 & 0 & -2 & 1 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 2 \\ 0 & -2 & 0 & 2 & 0 & 1 & 0 & 1 & 2 \\ \hline 0 & 3 & 0 & -3 & 0 & -2 & 0 & 0 & -2 \end{array}$$

zur Basis B' und sind bereit den Simplexschritt ein weiteres Mal auszuführen.

Bemerkung 2.2.5. Wir können nun eine interessante Beobachtung im Beispiel machen: Wir sind bei der Basislösung

$$x^T = (1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 2 \ 2)$$

zur Basis $B = \{1, 2, 7, 8\}$ gestartet sind und haben zur Basislösung

$$z^T = (1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 2 \ 2)$$

zur Basis $B' = \{1, 5, 7, 8\}$ gewechselt. Es ist $x = z$ und auch der Wert des linearen Programms hat sich daher nicht geändert. Dies bedeutet also, wenn der rechte obere Bereich (in dem x_B bzw. dann $z_{B'}$ steht) Nuller enthält, kann es passieren, dass man zwar die Basis wechselt, nicht aber die Ecke des zulässigen Bereichs. Die obigen Argumente garantieren uns aber, dass, wenn wir den Simplexschritt im Fall 2b beenden, wir uns in einer Ecke befinden, in der die Zielfunktion zumindest nicht größer ist in der Ecke, in der wir gestartet sind.

2 Der Simplexalgorithmus

Bemerkung 2.2.6. Nach Konstruktion enthalten die Tableaus immer m Spalten, in denen Spalten der Einheitsmatrix (und Null darunter) stehen. Diese Spalten haben im wesentlichen nur folgenden Informationsgehalt: Welche Variablen gehören zu B und zu welcher Variable gehören die Einträge ganz rechts. Man kann also die gleiche Information auch in dem kleineren Tableau

	k_1	$\dots$	k_{n-m}	
b_1	$A_B^{-1}A_K$			$A_B^{-1}b$
$\vdots$				
b_m				
	$c_K^T - c_B^T A_B^{-1} A_K$			$-c_B^T A_B^{-1} b$

mit $B = \{b_1, \dots, b_n\}$ und $K = \{k_1, \dots, k_{n-m}\}$ unterbringen und auch alle Operationen des Simplexschritts lassen sich in diesem kleineren Tableau durchführen. Angenommen wir haben das Tableau

	$\dots$	k_i	$\dots$	k_j	$\dots$	
$\vdots$		$\vdots$		$\vdots$		$\vdots$
b_r	$\dots$	α_{ri}	$\dots$	α_{rj}	$\dots$	β_r
$\vdots$		$\vdots$		$\vdots$		$\vdots$
b_s	$\dots$	α_{si}	$\dots$	α_{sj}	$\dots$	β_s
$\vdots$		$\vdots$		$\vdots$		$\vdots$
	$\dots$	γ_i	$\dots$	γ_j	$\dots$	δ

und wir wollen in der Basismenge b_s durch k_i ersetzen, so erhalten wir als neues Tableau

	$\dots$	b_s	$\dots$	k_j	$\dots$	
$\vdots$		$\vdots$		$\vdots$		$\vdots$
b_r	$\dots$	$-\frac{\alpha_{ri}}{\alpha_{si}}$	$\dots$	$\alpha_{rj} - \alpha_{ri} \frac{\alpha_{sj}}{\alpha_{si}}$	$\dots$	$\beta_r - \alpha_{ri} \frac{\beta_i}{\alpha_{si}}$
$\vdots$		$\vdots$		$\vdots$		$\vdots$
k_i	$\dots$	$\frac{1}{\alpha_{si}}$	$\dots$	$\frac{\alpha_{sj}}{\alpha_{si}}$	$\dots$	$\frac{\beta_s}{\alpha_{si}}$
$\vdots$		$\vdots$		$\vdots$		$\vdots$
	$\dots$	$-\frac{\gamma_i}{\alpha_{si}}$	$\dots$	$\gamma_j - \gamma_i \frac{\alpha_{sj}}{\alpha_{si}}$	$\dots$	$\delta - \gamma_i \frac{\beta_r}{\alpha_{si}}$

d.h. wir dividieren die s -te Zeile durch α_{si} und eliminieren alle anderen Einträge in der i -ten Spalte durch Zeilenoperationen zu Null. In der i -ten Spalte wenden wir diese Operationen aber auf e_s an. Schließlich tauschen wir in der Beschriftung b_s und k_i . Diese Variante braucht deutlich weniger Speicherplatz.

Beispiel 2.2.7. Wir illustrieren die obige Bemerkung indem wir den Simplexschritt in Beispiel 2.2.4 in der „sparsameren“ Version des Simplextableaus durchführen. Wir

starten also mit dem Tableau

	3	4	5	6	
1	-1	0	$\frac{1}{2}$	$\frac{1}{2}$	1
2	0	-1	$\frac{1}{2}$	$-\frac{1}{2}$	0
7	0	0	0	1	2
8	0	0	1	0	2
	0	0	$-\frac{3}{2}$	$-\frac{1}{2}$	-2

Wir wählen den negativen Eintrag $-\frac{3}{2}$ in der letzten Zeile und wollen $k = 5$ in die neue Basismenge aufnehmen. Wir dividieren nun alle Einträge in der ganz rechten Spalte durch den Eintrag in der gleichen Zeile aus der Spalte, die zu $k = 5$ gehört, sofern dieser Eintrag positiv ist und erhalten 2 (für $j = 1$), 0 (für $j = 2$) und 2 (für $j = 8$). Da wir für $j = 2$ das kleinste Ergebnis erhalten wählen wir $j = 2$ als jenes Element, das wir aus der aktuellen Basis entfernen. Wir dividieren also die zweite Zeile (da $j = 2$ in der zweiten Zeile steht—siehe erste Spalte) durch $\frac{1}{2}$ und eliminieren durch Zeilenoperationen alle anderen Einträge in dieser Spalte. Im Tableau führen wir diese Operationen aber nur in allen anderen Spalten durch und führen in der Spalte, die bisher zu $k = 5$ gehört hat, die selben Operationen mit e_2 durch. Schließlich vertauschen wir in der Beschriftung 2 und 5 und erhalten folgendes Tableau.

	3	4	2	6	
1	-1	1	-1	1	1
5	0	-2	2	-1	0
7	0	0	0	1	2
8	0	2	-2	1	2
	0	-3	3	-2	-2

Dieses Tableau entspricht genau dem in Beispiel 2.2.4 erhaltenen.

2.3 Zusammenfassung und Erfolgsgarantie

Zusammengefasst lässt sich der Simplexschritt also als folgender Algorithmus beschreiben.

Algorithmus 2.3.1 (Simplexschritt). Wir betrachten den Simplexschritt zum linearen Programm

$$\min\{c^\top x : Ax = b, x \geq 0\}$$

mit $A \in \text{Mat}_{m,n}$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Wir setzen $N := \{1, \dots, n\}$

Eingabe: Eine Basismenge B , zu der es eine zulässige Basislösung gibt und ein Simplextableau

$$T = \begin{array}{c|c|c} I_m & A_B^{-1} A_K & A_B^{-1} b \\ \hline 0 & c_K^\top - c_B^\top A_B^{-1} A_K & -c_B^\top A_B^{-1} b \end{array}$$

2 Der Simplexalgorithmus

zur Basis B .

Ausgabe: Eine Basismenge B' , ein zugehöriges Simplextableau T' und die Information, ob die zugehörige Basislösung optimal ist.

Durchführung: Wir setzen $K = N \setminus B$.

- (1) Falls $c_K^\top - c_B^\top A_B^{-1} A_K \geq 0$ ist, *stoppen* wir, setzen $B' = B$, $T' = T$ und geben die Information zurück ein Minimum gefunden zu haben.
- (2) Sonst wählen wir ein $k \in K$ mit $c_k - c_B^\top A_B^{-1} A_{-k} < 0$.
- (3) Ist $(A_B^{-1} A_K)_{jk} \leq 0$ für alle $j \in B$, *stoppen* wir und geben die Information zurück, dass das lineare Programm keine Lösung hat.
- (4) Ansonsten wählen wir ein

$$j \in \operatorname{argmin} \left\{ \frac{x_j}{(A_B^{-1} A_K)_{jk}} : (A_B^{-1} A_K)_{jk} > 0 \right\}$$

und setzen $B' = B \cup \{k\} \setminus \{j\}$. Das Tableau T' erhalten wir aus T , indem wir die zu j gehörige Zeile von T durch $(A_B^{-1} A_K)_{jk}$ dividieren und dann alle anderen Einträge der k -ten Spalte eliminieren.

- (5) Wir geben B' , T' und die Information noch kein Minimum gefunden zu haben zurück.

Der oben beschriebene Algorithmus kann so nicht implementiert werden, da er in (2) und (4) keine klare Anweisung enthält *welches* k bzw. j ausgewählt werden soll, wenn es mehr als eine Möglichkeit gibt. Wir brauchen in diesen Schritten also noch eine Auswahlregel.

Bevor wir uns dieser Frage widmen, wollen wir zuerst die allgemeine Form des Simplexalgorithmus formulieren.

Algorithmus 2.3.2 (Simplexalgorithmus, Phase II (allgemeine Form)). Wir betrachten das lineare Programm

$$\min \{c^\top x : Ax = b, x \geq 0\}$$

mit $A \in \operatorname{Mat}_{m,n}$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Wir setzen $N = \{1, \dots, n\}$.

Eingabe: A , b , c und eine Basismenge B , zu der es eine zulässige Basislösung gibt.

Ausgabe: Ein zulässiger Punkt x , der die Zielfunktion minimiert oder die Information, dass es keine Lösung gibt.

Durchführung:

- (1) Wir bestimmen A_B^{-1} und setzen

$$\tilde{T} = \begin{pmatrix} A_B^{-1} A & A_B^{-1} b \\ c^\top - c_B^\top A_B^{-1} A & 0 \end{pmatrix}.$$

- (2) Wie führen einen Simplexschritt durch, indem wir Algorithmus 2.3.1 auf T und B anwenden und erhalten ein Tableau T' und B' .
- (3) Haben wir aus Algorithmus 2.3.1 die Information erhalten, dass das lineare Programm keine Lösung besitzt, *stoppen* und geben diese Information zurück.
- (4) Haben wir aus Algorithmus 2.3.1 die Information erhalten ein Minimum gefunden zu haben, setzen wir $x_{B'} = A_{B'}^{-1}b$, d.h. wir setzen (bis auf den letzten Eintrag) alle Einträge der letzten Spalte von T' an die entsprechende Stelle. Genauer gesagt, für $k \in \{1, \dots, m\}$ sehen nach in welcher Spalte j von T der k -te Standardbasisvektor steht und setzen dann $x_j := t_{kn}$. Die restlichen Komponenten von x setzen wir auf 0. Wir *stoppen* und geben x zurück.
- (5) Ansonsten ersetzen wir B durch B' und T durch T' und gehen zurück zu Schritt (2).

Als direkte Folgerung der Sätze 2.2.2 und 2.2.3 erhalten wir das folgende Ergebnis.

Satz 2.3.3. *Wenn der Algorithmus 2.3.2 in (3) terminiert besitzt das lineare Programm keine Lösung. Wenn er in (4) terminiert, haben wir ein Minimum gefunden.*

Um zu zeigen, dass der Simplexalgorithmus funktioniert, müssen wir also nur zeigen, dass er terminiert. Da ein Polyeder nur endlich viele Ecken besitzt ist dies jedenfalls sichergestellt, wenn wir sicherstellen könnten, dass in jedem Simplexschritt die Ecke gewechselt wird und wir nicht später zu dieser Ecke zurückkehren können. Während wir die Rückkehr zu einer bereits verlassenen Ecke tatsächlich ausschließen können, siehe Aufgabe (2.3), haben wir in Beispiel 2.2.4 gesehen, dass es passieren kann, dass sich die Basislösung durch den Wechsel zu einer benachbarten Basis nicht ändert. Bevor wir eine Lösung dieses Problems betrachten, wollen wir zuerst das Beispiel aus dem vorigen Abschnitt weiter betrachten.

Beispiel 2.3.4. Wir setzen Beispiel 2.2.4 fort. Wir haben also das Tableau

$$\begin{array}{cccccccc|c}
 1 & -1 & -1 & 1 & 0 & 1 & 0 & 0 & 1 \\
 0 & 2 & 0 & -2 & 1 & -1 & 0 & 0 & 0 \\
 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 2 \\
 0 & -2 & 0 & 2 & 0 & 1 & 0 & 1 & 2 \\
 \hline
 0 & 3 & 0 & -3 & 0 & -2 & 0 & 0 & -2
 \end{array}$$

zur Basis $B = \{1, 5, 7, 8\}$. Wir wählen nun $k = 4$, da der Eintrag in der vierten Spalte der letzten Zeile -3 ist. Dann können wir $j = 1$ oder $j = 8$ wählen, da der entsprechende Quotient in beiden Fällen Eins ist. Wir wählen $j = 1$ und erhalten das Tableau

$$\begin{array}{cccccccc|c}
 1 & -1 & -1 & 1 & 0 & 1 & 0 & 0 & 1 \\
 2 & 0 & -2 & 0 & 1 & 1 & 0 & 0 & 2 \\
 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 2 \\
 -2 & 0 & 2 & 0 & 0 & -1 & 0 & 1 & 0 \\
 \hline
 3 & 0 & -3 & 0 & 0 & 1 & 0 & 0 & 1
 \end{array}$$

2 Der Simplexalgorithmus

zur Basis $B = \{4, 5, 7, 8\}$. Hier ergibt sich $k = 3$ und $j = 8$ und damit das Tableau

$$\begin{array}{cccccccc|c} 0 & -1 & 0 & 1 & 0 & \frac{1}{2} & 0 & \frac{1}{2} & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 2 \\ -1 & 0 & 1 & 0 & 0 & -\frac{1}{2} & 0 & \frac{1}{2} & 0 \\ \hline 0 & 0 & 0 & 0 & 0 & -\frac{1}{2} & 0 & \frac{3}{2} & 1 \end{array}$$

zur Basis $B = \{3, 4, 5, 6\}$. Hier müssen wir $k = 6$ wählen und können dann sowohl $j = 4$ oder $j = 7$ wählen, da in beiden Fällen der entsprechende Quotient 2 ist. Wir wählen $j = 4$ und erhalten das Tableau

$$\begin{array}{cccccccc|c} 0 & -2 & 0 & 2 & 0 & 1 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 2 \\ 0 & 2 & 0 & -2 & 0 & 0 & 1 & -1 & 0 \\ -1 & -1 & 1 & 1 & 0 & 0 & 0 & 1 & 1 \\ \hline 0 & -1 & 0 & 1 & 0 & 0 & 0 & 2 & 2 \end{array}$$

zur Basis $B = \{3, 5, 6, 7\}$. Es ergibt sich $k = 2$ und $j = 7$ und somit das neue Tableau

$$\begin{array}{cccccccc|c} 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 2 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 2 \\ 0 & 1 & 0 & -1 & 0 & 0 & \frac{1}{2} & -\frac{1}{2} & 0 \\ -1 & 0 & 1 & 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} & 1 \\ \hline 0 & 0 & 0 & 0 & 0 & 0 & \frac{1}{2} & \frac{3}{2} & 2 \end{array}$$

zur Basis $B = \{2, 3, 5, 6\}$. Da alle Einträge in der letzten Zeile nicht-negativ sind, haben wir ein Minimum gefunden. Die entsprechende Basislösung ist

$$x = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 2 \\ 2 \\ 0 \\ 0 \end{pmatrix}$$

Wenn wir die Transformation aus Beispiel 1.3.2 wieder rückgängig machen bekommen wir

$$x = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$$

und -2 als Wert der Zielfunktion in diesem Punkt.

Definition 2.3.5 (Regel von R. G. Bland). Die Auswahlregel

(2) Wähle

$$k = \min \left\{ l \in K : c_l - c_B^T A_B^{-1} A_{-l} < 0 \right\}.$$

(4) Wähle

$$j = \min \operatorname{argmin} \left\{ \frac{x_j}{(A_B^{-1} A_K)_{jk}} : (A_B^{-1} A_K)_{jk} > 0 \right\}.$$

im Simplexschritt (Algorithmus 2.3.1) nennt man *Regel von R. G. Bland*.

Damit können wir nur beweisen, dass der Simplexalgorithmus funktioniert.

Satz 2.3.6. *Der Simplexalgorithmus (Algorithmus 2.3.2) mit der Auswahlregel von R. G. Bland stoppt nach endlich vielen Schritten in (3) oder (4).*

Beweis. Wir bezeichnen mit B_i die Basismenge, die im i -ten ausgewählt wurde, mit $x^{(i)}$ die zugehörige zulässige Basislösung und mit K_i die zugehörige Nichtbasismenge. Wir beweisen die Aussage indirekt und nehmen an, es gäbe $p < q$ mit $B_q = B_p$. Nach Aufgabe (2.3) gilt also $x^{(i)} = x^{(p)}$ für alle $p \leq i \leq q$. Wir betrachten die Menge

$$D = \left(\bigcup_{i=p}^q B_i \right) \cap \left(\bigcup_{i=p}^q K_i \right) \subset N$$

der Indizes, die in manchen dieser Basismengen, aber nicht in allen vorhanden sind. Da $x^{(p)}$ eine zulässige Basislösung für alle $B_p, \dots, B_q$ ist, muss $x_D^{(p)} = 0$ sein, da die Elemente von D für manche i in der Nichtbasismenge K_i enthalten sind. Wir setzen $r = \max D$. Da $B_p = B_q$ und r nicht in allen B_i enthalten ist, können wir $p \leq s, t \leq q$ mit $r \in B_s$, $r \notin B_{s+1}$, $r \notin B_t$ und $r \in B_{t+1}$ wählen. Sei $u \in N$ mit $B_{s+1} = (B_s \setminus \{r\}) \cup \{u\}$, d.h. der Index gegen den r im Schritt $s+1$ getauscht wurde. Aus $u \in K_s \cap B_{s+1}$ folgt, dass $u \in D$ und folglich $u < r$ gelten muss. Zur Vereinfachung der Notation setzen wir

$$\bar{A} = A_{B_s}^{-1} A, \quad \bar{b} = A_{B_s}^{-1} b \quad \text{und} \quad \bar{c}^T = c^T - c_{B_s}^T \bar{A}$$

sowie

$$\tilde{A} = A_{B_t}^{-1} A, \quad \tilde{b} = A_{B_t}^{-1} b \quad \text{und} \quad \tilde{c}^T = c^T - c_{B_t}^T \tilde{A},$$

d.h. $\bar{A}$, $\bar{b}$ und $\bar{c}^T$ sind die relevanten Daten des Tableaus zur Basis B_s und $\tilde{A}$, $\tilde{b}$ und $\tilde{c}^T$ die zur Basis B_t . Wir definieren nun $v \in \mathbb{R}^n$ für $\alpha \in \mathbb{R}$ durch

$$v_u := \alpha, \quad v_{B_s} := \bar{b} - \bar{A}_{-u} \alpha \quad \text{und} \quad v_{K_s \setminus \{u\}} = 0.$$

und bemerken, dass

$$Av = A_{B_s} v_{B_s} + \alpha A_{-u} = b - \alpha A_{-u} + \alpha A_{-u} = b$$

2 Der Simplexalgorithmus

und folglich auch $\bar{A}v = \bar{b}$ und $\tilde{A}v = \tilde{b}$ gilt. Also ist

$$\tilde{c}^\top v - \bar{c}^\top v = \tilde{c}^\top v - \tilde{c}^\top v + \tilde{c}_{B_s}^\top \tilde{A}_{B_s}^{-1} \tilde{A}v = \tilde{c}_{B_s}^\top \tilde{A}_{B_s}^{-1} \tilde{b} = \tilde{c}_{B_s}^\top \bar{b}$$

nach Aufgabe (2.5), wobei die rechte Seite nicht von α abhängt. Wegen

$$\begin{aligned} \tilde{c}^\top v - \bar{c}^\top v &= (\tilde{c}_{B_s}^\top - \bar{c}_{B_s}^\top) \bar{b} - \alpha((\tilde{c}_{B_s}^\top - \bar{c}_{B_s}^\top + \tilde{c}_{B_s}^\top \tilde{A}_{B_s}^{-1} \tilde{A}_{B_s}) \bar{A}_{-u} + \tilde{c}_u - \bar{c}_u) \\ &= \alpha(-\tilde{c}_{B_s}^\top \bar{A}_{-u} + \tilde{c}_u - \bar{c}_u), \end{aligned}$$

wobei $(\tilde{c}_{B_s}^\top - \bar{c}_{B_s}^\top) \bar{b} = c^\top x^{(s)} - c^\top x^{(t)} = 0$, muss daher

$$\sum_{j \in B_s} \tilde{c}_j \bar{A}_{ju} - \tilde{c}_u + \bar{c}_u = \tilde{c}_{B_s}^\top \bar{A}_{-u} - \tilde{c}_u + \bar{c}_u = 0$$

sein. Da u im $(s+1)$ -ten Schritt aufgenommen wird, muss $\bar{c}_u < 0$ sein. Da $u < r$ ist und r (aber nicht u) im t -ten Schritt aufgenommen wird, muss $\tilde{c}_u \geq 0$ sein. Also gibt es ein $j \in B_s$ mit $\tilde{c}_j \bar{A}_{ju} > 0$. Insbesondere ist $\tilde{c}_j \neq 0$, folglich $j \in B_s \cap K_t \subset D$ und daher $j \leq r$. Es ist $\bar{A}_{ru} > 0$ und $\tilde{c}_r < 0$, da im $(s+1)$ -ten Schritt r gegen u getauscht wird und r im $(t+1)$ -ten Schritt aufgenommen wird. Also muss $j < r$ und $\tilde{c}_j > 0$ sein, da sonst im $(t+1)$ -ten Schritt nach der Bland'schen Regel j statt r aufgenommen werden würde. Also ist $\bar{A}_{ju} > 0$ und $\bar{b}_j = 0$, da $j \in D$ und folglich hätte im $(s+t)$ -ten Schritt j statt r gegen u getauscht werden müssen, was im Widerspruch zu unserer Annahme steht, dass wir die Auswahlregel von R. G. Bland verwendet haben. $\square$

Bemerkung 2.3.7. Während diese Auswahlregel einfach und interessant aus theoretischer Sicht ist, zeigt sich in praktischen Anwendungen sowohl, dass Rundungsfehler dazu führen, dass der Simplexalgorithmus auch bei anderen Auswahlregeln nicht zyklisch wird und dass die Regel nach R. G. Bland, im Vergleich zu anderen, zu vielen Schritten führt und damit ineffizient ist.

Die ursprüngliche Auswahlregel von G. Dantzig war im wesentlichen

(2) Wähle

$$k = \min \operatorname{argmin} \left\{ c_l - c_B^\top A_B^{-1} A_{-l} < 0 : l \in K \right\}.$$

(4) Wähle

$$j = \min \operatorname{argmin} \left\{ \frac{x_j}{(A_B^{-1} A_K)_{jk}} : (A_B^{-1} A_K)_{jk} > 0 \right\}.$$

Es gibt heute eine Reihe von Auswahlregeln, die sich als im Regelfall schneller erwiesen haben.

2.4 Bestimmung einer zulässigen Basislösung

Wir betrachten das lineare Programm

$$\min\{c^T x : Ax = b, x \geq 0\}$$

mit $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Um den Simplexalgorithmus starten zu können brauchen wir eine Basismenge $B \subset N$, zu der es eine zulässige Basislösung gibt. Wir wollen nun ein Hilfsprogramm betrachten, das uns ermöglicht den Simplexalgorithmus zu verwenden, um eine solche Basismenge zu bestimmen. Wir betrachten das Hilfsprogramm

$$\min\{\mathbb{1}^T z : Ax + z = b, x, z \geq 0\}$$

und können, durch Multiplikation der entsprechenden Zeilen von A und b mit -1 falls nötig, annehmen, dass alle Einträge von b nicht-negativ sind. Wir setzen

$$\tilde{A} = (A \quad I_m), \quad \tilde{N} = \{1, \dots, n+m\} \quad \text{und} \quad B = \{n+1, \dots, n+m\}.$$

Dann ist $\tilde{A}_B = I_m$ und $\tilde{A}_B^{-1}b \geq 0$, d.h. zu B gibt es eine zulässige Basislösung. Weiters besitzt das lineare Programm immer eine Lösung, da die Zielfunktion durch Null nach unten beschränkt ist.

Satz 2.4.1. *Das lineare Programm*

$$\min\{c^T x : Ax = b, x \geq 0\} \tag{LP}$$

besitzt genau dann eine zulässige Basislösung wenn

$$\min\{\mathbb{1}^T z : Ax + z = b, x, z \geq 0\} = 0 \tag{LPH}$$

ist.

Beweis. Angenommen (LP) besitzt eine zulässige Basislösung $x \in \mathbb{R}^n$. Dann ist $x \geq 0$ und $Ax = b$ und folglich erfüllt $z = 0$ sowohl $Ax + z = b$ als auch $x, z \geq 0$, d.h. die Zielfunktion von (LPH) nimmt das Minimum Null in $(x, 0)$ an.

Nimmt umgekehrt die Zielfunktion von (LPH) ihr Minimum in (x, z) mit $z = 0$ an, so ist x eine zulässige Basislösung von (LP), da $Ax = Ax + 0 = b$ und $x \geq 0$ ist. $\square$

Wir können also zu einem gegebenen linearen Programm immer das zugehörige Hilfsprogramm betrachten und mittels Simplexalgorithmus entscheiden, ob das ursprüngliche lineare Programm eine zulässige Basislösung besitzt und gegebenenfalls eine solche berechnen. Um dann mit dem Simplexalgorithmus das ursprüngliche Programm zu lösen, wollen wir direkt aus dem Tableau des Hilfsprogramms ein Starttableau für das ursprüngliche Programm bestimmen. Wir gehen dabei folgendermaßen vor.

2 Der Simplexalgorithmus

Angenommen wir haben $(x, 0)$ als Lösung des Hilfsprogramms erhalten und die zugehörige Basismenge sei $\tilde{B} \subset \tilde{N}$. Wir haben also mit dem Tableau

$$\tilde{T} = \begin{pmatrix} \tilde{A}_{\tilde{B}}^{-1} \tilde{A} & \tilde{A}_{\tilde{B}}^{-1} b \\ \tilde{c}^T - \tilde{c}_{\tilde{B}}^T \tilde{A}_{\tilde{B}}^{-1} \tilde{A}_{\tilde{K}} & -\tilde{c}_{\tilde{B}}^T \tilde{A}_{\tilde{B}}^{-1} b \end{pmatrix}$$

mit $\tilde{c}^T = (\mathbb{1}^T, 0)$ geendet. Ist $\tilde{B} \cap \{n+1, \dots, n+m\} = \emptyset$, so können wir $B = \tilde{B}$ setzen durch Elimination der zu B gehörigen Einträge der letzten Zeile von

$$\begin{pmatrix} \tilde{A}_{\tilde{B}}^{-1} \tilde{A}_N & \tilde{A}_{\tilde{B}}^{-1} b \\ c^T & 0 \end{pmatrix}$$

ein Starttableau für den Simplexalgorithmus für das ursprüngliche lineare Programm erhalten. Ist $\tilde{B} \cap \{n+1, \dots, n+m\} \neq \emptyset$, gibt es mehrere Basismengen zur Basislösung $(x, 0)$ und folglich müssen manche Einträge von x Null sein. Wir gehen nun für $j \in \tilde{B} \cap \{n+1, \dots, n+m\}$ folgendermaßen vor. Wir nehmen dabei an, dass $\tilde{T}_{-j} = e_k$ ist.

- (1) Ist $\tilde{T}_{ik} = 0$ für alle $i \in N$, so bezieht sich die k -te Zeile von $\tilde{T}$ nur auf Variablen, die im Hilfsprogramm eingeführt wurden. Wir lassen also die j -te Spalte und die k -te Zeile von $\tilde{T}$ weg.
- (2) Gibt es ein $\tilde{T}_{ik} \neq 0$ mit $i \in N$, so muss der k -te Eintrag der letzten Spalte von $\tilde{T}$ Null sein. Wir führen dann einen Simplexschritt (Algorithmus 2.3.1) so durch, dass er i und j vertauscht. Dabei ändert sich die zulässige Basislösung nicht und wir können die j -te Spalte weglassen.

Durch die obigen Schritte erhalten wir also immer (bis auf die letzte Zeile, die wir durch Elimination getrennt erreichen) ein Starttableau für den Simplexalgorithmus für das ursprüngliche lineare Programm.

Beispiel 2.4.2. Wir wollen ein Beispiel betrachten, bei dem die Ausgangsmatrix nicht vollen Rang hat. Gegeben sei das lineare Programm

$$\min\{c^T x : Ax = b, x \geq 0\}$$

mit

$$A = \begin{pmatrix} 1 & 1 & 1 \\ -1 & 2 & 3 \\ 0 & 3 & 4 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 1 \\ 2 \end{pmatrix} \quad \text{und} \quad c = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}.$$

Als Starttableau des Hilfsprogramms erhalten wir

$$\begin{array}{cccccc|c} 1 & 1 & 1 & 1 & 0 & 0 & 1 \\ -1 & 2 & 3 & 0 & 1 & 0 & 1 \\ 0 & 3 & 4 & 0 & 0 & 1 & 2 \\ \hline 0 & -6 & -8 & 0 & 0 & 0 & -4 \end{array}$$

und nach Durchführung des Simplexalgorithmus

$$\begin{array}{cccccc|c} 1 & 0 & -\frac{1}{3} & \frac{2}{3} & -\frac{1}{3} & 0 & \frac{1}{3} \\ 0 & 1 & \frac{4}{3} & \frac{1}{3} & \frac{1}{3} & 0 & \frac{2}{3} \\ 0 & 0 & 0 & -1 & -1 & 1 & 0 \\ \hline 0 & 0 & 0 & 2 & 2 & 0 & 0 \end{array}$$

zur Basis $\{1, 2, 6\}$. Da sich die dritte Zeile nur auf „Hilfsvariablen“ bezieht, d.h. die Einträge in den ersten drei Spalten sind Null, können wir sie einfach weglassen. Damit erhalten wir als Starttableau für die Phase II das Tableau

$$\begin{array}{ccc|c} 1 & 0 & -\frac{1}{3} & \frac{1}{3} \\ 0 & 1 & \frac{4}{3} & \frac{2}{3} \\ \hline 0 & 0 & -\frac{4}{3} & -\frac{5}{3} \end{array}$$

Durch einen Simplexschritt bringen wir dieses auf

$$\begin{array}{ccc|c} 1 & \frac{1}{4} & 0 & \frac{1}{2} \\ 0 & \frac{3}{4} & 1 & \frac{1}{2} \\ \hline 0 & 1 & 0 & -1 \end{array}$$

und erhalten damit als Lösung $x^T = (\frac{1}{2}, 0, \frac{1}{2})$.

2.5 Literatur und Ausblick

Der Beweis von Satz 2.3.6 basiert auf dem von Satz 21 in [11]. Die Auswahlregeln von R. G. Bland wurde in der Arbeit [2] untersucht und dort wurde gezeigt, dass der Simplexalgorithmus damit immer terminiert.

2.6 Aufgaben

- (2.1) **SIMPLEXSCHRITT (BEINAHE) VON HAND DURCHFÜHREN:** Wir betrachten das lineare Programm, das durch

$$A = \begin{pmatrix} -1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 1 & 0 & 0 \\ 1 & 1 & -1 & -1 & 0 & 0 & 1 & 0 \\ 1 & -1 & -1 & 1 & 0 & 0 & 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 3 \\ 1 \end{pmatrix} \quad \text{und} \quad c = \begin{pmatrix} 1 \\ 1 \\ -1 \\ -1 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

gegeben ist. Starten Sie mit der Basismenge $B = \{5, 6, 7, 8\}$ und führen Sie so lange den Simplexschritt durch, bis Sie ein Minimum gefunden haben.

Anleitung: Die einzelnen Berechnungen müssen nicht von Hand durchgeführt werden. Bitte verwenden Sie aber keine Implementierung des Simplexschritts, sondern führen Sie den Schritt „manuell“ durch.

2 Der Simplexalgorithmus

- (2.2) ℓ_1 - UND ℓ_∞ -MINIMIERUNG ALS LINEARES PROGRAMM: Wir betrachten $A \in \text{Mat}_{m,n}(\mathbb{R})$ und $b \in \mathbb{R}^m$. Finden Sie für die folgenden Minimierungsprobleme jeweils ein äquivalentes lineares Programm, d.h. finden Sie jeweils ein lineares Programm aus dessen Lösung man eine Lösung des entsprechenden Minimierungsproblems bekommt.

- a) $\min \|x\|_1$ unter $Ax = b$
- b) $\min \|Ax - b\|_1$
- c) $\min \|Ax - b\|_\infty$

Geben Sie auch an, wie man aus der Lösung des linearen Programms eine Lösung des Minimierungsproblems erhält.

- (2.3) RUNDREISEN IM SIMPLEXALGORITHMUS: Wir untersuchen, wie es passieren kann, dass der Simplexalgorithmus zyklisch wird.

- a) Wir nehmen an, dass der Simplexschritt die Basismenge B durch die Basismenge B' ersetzt hat. Zeigen Sie, dass wenn der Schritt nochmal ausgeführt wird, das Ergebnis nicht B' sein kann.
- b) Angenommen wir haben in k Schritten die Basismengen $B_1, \dots, B_k$ bekommen und es gelte $B_1 = B_k$. Zeigen Sie, dass die zugehörigen zulässigen Basislösungen $x_1, \dots, x_k$ alle gleich sein müssen.

- (2.4) SIMPLEXSCHRITT IMPLEMENTIEREN: Schreiben Sie eine Funktion, die als Eingabe eine Matrix $T \in \text{Mat}_{m+1,n+1}$ und eine Menge B akzeptiert und folgendes damit macht: Die Matrix T soll ein Simplextableau zur Basismenge B sein. Die Funktion führt einen Simplexschritt durch und gibt folgende Ausgabe:

- Die Information, ob ein Minimum gefunden wurde
- Eine neue Basismenge B'
- Ein zugehöriges Simplextableau T'

Sollte im Simplexschritt festgestellt werden, dass die Zielfunktion auf dem zulässigen Bereich nach unten unbeschränkt ist, sollte die Funktion (z.B. durch ein Exception oder eine Fehlermeldung) abgebrochen werden.

Testen Sie die Funktion an dem Beispiel aus der Vorlesung und an dem Beispiel aus Aufgabe (2.1).

- (2.5) DIREKTE UMRECHNUNG ZWISCHEN ZWEI BASEN: Wir betrachten das lineare Programm

$$\min\{c^T x : Ax = b, x \geq 0\}$$

mit $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Weiters sei $N = \{1, \dots, n\}$ und $B, B' \subset N$ zwei Basismengen mit $K = N \setminus B$ und $K' = N \setminus B'$. Wir betrachten die Simplextableaus

$$\left[\begin{array}{c|c} \bar{A} & \bar{b} \\ \hline \bar{c}^T & -v_B \end{array} \right] \quad \text{und} \quad \left[\begin{array}{c|c} \tilde{A} & \tilde{b} \\ \hline \tilde{c}^T & -v_{B'} \end{array} \right]$$

zu den Basismengen B und B' , d.h. $\bar{A} = A_B^{-1}A$, $\bar{b} = A_B^{-1}b$, $\bar{c}^\top = c^\top - c_B^\top A_B^{-1}A$, $-v_B = c_B^\top A_B^{-1}b$ und analog für $\tilde{A}$, $\tilde{b}$, $\tilde{c}^\top$ und $v_{B'}$.

- Argumentieren Sie, dass die obige Darstellung von $\bar{c}$ (bzw. von $\tilde{c}$) mit der in der Vorlesung beschriebenen Darstellung der letzten Zeile des Simplextableaus übereinstimmt.
- Zeigen Sie, dass $\tilde{A} = (A_B^{-1}A_{B'})^{-1}\bar{A} = \bar{A}_{B'}^{-1}\bar{A}$ gilt.
- Zeigen Sie, dass $\tilde{c}^\top = \bar{c}^\top - \bar{c}_B^\top \tilde{A}_B^{-1}\tilde{A}$ gilt.

(2.6) ZYKLISCHER SIMPLEXALGORITHMUS: Wir betrachten das lineare Programm

$$\min\{c^\top x : Ax = b\}$$

mit

$$A = \begin{pmatrix} \frac{1}{3} & -2 & -\frac{2}{3} & -\frac{1}{3} & 1 & 0 \\ 0 & 2 & 1 & \frac{6}{13} & 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \text{und} \quad c = \begin{pmatrix} -\frac{3}{4} \\ 4 \\ 1 \\ \frac{5}{13} \end{pmatrix}.$$

- Überprüfen Sie, dass der Simplexalgorithmus für dieses Beispiel mit der *G. Dantzig*-Auswahlregel

$$(2) \quad k = \min \operatorname{argmin} \left\{ c_l - c_B^\top A_B^{-1} A_{-l} < 0 : l \in K \right\}.$$

$$(4) \quad j = \min \operatorname{argmin} \left\{ \frac{x_j}{(A_B^{-1} A_K)_{jk}} : (A_B^{-1} A_K)_{jk} > 0 \right\}.$$

zyklisch wird.

- Falls Sie das Simplexverfahren implementiert haben: adaptieren Sie es so, dass Sie die Dantzig-Auswahlregel verwenden können und testen Sie, ob dies auch zyklisch wird. Falls dies nicht passiert, vergleichen Sie die Lösung mit der Lösung zur Bland-Auswahlregel.

(2.7) SPARSAMERES SIMPLEXVERFAHREN VON HAND DURCHFÜHREN: Wir betrachten das lineare Programm, das durch

$$A = \begin{pmatrix} 2 & 2 & 0 & 0 & -2 & 1 & 0 & 0 \\ 2 & 1 & -2 & 2 & 2 & 0 & 1 & 0 \\ 2 & 3 & 3 & -2 & 1 & 0 & 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \quad \text{und} \quad c = \begin{pmatrix} -1 \\ 3 \\ -3 \\ 2 \\ -2 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

gegeben ist. Starten Sie mit der Basismenge $B = \{5, 6, 7, 8\}$ und führen Sie so lange sparsamere Simplexverfahren aus Bemerkung 2.2.6 durch, bis Sie ein

2 Der Simplexalgorithmus

Minimum gefunden haben.

Anleitung: Die einzelnen Berechnungen müssen nicht von Hand durchgeführt werden. Bitte verwenden Sie aber keine Implementierung des Simplexschritts, sondern führen Sie den Schritt „manuell“ durch.

- (2.8) SPARSAMERES SIMPLEXVERFAHREN IMPLEMENTIEREN: Schreiben Sie eine Funktion, die als Eingabe eine Matrix $T \in \text{Mat}_{m+1,m+1}(\mathbb{R})$ und zwei Listen B und K akzeptiert und folgendes damit macht: Die Matrix T soll ein Simplextableau zur Basismenge B sein. Die Funktion führt einen Simplexschritt (wie in Bemerkung 2.2.6) durch und gibt folgende Ausgabe:

- Die Information, ob ein Minimum gefunden wurde
- Eine neue Basismenge B' und eine neue Nichtbasismenge K'
- Ein zugehöriges Simplextableau T'

Sollte im Simplexschritt festgestellt werden, dass die Zielfunktion auf dem zulässigen Bereich nach unten unbeschränkt ist, sollte die Funktion (z.B. durch ein Exception oder eine Fehlermeldung) abgebrochen werden.

Testen Sie die Funktion an dem Beispiel aus der Vorlesung und an dem Beispiel aus Aufgabe (3) des aktuellen Übungsblatts und Aufgabe (2) des letzten Übungsblatts.

- (2.9) SIMPLEXALGORITHMUS KOMPLETT DURCHFÜHREN: Finden Sie eine Lösung des linearen Programms

$$\min\{c^\top x : Ax = b, x \geq 0\}$$

mit

$$A = \begin{pmatrix} 1 & 2 & 1 & 0 & -1 \\ -1 & 3 & 0 & 1 & 2 \\ -2 & 1 & 3 & 0 & 2 \end{pmatrix}, \quad b = \begin{pmatrix} 2 \\ 6 \\ 6 \end{pmatrix} \quad \text{und} \quad c = \begin{pmatrix} 1 \\ 2 \\ 1 \\ -1 \\ 3 \end{pmatrix}.$$

3 Konvexe Funktionen und deren Minima

3.1 Konvexe Funktionen

In Analysis 2 haben Sie gesehen, dass eine stetig differenzierbare Funktion

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

eine lokale Extremstelle in $\xi \in \mathbb{R}^n$ hat wenn $\nabla f(\xi) = 0$ und dass man ein unter bestimmten Voraussetzungen lokales Minimum finden kann, indem man von einem Startpunkt $x_0 \in \mathbb{R}^n$ iterativ mittels $x_{n+1} = x_n - \nabla f(x_n)$ sich immer in Richtung des steilsten Abstiegs bewegt. Wir sind oft an globalen Minima interessiert und wollen nicht nur lokale Minima finden. Wir betrachten nun eine Klasse von Funktionen, bei denen lokale Minima bereits globale Minima sind.

Definition 3.1.1. Es sei $\Omega \subset \mathbb{R}^n$ eine konvexe Menge. Eine Funktion $f: \Omega \rightarrow \mathbb{R}$ ist konvex, falls

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

für alle $x, y \in \Omega$ und alle $\lambda \in [0, 1]$.

Beispiel 3.1.2. Wir betrachten ein paar Beispiele konvexer Funktionen auf $\mathbb{R}^n$.

1. Die Funktion $\mathbb{R} \rightarrow \mathbb{R}$, $x \mapsto x^4$ ist konvex.
2. Die Norm

$$\mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto \|x\|$$

ist eine konvexe Funktion, da wegen der Dreiecksungleichung der absoluten Homogenität

$$\|(1 - t)x + ty\| \leq (1 - t)\|x\| + t\|y\| \quad \text{für alle } x, y \in \mathbb{R}^n \text{ und } t \in [0, 1]$$

gilt. Sie erfüllt sogar die stärkere Bedingung

$$\|(1 - t)x + ty\| < (1 - t)\|x\| + t\|y\| \quad \text{für alle } t \in (0, 1), \quad (3.1)$$

falls $x \neq y$ und $\|x\| = \|y\|$ (Übung).

3. Es sei $A \in \text{Mat}_{n,n}(\mathbb{R})$ eine symmetrische positive definite Matrix. Dann ist die quadratische Form

$$\mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto x^T A x$$

eine konvexe Funktion (Übung).

3 Konvexe Funktionen und deren Minima

Satz 3.1.3. Es sei $\Omega \subset \mathbb{R}^n$ offen und konvex. Jede konvexe Funktion $f: \Omega \rightarrow \mathbb{R}$ ist stetig.

Beweis. Zu $z \in \Omega$, gibt es ein $\sigma > 0$ so dass der Würfel

$$W = \text{Konv}(\{z + \sigma w: w \in \mathbb{R}^n, w_k \in \{\pm 1\}, k = 1, \dots, n\})$$

in Ω enthalten ist, da Ω offen ist. Wir bezeichnen mit $\{v_1, \dots, v_{2^n}\}$ die Menge der obigen Punkte $x + \sigma w$, d.h. die Menge der Eckpunkte des Würfels und setzen

$$C := \max\{f(v_i) - f(z): i = 1, \dots, 2^n\}.$$

Zu $x \in \Omega$ mit $\|x - z\| \leq \sigma$ liegt auch der Punkt

$$u = z + \sigma \frac{x - z}{\|x - z\|}$$

im Würfel W , da $\overline{B(z, \sigma)} \subset W$. Damit ist

$$\begin{aligned} f(x) - f(z) &\leq \left(1 - \frac{\|x - z\|}{\sigma}\right) f(z) + \frac{\|x - z\|}{\sigma} f(u) - f(z) \\ &= \frac{\|x - z\|}{\sigma} (f(u) - f(z)) \leq \frac{\|x - z\|}{\sigma} \sum_{i=1}^{2^n} \lambda_i (f(v_i) - f(z)) \leq C \frac{\|x - z\|}{\sigma} \end{aligned}$$

für geeignete $\lambda_i \geq 0$ mit $\sum_{i=1}^{2^n} \lambda_i = 1$. Es ist

$$z = \frac{\|z - x\|}{\sigma + \|z - x\|} (z - (u - z)) + \frac{\sigma}{\sigma + \|z - x\|} u$$

und $z - (u - z) \in W$. Damit erhalten wir analog zu oben, dass

$$\frac{\sigma}{\sigma + \|z - x\|} (f(z) - f(u)) \leq \frac{\|z - x\|}{\sigma + \|z - x\|} C$$

gilt. Also ist

$$|f(x) - f(z)| \leq \frac{\|z - x\|}{\sigma} C$$

für alle $x \in \overline{B(z, \sigma)}$. Zu $\varepsilon > 0$ wählen wir also $\delta = \min\{\sigma, \frac{\varepsilon \sigma}{C}\}$ und erhalten

$$|f(x) - f(z)| < \frac{\varepsilon \sigma}{C} \frac{C}{\sigma} = \varepsilon$$

für alle $x \in B(z, \delta)$, also ist f stetig in z . □

Definition 3.1.4. Es sei $\Omega \subset \mathbb{R}^n$ eine konvexe Menge und $f: \Omega \rightarrow \mathbb{R}$ eine Funktion. Die Menge

$$\text{epi } f = \left\{ \begin{pmatrix} x \\ \lambda \end{pmatrix} \in \Omega \times \mathbb{R}: f(x) \leq \lambda \right\}$$

heißt *Epigraph von f* .

Satz 3.1.5. *Es sei $\Omega \subset \mathbb{R}^n$ eine konvexe Menge. Eine Funktion $f: \Omega \rightarrow \mathbb{R}$ ist genau dann konvex wenn $\text{epi } f$ eine konvexe Menge ist.*

Beweis. Siehe Aufgabe (3.1) □

Definition 3.1.6. Es sei $C \subset \mathbb{R}^n$ eine konvexe Menge und $z \in \partial C$. Eine Hyperebene

$$\{x \in \mathbb{R}^n: \langle x, v \rangle = a\}$$

mit $v \in \mathbb{R}^n$ und $a \in \mathbb{R}$ heißt *Stützhyperebene an C in z* , falls $\langle z, v \rangle = a$ und $\langle x, v \rangle \leq a$ für alle $x \in C$ gilt.

Der folgende Satz zeigt, dass es zu jeder konvexe Menge in jedem Randpunkt eine Stützhyperebene gibt.

Satz 3.1.7. *Es sei $C \subset \mathbb{R}^n$ eine konvexe Menge und $z \in \partial C$. Dann gibt es ein $v \in \mathbb{R}^n$ und ein $a \in \mathbb{R}$ mit $\langle z, v \rangle = a$ und $\langle x, v \rangle \leq a$ für alle $x \in C$.*

Beweis. Wir betrachten eine Folge $(x_n)_{n \in \mathbb{N}}$ von Elementen außerhalb des Abschlusses von C , die gegen $z \in \partial C$ konvergiert. Nach Satz 1.3.3 erhalten wir eine Folge von Elementen $v_n \in \mathbb{R}^n$ mit $\langle x, v_n \rangle \leq \langle x_n, v_n \rangle$ für alle $x \in C$. Wir nehmen o.E.d.A an, dass $\|v_n\| = 1$ ist und können nach dem Satz von Heine-Borel eine Teilfolge $(v_{n_k})_{k \in \mathbb{N}}$ auswählen, die gegen ein $v \in \mathbb{R}^n$ konvergiert. Für diesen Grenzwert gilt

$$\langle x, v \rangle = \lim_{k \rightarrow \infty} \langle x, v_{n_k} \rangle \leq \lim_{k \rightarrow \infty} \langle x_{n_k}, v_{n_k} \rangle = \langle z, v \rangle$$

für alle $x \in C$. □

Definition 3.1.8. Es sei $\Omega \subset \mathbb{R}^n$ eine konvexe Menge, $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion und $\xi \in \Omega$. Ein Vektor $g \in \mathbb{R}^n$ heißt *Subgradient von f bei ξ* , falls

$$f(x) \geq f(\xi) + \langle g, x - \xi \rangle$$

für alle $x \in \Omega$ gilt. Die Menge

$$\partial f(\xi) = \{g \in \mathbb{R}^n: g \text{ Subgradient von } f \text{ bei } \xi\}$$

nennt man *Subdifferential von f bei ξ* .

Satz 3.1.9. *Es sei $\Omega \subset \mathbb{R}^n$ eine konvexe Menge und $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion. Dann besitzt f in jedem Punkt $\xi \in \Omega^\circ$, d.h. in jedem Punkt im Inneren von Ω , einen Subgradienten.*

Beweis. Nach Satz 3.1.5 ist die Menge

$$\text{epi } f = \left\{ \begin{pmatrix} x \\ \lambda \end{pmatrix} \in \Omega \times \mathbb{R}: f(x) \leq \lambda \right\} \subset \mathbb{R}^{n+1}$$

eine konvexe Menge. Wir zeigen nun, dass $(\xi, f(\xi)) \in \partial \text{epi } f$ für $\xi \in \Omega^\circ$. Sei U eine offene Umgebung von $(\xi, f(\xi))$ in $\mathbb{R}^{n+1}$. Also gibt es eine offene Menge $V \subset \Omega$ und

3 Konvexe Funktionen und deren Minima

ein $r > 0$ mit $V \times (f(\xi) - r, f(\xi) + r) \subset U$. Da $f|_{\Omega^\circ}$ nach Satz 3.1.3 stetig ist, gibt es eine offene Umgebung $W \subset V$ von ξ mit $f(W) \subset (f(\xi) - \frac{r}{2}, f(\xi) + \frac{r}{2})$. Also ist der Punkt $(\xi, f(\xi) - \frac{r}{4}) \in U$ ein Element von $\mathbb{R}^{n+1} \setminus \text{epi } f$ und, da U beliebig war, enthält jede Umgebung von $(\xi, f(\xi)) \in \text{epi } f$ ein Element des Komplements des Epigraphs, d.h. $(\xi, f(\xi)) \in \partial \text{epi } f$. Nach Satz 3.1.7 besitzt $\text{epi } f$ eine Stützhyperebene in $(\xi, f(\xi))$, d.h. ein $(v, c) \in \mathbb{R}^{n+1}$ mit

$$\langle v, x \rangle + c\lambda \leq \langle v, \xi \rangle + cf(\xi)$$

für alle $x \in \Omega$ und alle $\lambda \geq f(x)$. Wir müssen nun zeigen, dass $c < 0$ sein muss. Als erstes bemerken wir, dass $c \neq 0$ ist, da sonst v ein Stützhyperebene an Ω in ξ definieren würde, was nicht sein kann, da ξ ein innerer Punkt ist. Wäre $c > 0$, so erhalten wir für $x = \xi$ nach Division durch c die widersprüchliche Ungleichung $\lambda \leq f(\xi)$ für alle $\lambda \geq f(\xi)$. Also ist $c < 0$. Wir setzen $g := -\frac{1}{c}v$ und erhalten mittels Division durch c für $\lambda = f(x)$ aus der obigen Ungleichung

$$f(x) \geq f(\xi) + \langle g, x - \xi \rangle,$$

d.h. g ist ein Subgradient von f bei ξ . □

Satz 3.1.10. *Es sei $\Omega \subset \mathbb{R}^n$ eine offene konvexe Menge und $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion. Dann ist f in $\xi \in \Omega$ genau dann differenzierbar, wenn f in ξ einen eindeutigen Subgradienten besitzt. In diesem Fall ist $\partial f(\xi) = \{\nabla f(\xi)\}$.*

Beweis. Siehe Aufgabe (3.4). □

Satz 3.1.11. *Es sei $C \subset \mathbb{R}^n$ eine abgeschlossene konvexe Menge und $x \notin C$. Dann gibt es einen eindeutigen Punkt $P_C x$ in C mit minimalem Abstand zu x . Dieser ist durch $y \in C$ und*

$$\langle x - y, z - y \rangle \leq 0 \quad \text{für alle } z \in C \tag{3.2}$$

charakterisiert.

Beweis. Da $y \mapsto \|x - y\|$ stetig und die Menge $C \cap \{y \in \mathbb{R}^n: \|x - y\| \leq 2d(x, C)\}$ kompakt ist, gibt es mindestens ein $y \in C$ mit $\|x - y\| = d(x, C)$. Wegen (3.1) ist das Minimum eindeutig, da für $y_1, y_2 \in C$ mit $\|x - y_1\| = \|x - y_2\| = d(x, C)$ und $y_1 \neq y_2$ auch deren Mittelpunkt $\frac{1}{2}(y_1 + y_2)$ in C liegt und dort gelten müsste

$$\left\| x - \frac{1}{2}(y_1 + y_2) \right\| = \left\| \frac{1}{2}(x - y_1) + \frac{1}{2}(x - y_2) \right\| < \frac{1}{2}(\|x - y_1\| + \|x - y_2\|) = d(x, C),$$

was im Widerspruch zur Definition von $d(x, C)$ steht. Wir zeigen nun, dass (3.2) den Punkt mit minimalem Abstand charakterisiert. Angenommen (3.2) gilt, dann ist

$$\|z - x\|^2 = \|z - y + y - x\|^2 = \|z - y\|^2 + 2\langle z - y, y - x \rangle + \|y - x\|^2 \geq \|y - x\|^2,$$

d.h. $\|z - x\| \geq \|y - x\|$ für alle $z \in C$. d.h. y minimiert den Abstand. Umgekehrt nehmen wir an, dass $y \in C$ den Abstand zu x minimiert. Zu $z \in C$ und $\lambda \in (0, 1)$ setzen wir $z_\lambda := (1 - \lambda)y + \lambda z$ und bemerken, dass

$$\begin{aligned}\|x - y\|^2 &\leq \|x - z_\lambda\|^2 = \|x - y - \lambda(z - y)\|^2 \\ &= \|x - y\|^2 - 2\lambda\langle x - y, z - y \rangle + \lambda^2\|z - y\|^2\end{aligned}$$

was für $\lambda \rightarrow 0$ die benötigte Ungleichung liefert. $\square$

3.2 Optimalitätsbedingungen

Satz 3.2.1. *Es sei $\Omega \subset \mathbb{R}^n$ eine offene konvexe Menge, $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion und $\xi \in \Omega$ ein lokales Minimum von f . Dann ist ξ ein globales Minimum von f .*

Beweis. Wir nehmen an wir hätten einen Punkt $\xi' \in \Omega$ mit $f(\xi') < f(\xi)$. Da ξ ein lokales Minimum ist, gibt es ein $\varepsilon > 0$ so, dass $f(\xi) \leq f(x)$ für alle $x \in \Omega$ mit $\|x - \xi\| < \varepsilon$ ist. Wir wählen nun ein $\lambda \in (0, 1)$ mit $\|\lambda\xi + (1 - \lambda)\xi' - \xi\| < \varepsilon$ und bemerken, dass

$$f(\lambda\xi + (1 - \lambda)\xi') \leq \lambda f(\xi) + (1 - \lambda)f(\xi') < f(\xi)$$

woraus folgt, dass ξ kein lokales Minimum ist. $\square$

Satz 3.2.2. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine stetig differenzierbare konvexe Funktion. Ein Punkt $\xi \in \mathbb{R}^n$ ist genau dann ein globales Minimum von f wenn $\nabla f(\xi) = 0$ ist.*

Beweis. Dass für eine stetig differenzierbare Funktion der Gradient in einem lokalen Minimum verschwindet ist aus Analysis 2 bekannt. Da f auf ganz $\mathbb{R}^n$ definiert ist, ist das globale Minimum auch ein lokales Minimum.

Wir nehmen nun also an, dass $\nabla f(\xi) = 0$ ist. Da f stetig differenzierbar ist, gilt

$$\begin{aligned}\langle \nabla f(\xi), x - \xi \rangle &= \lim_{h \rightarrow 0^+} \frac{f(\xi + h(x - \xi)) - f(\xi)}{h} \\ &\leq \lim_{h \rightarrow 0^+} \frac{(1 - h)f(\xi) + hf(x) - f(\xi)}{h} = f(x) - f(\xi),\end{aligned}$$

d.h.

$$f(x) \geq f(\xi) + \langle \nabla f(\xi), x - \xi \rangle.$$

für alle $x \in \mathbb{R}^n$. Ist nun $\nabla f(\xi) = 0$, so folgt $f(x) \geq f(\xi)$ für alle $x \in \mathbb{R}^n$, d.h. ξ ist ein globales Minimum von f . $\square$

Satz 3.2.3. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine konvexe Funktion. Ein Punkt $\xi \in \mathbb{R}^n$ ist genau dann ein globales Minimum von f , wenn $0 \in \partial f(\xi)$ ist.*

Beweis. Siehe Aufgabe (3.6). $\square$

3 Konvexe Funktionen und deren Minima

Wir betrachten nun das Problem

$$\begin{aligned} \min \quad & f(x) \\ & g_i(x) \leq 0, \quad 1 \leq i \leq p \\ & Ax = b \end{aligned} \tag{3.3}$$

mit differenzierbaren konvexen Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$, $1 \leq i \leq p$, sowie $A \in \text{Mat}_{m,n}(\mathbb{R})$ und $b \in \mathbb{R}^m$.

Wir nehmen im Folgenden an, dass das Problem (3.3) die *Slater-Bedingung* erfüllt, d.h. dass es einen Punkt $\xi \in \mathbb{R}^n$ mit $g_i(\xi) < 0$ für $1 \leq i \leq p$ und $A\xi = b$ gibt. Weiters nehmen wir an, dass die in (3.3) vorkommenden Funktionen stetig differenzierbar sind.

Definition 3.2.4. Ein Punkt $(x^*, \mu^*, \lambda^*) \in \mathbb{R}^{n+p+m}$ heißt *Karush-Kuhn-Tucker-Punkt* oder kurz *KKT-Punkt* für (3.3), falls die Bedingungen

$$\begin{aligned} \nabla f(x^*) + \sum_{i=1}^p \mu_i^* \nabla g_i(x^*) + \sum_{j=1}^m \lambda_j^* A_{j-}^\top &= 0 \\ g_i(x^*) &\leq 0 \\ Ax^* &= b \\ \mu_i^* &\geq 0 \\ \mu_i^* g_i(x^*) &= 0 \end{aligned}$$

erfüllt sind.

Satz 3.2.5 (Karush-Kuhn-Tucker). *Es seien $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$ stetig differenzierbare konvexe Funktionen. Ein Punkt $x^* \in \mathbb{R}^n$ ist genau dann eine Lösung des Optimierungsproblems (3.3), wenn es $(\mu^*, \lambda^*) \in \mathbb{R}^{p+m}$ so gibt, dass (x^*, μ^*, λ^*) ein KKT-Punkt für (3.3) ist.*

Beweis. Angenommen (x^*, μ^*, λ^*) sei ein KKT-Punkt für (3.3). Für $x \in \mathbb{R}^n$ mit $g_i(x) \leq 0$ und $Ax = b$ erhalten wir aus den KKT-Bedingungen und Satz 3.1.10, dass

$$\begin{aligned} f(x) - f(x^*) &\geq \nabla f(x^*)^\top (x - x^*) \\ &= - \sum_{i=1}^p \mu_i^* \nabla g_i(x^*)^\top (x - x^*) - \sum_{j=1}^m \lambda_j^* A_{j-}^\top (x - x^*) \\ &\geq \sum_{i=1}^p \mu_i^* (g_i(x^*) - g_i(x)) = - \sum_{i=1}^p \mu_i^* g_i(x) \\ &\geq 0, \end{aligned}$$

d.h. $f(x) \geq f(x^*)$ für alle zulässigen Punkte. Daher ist x^* eine Lösung des Optimierungsproblems (3.3).

Sei nun umgekehrt $x^* \in \mathbb{R}^n$ eine Optimallösung von (3.3). Wir betrachten die Menge

$$C := \{a \in \mathbb{R}^{m+p+1} : \exists x \in \mathbb{R}^n \text{ mit } a_0 > f(x) - f(x^*), a_i \geq g_i(x) \text{ für } 1 \leq i \leq p \\ \text{und } a_{j+p} = A_{j-}x - b_j \text{ für } 1 \leq j \leq m\}$$

und stellen fest, dass es sich dabei um eine nichtleere konvexe Menge handelt, da f und alle g_i konvex sind. Da x^* ein Lösung von (3.3) ist, gilt $f(x) - f(x^*) \geq 0$ für alle zulässigen Punkte und daher kann es keinen Punkt $x \in \mathbb{R}^n$ mit $g_i(x) \leq 0$, $Ax - b = 0$ und $f(x) - f(x^*) < 0$ geben. Dies bedeutet gerade, dass $0 \notin C$. Wir können daher Satz 1.3.3 verwenden, um ein $y \in \mathbb{R}^{m+p+1} \setminus \{0\}$ zu bekommen für das $y^\top z \geq 0$ für alle $z \in C$ gilt. Insbesondere gilt also

$$0 \leq y_0(f(x) - f(x^*)) + \sum_{i=1}^p y_i g_i(x) + \sum_{j=1}^m y_{j+p}(A_{j-}x - b_j) \quad (3.4)$$

für alle $x \in \mathbb{R}^n$, da $(f(x) - f(x^*), g_1(x), \dots, g_p(x), A_{1-}x - b_1, \dots, A_{m-}x - b_m) \in \overline{C}$. Da für $(a_0, a_1, \dots, a_{m+p}) \in C$ und $i \leq p$ auch jedes $(a_0, \dots, a_{i-1}, a'_i, a_{i+1}, \dots, a_{m+p})$ mit $a'_i \geq a_i$ in C enthalten ist, folgt aus der Trennungsungleichung, dass $y_i \geq 0$ für $0 \leq i \leq p$ gelten muss. Daher ist die Funktion

$$h: \mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto y_0(f(x) - f(x^*)) + \sum_{i=1}^p y_i g_i(x) + \sum_{j=1}^m y_{j+p}(A_{j-}x - b_j)$$

konvex und differenzierbar. Da $h(x^*) = 0$ ist, folgt aus (3.4), dass es sich bei x^* um ein globales Minimum von h handelt. Nach Satz 3.2.2 ist daher

$$0 = \nabla h(x^*) = y_0 \nabla f(x^*) + \sum_{i=1}^p y_i \nabla g_i(x^*) + \sum_{j=1}^m y_{j+p} A_{j-}^\top.$$

Da es sich bei x^* um einen zulässigen Punkt handelt, ist auch $g_i(x^*) \leq 0$ und $Ax^* = b$. Wir müssen also nur noch zeigen, dass $y_0 \neq 0$ und $y_i g_i(x^*) = 0$ für $1 \leq i \leq p$. Wir zeigen zuerst die zweite dieser Behauptungen. Angenommen wir hätten ein i mit $y_i g_i(x^*) \neq 0$. Wegen $y_i \geq 0$ und $g_i(x^*) \leq 0$ müsste dann $y_i g_i(x^*) < 0$ und folglich $h(x^*) < 0$ sein. Dies widerspricht aber der obigen Beobachtung, dass $h(x^*) = 0$ ist.

Wir verwenden nun die Slater-Bedingung um zu zeigen, dass $y_0 \neq 0$ ist. Wieder nehmen wir das Gegenteil, d.h. $y_0 = 0$ an. Nach Voraussetzung gibt es also ein $x' \in \mathbb{R}^n$ mit $Ax' = b$ und $g_i(x') < 0$ für $1 \leq i \leq p$. Nach Satz 3.1.10 gilt

$$0 > \sum_{i=1}^p y_i g_i(x') \geq \sum_{i=1}^p y_i g_i(x^*) + \sum_{i=1}^p y_i \nabla g_i(x^*)(x' - x^*) = 0,$$

ein Widerspruch. Folglich muss $y_0 \neq 0$ gelten und wir setzen $\mu_i^* = y_i/y_0$ für $1 \leq i \leq p$ und $\lambda_j^* = y_{j+p}/y_0$ für $1 \leq j \leq m$, um den geforderten KKT-Punkt (x^*, μ^*, λ^*) zu erhalten. $\square$

3 Konvexe Funktionen und deren Minima

Bemerkung 3.2.6. Man kann in (3.3) auch allgemeinere Bedingungen stellen. Beispielsweise kann man das Problem

$$\begin{aligned} \min \quad & f(x) \\ & g_i(x) \leq 0, \quad 1 \leq i \leq p \\ & h_j(x) = 0, \quad 1 \leq j \leq q \end{aligned}$$

für stetig differenzierbare Funktionen g_i und h_j betrachten. Auch die KKT-Bedingungen lassen sich für diesen allgemeineren Fall formulieren, aber die Slater-Bedingung ist hier nicht mehr geeignet, um zu erreichen, dass jeder KKT-Punkt eine Lösung des Minimierungsproblems ist. Will man erreichen, dass im obigen Problem der zulässige Bereich eine konvexe Menge ist, so landet man wieder genau bei (3.3).

Zum Abschluss betrachten wir noch Optimalitätsbedingungen, die keine Differenzierbarkeit voraussetzen. Wir betrachten dazu wieder das Minimierungsproblem

$$\begin{aligned} \min \quad & f(x) \\ & g_i(x) \leq 0, \quad 1 \leq i \leq p \\ & Ax = b \end{aligned} \tag{3.5}$$

mit konvexen, nicht notwendigerweise differenzierbaren, Funktionen $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$ sowie $A \in \text{Mat}_{m,n}(R)$ und $b \in \mathbb{R}^m$.

Definition 3.2.7. Zu den Daten aus (3.5) setzen wir

$$D := \{y \in \mathbb{R}^{p+m} : y_i \geq 0 \text{ für } i = 1, \dots, p\}.$$

Die Funktion

$$L: \mathbb{R}^n \times D \rightarrow \mathbb{R}, \quad (x, y) \mapsto f(x) + \sum_{i=1}^p y_i g_i(x) + \sum_{j=1}^{j+p} y_j (A_{i-j}x - b_i)$$

nennt man *Lagrange-Funktion des Problems* (3.5). Ein Punkt $(x^*, y^*) \in \mathbb{R}^n \times D$ heißt *Sattelpunkt von L*, falls

$$L(x, y^*) \geq L(x^*, y^*) \geq L(x^*, y)$$

für alle $x \in \mathbb{R}^n$ und alle $y \in D$ gilt.

Satz 3.2.8. Es sei $(x^*, y^*) \in \mathbb{R}^n \times D$ ein Sattelpunkt der Lagrange-Funktion L von (3.5). Dann ist x^* eine Lösung von (3.5) und es gilt $L(x^*, y^*) = f(x^*)$. Ist umgekehrt $x^* \in \mathbb{R}^n$ eine Lösung von (3.5) und das System erfüllt die Slater-Bedingung, so gibt es ein $y^* \in D$ so, dass (x^*, y^*) ein Sattelpunkt der Lagrange-Funktion ist.

Beweis. Es sei $(x^*, y^*) \in \mathbb{R}^n \times D$ ein Sattelpunkt der Lagrange-Funktion von (3.5). Folglich gilt

$$L(x^*, y^*) \geq L(x^*, y) = f(x^*) + \sum_{i=1}^p y_i g_i(x^*) + \sum_{j=1}^m y_{p+j} (A_j x^* - b_j)$$

für alle $y \in D$. Da die linke Seite der Ungleichung fix ist und damit die rechte Seite nach oben beschränkt ist, muss $g_i(x^*) \leq 0$ für $i = 1, \dots, p$ und $Ax^* - b = 0$ gelten. Also ist x^* ein zulässiger Punkt. Angenommen es wäre $y_i^* > 0$ und $g_i(x^*) < 0$ für ein $i \in \{1, \dots, p\}$, so wäre $L(x^*, y^*) < L(x^*, y)$ für $y \in \mathbb{R}^{p+m}$ mit $y_i = 0$ und $y_k = y_k^*$ für $k \neq i$. Dies steht aber im Widerspruch dazu, dass (x^*, y^*) ein Sattelpunkt der Lagrange-Funktion ist. Also ist $y_i^* g_i(x^*) = 0$ für $i = 1, \dots, p$ und folglich,

$$f(x^*) = L(x^*, y^*) \leq L(x, y^*) = f(x) + \sum_{i=1}^p y_i^* g_i(x) \leq f(x)$$

für alle zulässigen Punkte $x \in \mathbb{R}^n$. Also ist x^* eine Lösung von (3.5).

Für den Beweis der umgekehrten Implikation, sei $x^* \in \mathbb{R}^n$ eine Lösung von (3.5). Den Punkt $y^* \in D$ erhalten wir analog zum Beweis von Satz 3.2.5, siehe Aufgabe (3.11). $\square$

3.3 Literatur und Ausblick

Zur Vorbereitung dieses Abschnitts wurden neben [7] und [6] die Bücher [1] und [9] verwendet. Insbesondere basiert der Beweis von Satz 3.2.5 auf der Darstellung in [1] und [9]. Als eine detaillierte Darstellung der konvexen Analysis, die eine der wesentlichen Grundlagen für die konvexe Optimierung bildet, sei noch [12] erwähnt.

Ein Lehrbuch, in dem sowohl lineare als auch nichtlineare Optimierung und die dazu verwendete konvexe Analysis detailliert behandelt wird, ist das Buch [7].

3.4 Aufgaben

(3.1) KONVEXITÄT VON FUNKTIONEN UND DES EPIGRAPHS: Es sei $\Omega \subset \mathbb{R}^n$ eine konvexe Menge und $f: \Omega \rightarrow \mathbb{R}$ eine Funktion.

- Zeigen Sie, dass f genau dann konvex ist, wenn ihr Epigraph eine konvexe Menge ist.
- Zeigen Sie, dass $\text{epi } f$ genau dann abgeschlossen (in $\Omega \times \mathbb{R}$) ist, wenn f untenhalbstetig ist, d.h. wenn

$$f(x) \leq \liminf_{y \rightarrow x} f(y)$$

für alle $x \in \Omega$ gilt.

3 Konvexe Funktionen und deren Minima

(3.2) KONVEXE FUNKTIONEN:

- a) Zeigen Sie, dass die euklidische Norm die Eigenschaft hat, dass

$$\|\lambda x + (1 - \lambda)y\| < \lambda\|x\| + (1 - \lambda)\|y\|$$

für $x \neq y$ mit $\|x\| = \|y\|$ und $\lambda \in (0, 1)$ gilt.

- b) Geben Sie ein Beispiel einer Norm auf $\mathbb{R}^n$, die die Eigenschaft aus (a) nicht hat.
- c) Es sei $A \in \text{Mat}_{n,n}(\mathbb{R})$. Zeigen Sie, dass

$$\mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto x^\top A x$$

konvex ist.

- d) Zeigen Sie, dass

$$f: [0, 1] \rightarrow \mathbb{R}, \quad x \mapsto -\sqrt{x}$$

eine konvexe Funktion ist. Besitzt f im Nullpunkt einen Subgradienten?

(3.3) KONVEXE FUNKTIONEN UND RICHTUNGSABLEITUNG: Es sei $\Omega \subset \mathbb{R}^n$ eine offene konvexe Menge und $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion. Wir zeigen, dass f in allen Punkten von Ω einseitige Richtungsableitungen besitzt. Sei dazu $x \in \Omega$ und $u \in \mathbb{R}^n$ mit $\|u\| = 1$.

- a) Sei $\varepsilon > 0$ klein genug, dass $x \pm \varepsilon u \in \Omega$. Zeigen Sie, dass die Funktion

$$(-\varepsilon, \varepsilon) \setminus \{0\} \rightarrow \mathbb{R}, \quad t \mapsto \frac{f(x + tu) - f(x)}{t}$$

monoton wachsend und beschränkt ist.

- b) Schließen Sie aus (a), dass die Grenzwerte

$$\lim_{t \searrow 0} \frac{f(x + tu) - f(x)}{t} \quad \text{und} \quad \lim_{t \nearrow 0} \frac{f(x + tu) - f(x)}{t}$$

existieren.

(3.4) MEHR ZUM SUBDIFFERENTIAL: Es sei $\Omega \subset \mathbb{R}^n$ eine offene konvexe Menge, $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion und $\xi \in \Omega$.

- a) Zeigen Sie, dass $\partial f(\xi)$ eine konvexe Menge ist.
- b) Zeigen Sie, dass wenn f in ξ differenzierbar ist $\partial f(\xi)$ genau ein Element besitzt.
- c) Bestimmen Sie das Subdifferential der Funktion $\mathbb{R} \rightarrow \mathbb{R}, x \mapsto |x|$.

(3.5) CHARAKTERISIERUNG KONVEXER FUNKTIONEN: Es sei $\Omega \subset \mathbb{R}^n$ eine konvexe offene Menge und $f: \Omega \rightarrow \mathbb{R}$.

- a) Zeigen Sie, dass f genau dann konvex ist, wenn es in jedem Punkt einen Subgradienten besitzt.
- b) Sei f stetig differenzierbar. Zeigen Sie, dass f genau dann konvex ist, falls für alle $x, \xi \in \Omega$ die Ungleichung

$$f(x) \geq f(\xi) + \langle \nabla f(\xi), x - \xi \rangle$$

gilt.

- (3.6) GLOBALES MINIMUM UND SUBGRADIENT: Es sei $\Omega \subset \mathbb{R}^n$ eine konvexe offene Menge und $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion.

- a) Zeigen Sie, dass $\xi \in \Omega$ genau dann ein globales Minimum von f ist, wenn Null ein Subgradient in ξ , d.h. $0 \in \partial f(\xi)$ ist.
- b)

- (3.7) SUBGRADIENTEN UND RICHTUNGSABLEITUNG: Es sei $\Omega \subset \mathbb{R}^n$ eine offene konvexe Menge, $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion und $\xi \in \Omega$. Für $u \in \mathbb{R}^n \setminus \{0\}$ betrachten wir die *einseitige Richtungsableitung*

$$\partial_u^+ f(\xi) = \lim_{t \searrow 0} \frac{f(\xi + tu) - f(\xi)}{t},$$

die nach Aufgabe 2 von Blatt 6 existiert.

- a) Zeigen Sie, dass die einseitige Richtungsableitung positiv homogen ist. In anderen Worten, zeigen Sie, dass $\partial_{\alpha u}^+ f(\xi) = \alpha \partial_u^+ f(\xi)$ für alle $\alpha > 0$ gilt.
- b) Zeigen Sie, dass die einseitige Richtungsableitung subadditiv (in u) ist, d.h. dass für alle $u, v \in \mathbb{R}^n \setminus \{0\}$ die Ungleichung $\partial_{u+v}^+ f(\xi) \leq \partial_u^+ f(\xi) + \partial_v^+ f(\xi)$ gilt.
- c) Zeigen Sie, dass $\partial_u^+ f(\xi) \geq \sup\{\langle d, u \rangle : d \in \partial f(\xi)\}$ gilt.
- d) Zeigen Sie auch die umgekehrte Ungleichung $\partial_u^+ f(\xi) \leq \sup\{\langle d, u \rangle : d \in \partial f(\xi)\}$.
Hinweis: Zeigen Sie mittels (a), dass jede affine (in u) Minorante von $\partial_u^+ f(\xi)$ linear gewählt werden kann und verwenden Sie dann Aufgabe (2)(c).

Wir haben also gezeigt, dass $\partial_u^+ f(\xi) = \sup\{\langle d, u \rangle : d \in \partial f(\xi)\}$ gilt.

- (3.8) DIFFERENZIERBARKEIT KONVEXER FUNKTIONEN: Es sei $\Omega \subset \mathbb{R}^n$ eine offene konvexe Menge, $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion und $\xi \in \Omega$.

- a) Zeigen Sie, dass f lokal Lipschitz ist.
- b) Zeigen Sie, dass f in ξ genau dann differenzierbar ist, wenn dort alle Richtungsableitungen existieren.
- c) Zeigen Sie, dass f in ξ differenzierbar ist, wenn $\partial f(\xi)$ aus einem Element besteht.

3 Konvexe Funktionen und deren Minima

- (3.9) KKT-BEDINGUNGEN UND LAGRANGE-MULTIPLIKATOR-REGEL: Wir betrachten das Minimierungsproblem

$$\begin{aligned} \min \quad & f(x) \\ & g_i(x) \leq 0, \quad 1 \leq i \leq p \\ & Ax = b \end{aligned}$$

und nehmen an wir hätten einen Minimum x^* gegeben. Wir wollen nun unter bestimmten Voraussetzungen die KKT-Bedingungen aus der Lagrange-Multiplikator-Regel herleiten.

- a) Wir definieren $J := \{j: g_j(x^*) = 0\}$, $k := |J|$, $G(x) = (g_j(x): j \in J)$ und setzen

$$\Omega := \{x \in \mathbb{R}^n: g_j(x) < 0, j \notin J\}.$$

Zeigen Sie, dass es sich bei Ω um eine offene konvexe Menge handelt.

- b) Wir setzen

$$F: \mathbb{R}^n \rightarrow \mathbb{R}^{k+m}, \quad x \mapsto \begin{pmatrix} G(x) \\ Ax - b \end{pmatrix}$$

und nehmen an, dass $\text{Rang } DF(x^*) = n$ ist, wobei $DF(x^*)$ die Jacobimatrix von F in x^* bezeichnet. Verwenden Sie die Lagrange-Multiplikatorregel, um die Existenz eines KKT-Punktes (x^*, μ^*, λ^*) zu zeigen.

- (3.10) OPERATIONEN MIT KONVEXEN FUNKTIONEN: Es sei $\Omega \subset \mathbb{R}^n$ konvex und $f_i: \Omega \rightarrow \mathbb{R}$, $i = 1, \dots, m$, konvexe Funktionen.

- a) Es seien $\lambda_1, \dots, \lambda_m \geq 0$, Zeigen Sie, dass die Funktion

$$\Omega \rightarrow \mathbb{R}, \quad x \mapsto \sum_{i=1}^m \lambda_i f_i(x)$$

konvex ist.

- b) Zeigen Sie, dass die Funktion

$$\Omega \rightarrow \mathbb{R}, \quad x \mapsto \max_{1 \leq i \leq m} f_i(x)$$

konvex ist.

- (3.11) SATTELPUNKT DER LAGRANGE-FUNKTION: Zeigen Sie, dass wenn ein konvexes Minimierungsproblem die Slater-Bedingung erfüllt, es zu jeder Minimallösung $x^* \in \mathbb{R}^n$ ein $y^* \in D$ so gibt, dass (x^*, y^*) ein Sattelpunkt der Lagrangefunktion ist.

- (3.12) DIFFERENZIERBARKEIT REELLER KONVEXER FUNKTIONEN: Wir zeigen, dass konvexe Funktionen fast überall differenzierbar sind.

- a) Es sei $f: \mathbb{R} \rightarrow \mathbb{R}$ konvex und $r, s, t \in \mathbb{R}$ mit $r < s < t$. Zeigen Sie, dass

$$f'_+(r) \leq f'_-(s) \leq f'_+(s) \leq f'_-(t)$$

gilt, wobei $f'_\pm(s)$ die einseitigen Ableitungen von f in s bezeichnen.

- b) Schließen Sie aus (a), dass für eine konvexe Funktion $f: \mathbb{R} \rightarrow \mathbb{R}$ eine abzählbare Menge $S \subset \mathbb{R}$ so gibt, dass f auf $\mathbb{R} \setminus S$ differenzierbar ist.

(3.13) DIFFERENZIERBARKEIT KONVEXER FUNKTIONEN: Es sei $\Omega \subset \mathbb{R}^n$ eine offene konvexe Menge und $f: \Omega \rightarrow \mathbb{R}$ eine konvexe Funktion.

- a) Zeigen Sie, dass f genau dann in $x \in \mathbb{R}^n$ differenzierbar ist, wenn es n -linear unabhängige Richtungen $u_1, \dots, u_n \in \mathbb{S}^{n-1}$ gibt für die Richtungsableitung $\partial_{u_i} f(x)$ existiert.
- b) Zeigen Sie, dass die Funktion

$$\mathbb{R}^{2n} \rightarrow \mathbb{R}, \quad (x, u) \mapsto \partial_u^+ f(x)$$

halbstetig von oben ist, d.h. dass $\limsup_{(x,v) \rightarrow (\xi,u)} \partial_v^+ f(x) \leq \partial_u^+ f(\xi)$ gilt.

- c) Verwenden Sie Aufgabe (2) und den Satz von Fubini-Tonelli, um zu zeigen, dass für fixes $u \in \mathbb{R}^n$ die Menge

$$H_{k,u} := \left\{ x \in \mathbb{R}^n : \partial_u^+ f(x) + \partial_{-u}^+ f(x) \geq \frac{1}{k} \right\}$$

eine abgeschlossene Nullmenge mit leerem Inneren ist.

- d) Schließen Sie aus (a) und (c), dass f außerhalb einer Nullmenge, deren Komplement eine dichte G_δ -Menge ist, differenzierbar ist.

Erinnerung: Eine Menge ist G_δ , falls sie abzählbarer Durchschnitt offener Mengen ist.

4 Nichtlineare Optimierung ohne Nebenbedingungen

In diesem Kapitel betrachten wir eine stetig differenzierbare Funktion

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

und suchen einen Punkt $\xi \in \mathbb{R}^n$, in dem die Funktion f ein (lokales) Minimum annimmt. Ist f zusätzlich konvex, so suchen wir natürlich ein globales Minimum.

Wir starten mit einer kurzen Wiederholung zu Analysis 2. Ein Punkt $\xi \in \mathbb{R}^n$ heißt *stationärer Punkt von f* , falls $\nabla f(\xi) = 0$ ist. Ist f sogar zweimal stetig differenzierbar, so bezeichnen wir mit

$$\mathcal{H}f(\xi) = (\partial_{ij}f(\xi))_{1 \leq i,j \leq n}$$

die *Hessematrix* von f im Punkt ξ . Nach dem Satz von Schwarz ist die Hessematrix eine symmetrische Matrix.

Satz 4.0.1. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine stetig differenzierbare Funktion und $\xi \in \mathbb{R}^n$. Jedes lokale Minimum von f ist ein stationärer Punkt. Ist f zweimal stetig differenzierbar und ξ ein lokales Minimum von f , so ist $\nabla f(\xi) = 0$ und $\mathcal{H}f(\xi)$ positiv semidefinit. Ist f zweimal stetig differenzierbar, $\nabla f(\xi) = 0$ und $\mathcal{H}f(\xi)$ positiv definit, so ist ξ ein lokales Minimum von f .*

Beweis. Siehe Analysis 2. □

Diese Beobachtungen legen nahe, dass man mit der folgenden Methode lokale Minima der Funktion f finden kann.

Algorithmus 4.0.2. Wir betrachten eine stetig differenzierbare Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und suchen ein lokales Minimum von f .

Eingabe: Einen Startpunkt $x_0 \in \mathbb{R}^n$

Ausgabe: Ein stationärer Punkt von f .

Durchführung: Wir setzen $k = 0$.

- (1) Falls $\nabla f(x_k) = 0$, geben wir x_k zurück.
- (2) Anderenfalls wählen wir $\alpha_k > 0$ und setzen

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

- (3) Wir ersetzen k durch $k + 1$ und gehen zurück zu Schritt (1).

Dies ist noch kein konkretes Verfahren, da wir insbesondere nicht festgelegt, wie wir α_k wählen.

4.1 Abstiegsverfahren

Statt direkt in Richtung des steilsten Abstiegs zu gehen, können wir allgemeiner Richtungen wählen, in die die Funktion kleiner wird. Wir wiederholen aus Analysis 2, dass die Richtungsableitung einer stetig differenzierbaren Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ im Punkt $\xi \in \mathbb{R}^n$ in Richtung $v \in \mathbb{S}^{n-1}$ durch

$$\partial_v f(\xi) = \langle \nabla f(\xi), v \rangle$$

gegeben ist. Also nimmt f in alle Richtungen $v \in \mathbb{S}^{n-1}$ ab, für die

$$\langle \nabla f(\xi), v \rangle < 0$$

gilt. Man nennt daher einen Vektor $v \in \mathbb{S}^{n-1}$ *Abstiegsrichtung* von f im Punkt ξ , falls $\langle \nabla f(\xi), v \rangle < 0$ ist.

4.1.1 Gradientenverfahren mit Liniensuche

Wir fixieren $\beta, \gamma \in (0, 1)$ und betrachten das folgende Verfahren.

Algorithmus 4.1.1 (Gradientenverfahren mit Armijo-Liniensuche). Wir betrachten eine stetig differenzierbare Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und suchen ein lokales Minimum von f .

Eingabe: Einen Startpunkt $x_0 \in \mathbb{R}^n$

Ausgabe: Ein stationärer Punkt von f .

Durchführung: Wir setzen $k = 0$.

- (1) Falls $\nabla f(x_k) = 0$, geben wir x_k zurück.
- (2) Anderenfalls setzen wir

$$v_k = -\frac{\nabla f(x_k)}{\|\nabla f(x_k)\|}$$

und wählen das größte $\alpha_k \in \{\beta^m : m \in \mathbb{N}_0\}$ so, dass

$$f(x_k + \alpha_k v_k) - f(x_k) \leq \alpha_k \gamma \langle \nabla f(x_k), v_k \rangle.$$

Damit setzen wir

$$x_{k+1} = x_k + \alpha_k v_k.$$

- (3) Wir ersetzen k durch $k + 1$ und gehen zurück zu Schritt (1).

Als erstes wollen wir zeigen, dass wir immer ein $\alpha_k > 0$ wie im Algorithmus beschrieben wählen können.

Satz 4.1.2. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine stetig differenzierbare Funktion, $\xi \in \mathbb{R}^n$, $v \in \mathbb{S}^{n-1}$ eine Abstiegsrichtung von f im Punkt ξ und $\gamma \in (0, 1)$. Dann gibt es ein $\delta > 0$ so, dass*

$$f(\xi + \alpha v) - f(\xi) \leq \alpha \gamma \langle \nabla f(\xi), v \rangle$$

für alle $\alpha \in [0, \delta]$.

Beweis. Für $\alpha = 0$ ist die Ungleichung erfüllt. Weiters ist

$$\lim_{\alpha \rightarrow 0} \frac{f(\xi + \alpha v) - f(\xi)}{\alpha} = \partial_v f(\xi) = \langle \nabla f(\xi), v \rangle$$

da f stetig differenzierbar ist. Da $\gamma \in (0, 1)$, gibt es also ein $\delta \in (0, 1)$ so, dass

$$\frac{f(\xi + \alpha v) - f(\xi)}{\alpha} < \gamma \langle \nabla f(\xi), v \rangle$$

für alle $\alpha \in (0, \delta]$. Also ist

$$f(\xi + \alpha v) - f(\xi) \leq \alpha \gamma \langle \nabla f(\xi), v \rangle$$

für alle $\alpha \in [0, \delta]$. □

Bemerkung 4.1.3. Wir können also in Schritt (2) in Algorithmus 4.1.1 also das kleinste $m \in \mathbb{N}_0$ wählen, für das

$$f(x_k + \beta^m v_k) - f(x_k) \leq \beta^m \gamma \langle \nabla f(x_k), v_k \rangle$$

gilt und finden immer ein solches m , da $\beta^m \rightarrow 0$ für $m \rightarrow \infty$.

Wir wollen uns nun der Frage widmen, wann dieses Verfahren tatsächlich einen stationären Punkt von f liefert.

Satz 4.1.4. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine nach unten beschränkte stetig differenzierbare Funktion. Algorithmus 4.1.1 stoppt nach endlich vielen Schritten in einem stationären Punkt oder liefert eine Folge $(x_k)_{k \in \mathbb{N}}$ deren Häufungspunkte stationäre Punkte von f sind und für die $f(x_{k+1}) < f(x_k)$ für alle $k \in \mathbb{N}$ gilt.*

Beweis. Falls der Algorithmus nach endlich vielen Schritten stoppt, ist in (1) der Fall $\nabla f(x_k) = 0$ eingetreten. Also ist x_k ein stationärer Punkt von f .

Sei nun anderenfalls $(x_k)_{k \in \mathbb{N}}$ eine unendliche Folge, die von Algorithmus 4.1.1 generiert wurde und x^* ein Häufungspunkt davon. Nach Konstruktion gilt

$$f(x_{k+1}) \leq f(x_k) - \gamma \|\nabla f(x_k)\| < f(x_k)$$

für alle $k \in \mathbb{N}$, da der Algorithmus nicht stoppt und daher $\nabla f(x_k) \neq 0$ ist. Sei nun $(x_{k_j})_{j \in \mathbb{N}}$ eine Teilfolge, die gegen x^* konvergiert. Aus den obigen Ungleichungen folgt

$$\gamma \|\nabla f(x_{k_j})\| \leq f(x_{k_j}) - f(x_{k_{j+1}})$$

für alle $j \in \mathbb{N}$. Da f nach unten beschränkt ist, konvergiert die rechte Seite nach Null, siehe Aufgabe (4.1) und folglich ist

$$\nabla f(x^*) = \lim_{j \rightarrow \infty} \nabla f(x_{k_j}) = 0$$

da f stetig differenzierbar ist. Also ist x^* ein stationärer Punkt von f . □

Bemerkung 4.1.5. Achtung: der Satz besagt nicht, dass die Folge einen Häufungspunkt besitzt, siehe auch Aufgabe (4.2).

Korollar 4.1.6. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine nach unten beschränkte stetig differenzierbare Funktion und $x_0 \in \mathbb{R}^n$ so, dass die Menge $\{x \in \mathbb{R}^n: f(x) \leq f(x_0)\}$ kompakt ist. Dann stoppt Algorithmus 4.1.1 mit x_0 als Startpunkt nach endlich vielen Schritten in einem stationären Punkt von f oder er generiert eine Folge $(x_k)_{k \in \mathbb{N}}$, die mindestens einen Häufungspunkt besitzt und deren Häufungspunkte stationäre Punkte von f sind.*

Beweis. In Anbetracht von Satz 4.1.4 müssen wir nur die Existenz eines Häufungspunkts beweisen. Nach Satz 4.1.4 liegen alle von Algorithmus 4.1.1 besuchten Punkte x_k in der kompakten Menge $\{x \in \mathbb{R}^n: f(x) \leq f(x_0)\}$ und folglich besitzt die Folge nach dem Satz von Bolzano-Weierstraß eine konvergente Teilfolge und damit einen Häufungspunkt. $\square$

4.1.2 Subgradientenverfahren

Als Beispiel einer Abstiegsmethode, die auch für nicht stetig differenzierbare *konvexe* Funktionen funktioniert, betrachten wir das Subgradientenverfahren.

Dazu wählen wir eine Folge positiver reeller Zahlen $(\alpha_k)_{k \in \mathbb{N}}$ mit $\lim_{k \rightarrow \infty} \alpha_k = 0$ und $\sum_{k=1}^{\infty} \alpha_k = \infty$.

Algorithmus 4.1.7 (Subgradientenverfahren). Wir betrachten eine konvexe Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und suchen ein lokales Minimum von f .

Eingabe: Einen Startpunkt $x_0 \in \mathbb{R}^n$

Ausgabe: Ein Minimum von f .

Durchführung: Wir setzen $k = 0$.

(1) Falls $0 \in \partial f(x_k)$, geben wir x_k zurück.

(2) Anderenfalls setzen wir

$$v_k = -\frac{d_k}{\|d_k\|}$$

für ein $d_k \in \partial f(x_k)$. Damit setzen wir

$$x_{k+1} = x_k + \alpha_k v_k.$$

(3) Wir ersetzen k durch $k + 1$ und gehen zurück zu Schritt (1).

Satz 4.1.8. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine konvexe Funktion, die ihr Minimum in einer beschränkten Menge annimmt, d.h. $M_f := \{x \in \mathbb{R}^n: f(x) = \inf\{f(\xi): \xi \in \mathbb{R}^n\}\}$ sei eine beschränkte Menge. Weiters sei $(\alpha_k)_{k \in \mathbb{N}}$ eine reelle Folge mit $\alpha_k > 0$, $\lim_{k \rightarrow \infty} \alpha_k = 0$ und $\sum_{k=1}^{\infty} \alpha_k = \infty$ und $x_0 \in \mathbb{R}^n$. Dann stoppt Algorithmus 4.1.7 entweder nach endlich vielen Schritten in einem Minimum von f oder er liefert eine Folge $(x_k)_{k \in \mathbb{N}}$ mit*

$$\lim_{k \rightarrow \infty} d(x_k, M_f) = 0 \quad \text{und} \quad \lim_{k \rightarrow \infty} f(x_k) = \min\{f(x): x \in \mathbb{R}^n\},$$

d.h. insbesondere besitzt die Folge eine Teilfolge, die gegen ein Minimum von f konvergiert.

Beweis. Es sei $z \in M_f$. Für $x_k \notin M_f$ gilt

$$\|x_{k+1} - z\|^2 = \left\| x_k - z - \alpha_k \frac{d_k}{\|d_k\|} \right\|^2 = \|x_k - z\|^2 + \alpha_k^2 - 2\alpha_k \langle x_k - z, \frac{d_k}{\|d_k\|} \rangle.$$

Wir bezeichnen mit $N_{f(x_k)} = \{x \in \mathbb{R}^n : f(x) = f(x_k)\}$ die Niveaumenge von f zu $f(x_k)$. Die Menge $N_{f(x_k),-} = \{x \in \mathbb{R}^n : f(x) \leq f(x_k)\}$ ist eine konvexe Menge (siehe Aufgabe (4.3)) und $H_k = \{x \in \mathbb{R}^n : \langle d_k, x - x_k \rangle = 0\}$ eine Stützhyperebene an $N_{f(x_k),-}$ im Punkt x_k . Weiters ist, siehe Aufgabe (4.7),

$$d(z, H_k) = -\left\langle z - x_k, \frac{d_k}{\|d_k\|} \right\rangle = \langle x_k - z, \frac{d_k}{\|d_k\|} \rangle,$$

da $\langle d_k, z - x_k \rangle \leq f(z) - f(x_k) < 0$. Da $z \in N_{f(x_k),-}$ und jede Strecke, die z mit einem Punkt in H_k verbindet, $N_{f(x_k)}$ schneidet, gilt also

$$d(z, N_{f(x_k)}) \leq d(z, H_k) = \langle x_k - z, \frac{d_k}{\|d_k\|} \rangle$$

und folglich

$$\|x_{k+1} - z\|^2 \leq \|x_k - z\|^2 + \alpha_k^2 - 2\alpha_k d(z, N_{f(x_k)}). \quad (4.1)$$

Wir setzen $m := \min\{f(x) : x \in \mathbb{R}^n\}$ das Minimum von f und betrachten für $\varepsilon > 0$ die Menge $U_\varepsilon := \partial N_{m+\varepsilon}$, die abgeschlossen ist. Aus Aufgabe (4.3) folgt, dass die Subniveaumenge $N_{m+\varepsilon,-}$ beschränkt und daher U_ε kompakt ist. Wir setzen

$$r(\varepsilon) := \min\{\|x - y\| : x \in U_\varepsilon, y \in M_f\} > 0,$$

da $U_\varepsilon \cap M_f = \emptyset$. Aus $\alpha_k \rightarrow 0$, erhalten wir ein $K_\varepsilon \in \mathbb{N}$ so, dass $\alpha_k < r(\varepsilon)$ für alle $k \geq K_\varepsilon$ ist. Ist $k \geq K_\varepsilon$ und $f(x_k) > m + \varepsilon$, so erhalten wir aus (4.1), dass

$$\|x_k - z\|^2 - \|x_{k+1} - z\|^2 \geq 2\alpha_k d(z, N_{f(x_k)}) - \alpha_k^2 \geq 2\alpha_k r(\varepsilon) - \alpha_k r(\varepsilon) = \alpha_k r(\varepsilon),$$

da $\alpha_k < r(\varepsilon)$ und $d(z, N_{f(x_k)}) \geq d(z, U_\varepsilon) \geq r(\varepsilon)$. Also ist

$$\begin{aligned} r(\varepsilon) \sum_{k=K_\varepsilon}^{K_\varepsilon+j} \alpha_k &\leq \sum_{k=K_\varepsilon}^{K_\varepsilon+j} (\|x_k - z\|^2 - \|x_{k+1} - z\|^2) = \|x_{K_\varepsilon} - z\|^2 - \|x_{K_\varepsilon+j+1} - z\|^2 \\ &\leq \|x_{K_\varepsilon} - z\|^2 \end{aligned}$$

für alle $j \in \mathbb{N}$ für die $f(x_{K_\varepsilon+l}) > m + \varepsilon$ für $l = 1, \dots, j$ ist. Da für $j \rightarrow \infty$ die linke Seite gegen Unendlich strebt, gibt es ein $K_{\varepsilon,2} \geq K_\varepsilon$ mit $f(x_{K_{\varepsilon,2}}) \leq m + \varepsilon$. Wir setzen

$$d(\varepsilon) := \max\{d(x, M_f) : x \in U_\varepsilon\}$$

4 Nichtlineare Optimierung ohne Nebenbedingungen

Ist $f(x_k) \leq m + \varepsilon$, so ist $d(x_k, M_f) \leq d(\varepsilon)$ und $d(x_{k+1}, M_f) \leq d(\varepsilon) + \alpha_k$ mittels Dreiecksungleichung. Ist andererseits $f(x_k) > m + \varepsilon$ und $k \geq K_\varepsilon$, so ist

$$d(x_{k+1}, M_f) \leq d(x_k, M_f)$$

und daher

$$d(x_k, M_f) \leq d(\varepsilon) + \max\{\alpha_k : k \geq K_{\varepsilon,2}\}$$

für $k \geq K_{\varepsilon,2}$. Da $d(\varepsilon) \rightarrow 0$ für $\varepsilon \rightarrow 0$, gibt es zu jedem $\delta > 0$ ein $\varepsilon_\delta > 0$ mit $d(\varepsilon_\delta) < \frac{\delta}{2}$. Weiters gibt es ein $K_\delta \in \mathbb{N}$ so, dass $f(x_{K_\delta}) \leq m + \varepsilon_\delta$ und $\alpha_k < \frac{\delta}{2}$ für $k \geq K_\delta$. Folglich ist

$$d(x_k, M_f) \leq \delta$$

für alle $k \geq K_\delta$, d.h. $d(x_k, M_f) \rightarrow 0$ für $k \rightarrow \infty$. Da f stetig ist, gilt $f(x_k) \rightarrow m$ für $k \rightarrow \infty$. $\square$

Zur Implementierung dieses Verfahrens brauchen wir eine Möglichkeit Subgradienten approximativ zu berechnen. Wir betrachten nun ein Verfahren, dass uns zu gegebenen $x_0 \in \mathbb{R}^n$ und $\varepsilon, \delta > 0$ einen Punkt $x \in B(x_0, \delta)$ und ein $g \in \mathbb{R}^n$ mit $d(g, \partial f(x)) < \varepsilon$ liefert.

Wir starten mit der folgenden Beobachtung: Angenommen wir haben einen Punkt $x \in \mathbb{R}^n$, eine Richtung $u \in \mathbb{S}^{n-1}$, $\tilde{\varepsilon} > 0$ und $h > 0$ mit

$$f(x + hu) + f(x - hu) - 2f(x) < \tilde{\varepsilon}h,$$

dann gibt es aufgrund der Stetigkeit von f für jedes $\tilde{\delta} > 0$ ein $\delta' > 0$ mit

$$f(y + hu) + f(y - hu) - 2f(x) < (\tilde{\varepsilon} + \tilde{\delta})h$$

für alle $y \in B(x, \delta')$.

Wir gehen nun induktiv vor und nehmen an wir haben für ein $k < n$ bereits einen Punkt

$$\bar{x}_k = x_0 + \sum_{i=1}^k c_i e_i \quad \text{mit} \quad \|\bar{x}_k - x_0\| \leq \frac{\delta k}{n}$$

und ein $h_k > 0$ mit

$$f(\bar{x}_k + h_k e_i) + f(\bar{x}_k - h_k e_i) - 2f(\bar{x}_k) \leq \frac{k\varepsilon h_k}{n\sqrt{n}}$$

für $1 \leq i \leq k < n$ konstruiert. Die Funktion

$$\mathbb{R} \rightarrow \mathbb{R}, \quad t \mapsto f(\bar{x}_k + t e_{k+1}) \tag{4.2}$$

ist konvex. Nach Aufgabe (3.13) ist diese Funktion daher fast über differenzierbar. Zu gewähltem $M \in \mathbb{N}$ setzen wir

$$y_m := \bar{x}_k + \frac{\delta m}{Mn} e_{k+1}$$

für $m = -M, \dots, M$. Weiters setzen wir

$$s_m := \frac{Mn}{\delta} (f(y_{m+1}) - f(y_m))$$

für $m = -M, \dots, M-1$ und erhalten eine monoton wachsende Folge, vgl. Aufgaben (3.3) und (3.13). Weiters ist

$$\partial_{e_{k+1}}^+ f \left(\bar{x}_k - \frac{\delta}{n} e_{k+1} \right) \leq s_{-M} \quad \text{und} \quad s_{M-1} \leq \partial_{e_{k+1}}^+ f \left(\bar{x}_k + \frac{\delta}{n} e_{k+1} \right)$$

nach Aufgabe (3.3). Diese Ungleichungen und dass die Funktion in (4.2) fast überall differenzierbar ist, erlaubt es uns M groß genug zu wählen so, dass es ein m mit

$$s_m - s_{m-1} < \frac{(k+1)\varepsilon}{n\sqrt{n}}$$

und

$$\frac{f(y_m + h_k e_i) + f(y_m - h_k e_i) - 2f(y_m)}{h_k} < \frac{(k+1)\varepsilon}{n\sqrt{n}}$$

gibt. Wir setzen

$$h_{k+1} := \min \left\{ h_k, \frac{\delta}{Mn} \right\} \quad \text{und} \quad \bar{x}_{k+1} = y_m$$

und erhalten

$$f(\bar{x}_{k+1} + h_{k+1} e_i) + f(\bar{x}_{k+1} - h_{k+1} e_i) - 2f(\bar{x}_{k+1}) < \frac{(k+1)\varepsilon h_{k+1}}{n\sqrt{n}}$$

und

$$\|\bar{x}_{k+1} - x_0\| \leq \|\bar{x}_k - x_0\| + \frac{\delta}{n} \leq \frac{\delta(k+1)}{n}.$$

Induktiv können wir also $x := \bar{x}_n$ setzen und erhalten ein $h > 0$ für das

$$f(x + h e_i) + f(x - h e_i) - f(x) \leq \frac{\varepsilon h}{\sqrt{n}}$$

für $i = 1, \dots, n$ und

$$\|x - x_0\| \leq \delta$$

gilt. Aus Aufgabe (3.3) wissen wir, dass

$$\frac{f(x) - f(x - h e_i)}{h} \leq \partial_{e_i}^- f(x) \leq \partial_{e_i}^+ f(x) \leq \frac{f(x + h e_i) - f(x)}{h}$$

gilt. Aus Aufgabe (3.7) erhalten wir weiters, dass

$$\partial_{e_i}^+ f(x) = \max\{\langle g, e_i \rangle : g \in \partial f(x)\} \quad \text{und} \quad \partial_{e_i}^- f(x) = \min\{\langle g, e_i \rangle : g \in \partial f(x)\}$$

gilt. Also ist

$$\partial f(x) \subset \prod_{i=1}^n \left[\frac{f(x) - f(x - he_i)}{h}, \frac{f(x + he_i) - f(x)}{h} \right]$$

und

$$g := \left(\frac{f(x + he_1) - f(x - he_1)}{2h}, \dots, \frac{f(x + he_n) - f(x - he_n)}{2h} \right)$$

erfüllt daher

$$\|g - \tilde{g}\| \leq \frac{\varepsilon}{2\sqrt{n}} \sqrt{n} = \frac{\varepsilon}{2}$$

für ein $\tilde{g} \in \partial f(x)$. Damit haben wir zu x_0 , ε und δ die gesuchten x und g gefunden.

4.2 Newton-Verfahren

Die stationäre Punkte von f sind durch die Nullstellen von ∇f gegeben. Ist ∇f stetig differenzierbar, so kann das Newton-Verfahren zur Bestimmung der Nullstellen verwendet werden. Wir wiederholen kurz die Motivation und betrachten die Taylor-Entwicklung von ∇f im Punkt $\xi \in \mathbb{R}^n$ und erhalten

$$\nabla f(x) \approx \nabla f(\xi) + \mathcal{H}f(\xi)(x - \xi),$$

d.h. für $\nabla f(x) = 0$ erhalten wir

$$x \approx \xi - \mathcal{H}f(\xi)^{-1} \nabla f(\xi).$$

Dies legt das folgende Minimierungsverfahren nahe.

Algorithmus 4.2.1 (Newton-Verfahren für Optimierungsprobleme). Wir betrachten eine zweimal stetig differenzierbare Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und suchen ein lokales Minimum von f .

Eingabe: Einen Startpunkt $x_0 \in \mathbb{R}^n$

Ausgabe: Ein stationärer Punkt von f .

Durchführung: Wir setzen $k = 0$.

- (1) Falls $\nabla f(x_k) = 0$, geben wir x_k zurück.
- (2) Anderenfalls berechnen wir $s_k \in \mathbb{R}^n$ durch lösen der Gleichung

$$\mathcal{H}f(x_k)s_k = -\nabla f(x_k)$$

- (3) Wir setzen $x_{k+1} = x_k + s_k$, ersetze k durch $k + 1$ und gehen zu Schritt (1).

Wir zeigen nun, dass wenn wir nahe genug an einem Minimum mit positiv definiter Hessematrix starten, das obige Verfahren auch dorthin konvergiert.

Satz 4.2.2. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine zweimal stetig differenzierbare Funktion und $\xi \in \mathbb{R}^n$ mit $\nabla f(\xi) = 0$ und $\mathcal{H}f(\xi)$ positiv definit. Dann gibt es ein $r > 0$ so, dass für alle $x_0 \in B(\xi, r)$ Algorithmus 4.2.1 durchgeführt werden kann, d.h. die auftretenden Hessematrizen sind invertierbar, und die Folge $(x_k)_{k \in \mathbb{N}}$, die dabei erzeugt wird, hat als Häufungspunkte stationäre Punkte von f .*

Beweis. Die Abbildungen

$$\mathbb{R}^n \rightarrow \text{Mat}_{n,n}(\mathbb{R}), \quad x \mapsto \mathcal{H}f(x) \quad \text{und} \quad \text{Mat}_{n,n}(\mathbb{R}) \rightarrow \mathbb{R}, \quad A \mapsto \det A$$

sind stetig, da f zweimal stetig differenzierbar ist und da Polynome stetig sind. Da $\mathcal{H}f(\xi)$ positiv definit ist, ist $\det \mathcal{H}f(\xi) > 0$. Also gibt es ein $r_1 > 0$ mit $\det \mathcal{H}f(x) > 0$ für alle $x \in B(\xi, r_1)$. Da auch die Abbildung

$$\text{Gl}_n(\mathbb{R}) \rightarrow \text{Gl}_n(\mathbb{R}), \quad A \mapsto A^{-1}$$

stetig ist, gibt es ein $C > 0$ so, dass $\|\mathcal{H}f(x)^{-1}\| \leq C$ für alle $x \in B(\xi, r_1/2)$. Da ∇f (in ξ) differenzierbar ist, gibt es zu jedem $\varepsilon > 0$ ein $r \in (0, r_1/2)$ so, dass

$$\begin{aligned} \|x - \mathcal{H}f(x)^{-1} \nabla f(x) - \xi\| &= \|\mathcal{H}f(x)^{-1} (\mathcal{H}f(x)(x - \xi) + \nabla f(\xi) - \nabla f(x))\| \\ &\leq C \|\nabla f(\xi) - \nabla f(x) - \mathcal{H}f(x)(\xi - x)\| \\ &\leq C\varepsilon \|x - \xi\| \end{aligned}$$

für alle $x \in B(\xi, r)$ mit $\nabla f(x) \neq 0$. Wir wählen $\varepsilon < \frac{1}{C}$ und erhalten damit

$$\|x - \mathcal{H}f(x)^{-1} \nabla f(x) - \xi\| < \|x - \xi\|,$$

d.h. der Newton-Schritt ist wohldefiniert und bildet insbesondere die Kugel $B(\xi, r)$ in sich selber ab. Für $x_0 \in B(\xi, r)$ liegen also alle Elemente der Folge $(x_k)_{k \in \mathbb{N}}$ in der kompakten Kugel $\bar{B}(\xi, \|x_0 - \xi\|)$. Folglich besitzt $(x_k)_{k \in \mathbb{N}}$ konvergente Teilfolgen. Wir zeigen nun, dass jeder Häufungspunkt dieser Folge ein stationärer Punkt von f ist, womit mit Aufgabe (4.1) die behauptete Konvergenz folgt. Sei x^* ein solcher Häufungspunkt, d.h. es gibt eine Teilfolge $(x_{k_j})_{j \in \mathbb{N}}$ mit $x_{k_j} \rightarrow x^*$ für $j \rightarrow \infty$. Aufgrund der Stetigkeit der Newton-Funktion

$$B(\xi, r) \rightarrow B(\xi, r), \quad x \mapsto \mathcal{H}f(x)^{-1} \nabla f(x),$$

siehe oben, gilt

$$x_{k_j+1} \rightarrow x^* - \mathcal{H}f(x^*)^{-1} \nabla f(x^*)$$

für $j \rightarrow \infty$. Auch die Folge $(x_{k_j+1})_{j \in \mathbb{N}}$ besitzt einen Häufungspunkt x' , der nach dem obigen

$$x' = x^* - \mathcal{H}f(x^*)^{-1} \nabla f(x^*)$$

erfüllt. Aus $\|x_{k_j+1} - \xi\| < \|x_{k_j} - \xi\|$ erhalten wir $\|x' - \xi\| \leq \|x^* - \xi\|$ und mit einem analogen Argument $\|x^* - \xi\| \leq \|x' - \xi\|$. Also ist $\|x' - \xi\| = \|x^* - \xi\|$. Also ist $\|x' - \xi\| \leq C_1 \varepsilon \|x^* - \xi\|$, falls $\nabla f(x^*) \neq 0$ ist. Zusammen mit $C_1 \varepsilon < 1$ erlaubt uns dies $\nabla f(x^*) = 0$ zu schließen. $\square$

Korollar 4.2.3. Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine zweimal stetig differenzierbare Funktion und $\xi \in \mathbb{R}^n$ ein isoliertes lokales Minimum von f mit $\nabla f(\xi) = 0$ und $\mathcal{H}f(\xi)$ positiv definit. Dann gibt es ein $r > 0$ so, dass für alle $x_0 \in B(\xi, r)$ Algorithmus 4.2.1 durchgeführt werden kann, d.h. die auftretenden Hessematrizen sind invertierbar, und die Folge $(x_k)_{k \in \mathbb{N}}$, die dabei erzeugt wird, konvergiert gegen ξ .

Bemerkung 4.2.4. Der obige Beweis zeigt, dass es zu einer zweimal stetig differenzierbaren Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und einem Punkt $\xi \in \mathbb{R}^n$ mit $\nabla f(\xi) = 0$ und $\mathcal{H}f(\xi)$ positiv definit, ein $r > 0$ und ein $C \in (0, 1)$ mit

$$\|\xi - x_k\| \leq C \|\xi - x_{k-1}\| \leq \dots \leq C^k \|\xi - x_0\|$$

für den k -ten Newton-Schritt mit Startpunkt $x_0 \in B(\xi, r)$ gibt. In anderen Worten mit jedem Schritt reduziert sich der Abstand zu ξ um den Faktor C . Man nennt diese vergleichsweise schnelle Konvergenz oft *lineare Konvergenz*.

Dieses schnelle Konvergenzverhalten in der Nähe eines lokalen Minimums mit positiv definiten Hessematrix motiviert folgendes Verfahren, bei dem das Gradientenverfahren verwendet wird, um (hoffentlich) in die Nähe eines solchen Minimums zu kommen und dann auf das Newton-Verfahren umsteigt.

Algorithmus 4.2.5 (Hybrid-Algorithmus aus steilstem Abstieg und Newton-Verfahren). Wir betrachten eine zweimal stetig differenzierbare Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und suchen ein lokales Minimum von f .

Eingabe: Einen Startpunkt $x_0 \in \mathbb{R}^n$

Ausgabe: Ein stationärer Punkt von f .

Durchführung: Wir setzen $k = 0$ und wählen $\beta, \gamma \in (0, 1)$.

- (1) Falls $\nabla f(x_k) = 0$ stoppen wir und geben x_k zurück.
- (2) Ist $\mathcal{H}f(x_k)$ invertierbar, so setzen wir

$$s_k = -\mathcal{H}f(x_k)^{-1} \nabla f(x_k).$$

ist $f(x_k + s_k) < f(x_k)$, gehen wir zu (4).

- (3) Wir setzen

$$v_k = -\frac{\nabla f(x_k)}{\|\nabla f(x_k)\|}$$

und wählen das größte $\alpha_k \in \{\beta^m : m \in \mathbb{N}_0\}$ so, dass

$$f(x_k + \alpha_k v_k) - f(x_k) \leq \alpha_k \gamma \langle \nabla f(x_k), v_k \rangle.$$

Damit setzen wir

$$s_k = \alpha_k v_k.$$

- (4) Wir setzen $x_{k+1} = x_k + s_k$, ersetzen k durch $k + 1$ und gehen zu Schritt (1).

Man kann für dieses Hybridverfahren den folgenden Konvergenzsatz beweisen.

Satz 4.2.6. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine zweimal stetig differenzierbare Funktion mit überall regulärer Hessematrix und $x_0 \in \mathbb{R}^n$ so dass $\{x \in \mathbb{R}^n: f(x) \leq f(x_0)\}$ eine kompakte Menge ist. Dann besitzt die Folge $(x_k)_{k \in \mathbb{N}}$, die von Algorithmus 4.2.5 erzeugt wird, mindestens einen Häufungspunkt und jeder Häufungspunkt ist ein stationärer Punkt von f .*

4.3 Literatur und Ausblick

Der Beweis von Satz 4.1.8 ist im wesentlichen der Beweis von Theorem 2.2 in [13, p. 25] und Konstruktion der Approximation an den Subgradienten folgt der Konstruktion am Ende von Abschnitt 1.3 in [13, pp. 14–17].

Der Abschnitt zum Newton-Verfahren ist grob an Teile von Kapitel 17.2 in [3] angelehnt. Satz 4.2.6 ist im wesentlichen Satz 17.5 in [3, p. 298] und wird dort bewiesen.

4.4 Aufgaben

(4.1) WIEDERHOLUNG ZU FOLGEN: Es sei $(a_k)_{k \in \mathbb{N}}$ eine Folge in $\mathbb{R}^n$.

- a) Es sei $n = 1$. Zeigen Sie, dass $\lim_{k \rightarrow \infty} (a_k - a_{k+1}) = 0$, falls $(a_k)_{k \in \mathbb{N}}$ monoton fallend und nach unten beschränkt ist.
- b) Zeigen Sie, dass eine beschränkte Folge $(a_k)_{k \in \mathbb{N}}$ genau dann konvergiert, wenn Sie nur einen Häufungspunkt besitzt.

(4.2) GRADIENTENVERFAHREN MIT LINIENSUCHE: WAS KANN SCHON SCHIEFGEHEN?:

- a) Zeigen Sie, dass

$$f: \mathbb{R} \rightarrow \mathbb{R}, \quad x \mapsto e^x$$

eine nach unten beschränkte konvexe Funktion ist, für die Algorithmus 4.1.1 eine Folge ohne Häufungspunkte erzeugt. Besitzt f stationäre Punkte?

- b) Zeigen Sie, dass

$$f: \mathbb{R} \rightarrow \mathbb{R}, \quad x \mapsto (x-1)x(x+1)$$

stationäre Punkte hat, aber Algorithmus 4.1.1 mit $x_0 = -2$ eine Folge ohne Häufungspunkte erzeugt.

- c) Geben Sie eine konvexe Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ so an, dass für jedes $x_0 \in \mathbb{R}^n$ die Menge

$$\{x \in \mathbb{R}^n: f(x) \leq f(x_0)\}$$

unbeschränkt ist.

4 Nichtlineare Optimierung ohne Nebenbedingungen

(4.3) UNBESCHRÄNKTE KONVEXE MENGEN UND MINIMA KONVEXER FUNKTIONEN: Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine konvexe Funktion.

- a) Zeigen Sie, dass eine abgeschlossene konvexe Menge $C \subset \mathbb{R}^n$ genau dann unbeschränkt ist, wenn sie einen Halbstrahl enthält.
- b) Zeigen Sie, dass Subniveaumengen konvexer Funktionen konvex sind.
- c) Zeigen Sie, dass die Menge

$$M_f = \{x \in \mathbb{R}^n : f(x) = m\}$$

mit $m = \min\{f(x) : x \in \mathbb{R}^n\}$ genau dann beschränkt ist, wenn jede Subniveaumenge von f beschränkt ist.

(4.4) KONVERGENZ IN ENDLICH VIELEN SCHRITTEN: Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine konvexe Funktion für die $m = \min\{f(x) : x \in \mathbb{R}^n\}$ existiert und für die die Menge

$$M_f := \{x \in \mathbb{R}^n : f(x) = m\}$$

eine kompakte Menge mit nicht-leerem Inneren ist. Zeigen Sie, dass das Subgradientenverfahren nach endlich vielen Schritten in einem Punkt von M_f stoppt. *Hinweis:* Es sei $B(z, r) \subset M_f$. Zeigen und verwenden Sie, dass im k -ten Schritt des Verfahrens entweder $x_k \in M_f$ oder der Abstand $d(z, \{x \in \mathbb{R}^n : f(x) = f(x_k)\}) \geq r$ ist.

(4.5) POWELL-WOLFE-SCHRITTWEITENREGEL: Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine nach unten beschränkte stetig differenzierbare Funktion, $\xi \in \mathbb{R}^n$ und $v \in \mathbb{S}^{n-1}$ eine Abstiegsrichtung von f in ξ . Weiters sei $\gamma \in (0, \frac{1}{2})$ und $\eta \in (\gamma, 1)$ gegeben. Zeigen Sie, dass es ein $\alpha > 0$ mit

$$f(x + \alpha v) - f(x) \leq \alpha \gamma \nabla f(x)^\top v \quad \text{und} \quad \nabla f(x + \alpha v)^\top v \geq \eta \nabla f(x)^\top v$$

gibt.

(4.6) IMPLEMENTIERUNG DES GRADIENTENVERFAHRENS: Wir wollen das numerische Verhalten des Gradientenverfahrens untersuchen.

- a) Implementieren Sie Algorithmus 4.1.1 in einer Programmiersprache Ihrer Wahl, vorzugsweise in Python.

Wir betrachten dazu die Rosenbrock-Funktion

$$f(x, y) = (1 - x)^2 + 100(y - x^2)^2$$

Aus Gründen der Vergleichbarkeit setzen wir $\beta = \frac{1}{2}$ und $\gamma = 10^{-4}$.

- b) Bestimmen Sie die stationären Punkte von f und zeigen Sie, dass f in $(1, 1)$ das Minimum annimmt.
 c) Plotten Sie ein paar Niveaukurven von f , das Minimum und ein paar Iterationsschritte des Verfahrens zum Startwert $(-\frac{12}{10}, 1)$.

(4.7) ABSTAND UND PROJEKTION ZU HYPEREBENEN UND HALBRÄUMEN:

- a) Es sei $v \in \mathbb{R}^n \setminus \{0\}$, $a \in \mathbb{R}$ und $H = \{x \in \mathbb{R}^n : \langle x, v \rangle = a\}$. Zeigen Sie, dass

$$d(x, H) = \frac{|\langle x, v \rangle - a|}{\|v\|}$$

für alle $x \in \mathbb{R}^n$ gilt.

- b) Zeigen Sie, dass für $a \in \mathbb{R}^n \setminus \{0\}$ und $b \in \mathbb{R}$ die Abbildung

$$P: \mathbb{R}^n \rightarrow \mathbb{R}^n, \quad x \mapsto x - a \frac{\max\{\langle a, x \rangle - b, 0\}}{\|a\|^2}$$

die metrische Projektion auf den Halbraum $\{x \in \mathbb{R}^n : \langle a, x \rangle \leq b\}$ ist.

(4.8) IMPLEMENTIERUNG DES SUBGRADIENTENVERFAHRENS: Wir wollen das Subgradienten-Verfahren implementieren.

- a) Implementieren Sie ein Subgradienten-Orakel, d.h. die Methode zur Näherung eines Subgradienten aus Abschnitt 4.1.2, in einer Programmiersprache Ihrer Wahl, vorzugsweise in Python.
 b) Implementieren Sie das Subgradienten-Verfahren (Algorithmus 4.1.7) in einer Programmiersprache Ihrer Wahl, vorzugsweise in Python. Ignorieren Sie dabei das Abbruchkriterium der Vorlesung, da wir keine Möglichkeit haben das algorithmisch zuverlässig zu testen. Wählen Sie stattdessen eine fixe Anzahl von Schritten.
 c) Testen Sie Ihre Implementierung an der Betragsfunktion auf $\mathbb{R}$ mit Startwert $x_0 = 5$.
 d) Testen Sie Ihre Implementierung an der Funktion

$$\mathbb{R}^{10} \rightarrow \mathbb{R}, \quad x \mapsto \|Ax - b\|_2 + \frac{1}{2}\|x\|_1$$

4 Nichtlineare Optimierung ohne Nebenbedingungen

mit einer zufälligen Matrix $A \in \text{Mat}_{5,10}(\mathbb{R})$ und einem zufälligen $b \in \mathbb{R}^5$ so, dass $Ax = b$ lösbar ist. Wählen Sie dazu $b = Az$ für eine zufälliges $z \in \mathbb{R}^{10}$.

- e) Testen Sie Ihre Implementierung an der Funktion

$$\mathbb{R}^{10} \rightarrow \mathbb{R}, \quad x \mapsto \|Ax - b\|_2 + \frac{1}{2}\|x\|_1$$

mit einer zufälligen Matrix $A \in \text{Mat}_{10,5}(\mathbb{R})$ und einem zufälligen $b \in \mathbb{R}^{10}$ so, dass $Ax = b$ lösbar ist. Wählen Sie dazu $b = Az$ für eine zufälliges $z \in \mathbb{R}^5$. Wie unterscheidet sich die Situation von der in (d)?

(4.9) IMPLEMENTIERUNG DES NEWTON-VERFAHRENS: Wir wollen das Newton-Verfahren implementieren.

- a) Implementieren Sie das Newton-Verfahren in einer Programmiersprache Ihrer Wahl, vorzugsweise Python.
- b) Implementieren Sie das Hybridverfahren (Algorithmus 4.2.5) in einer Programmiersprache Ihrer Wahl, vorzugsweise Python.
- c) Testen Sie Ihre Implementierung des Newton-Verfahrens an der Rosenbrock-Funktion aus Aufgabe (4.6) mit Startpunkt $x_0 = (-\frac{1}{2}, 1)$.
- d) Testen Sie das Hybridverfahren (mit den für β und γ aus Aufgabe (4.6)) an der Rosenbrock-Funktion mit Startwert $x_0 = (-\frac{12}{10}, 1)$.

Bonus in (c) und (d): Vergleichen Sie die Verfahren mit dem Gradientenverfahren.

5 Verfahren zur konvexen Optimierung mit Nebenbedingungen

Wir betrachten in diesem Kapitel Verfahren zur Lösung von Optimierungsproblemen der Form

$$\begin{aligned} \min \quad & f(x) \\ & g_i(x) \leq 0, \quad 1 \leq i \leq p \\ & h_j(x) = 0, \quad 1 \leq j \leq q \end{aligned} \tag{5.1}$$

für bestimmte Funktionen $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$, $1 \leq i \leq p$ und $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$, $1 \leq j \leq q$. Wir verwenden dabei die Notation

$$C := \{x \in \mathbb{R}^n: g_i(x) \leq 0, h_j(x) = 0 \text{ für } i = 1, \dots, p \text{ und } j = 1, \dots, q\}$$

für den zulässigen Bereich dieses Problems.

5.1 Projektionsverfahren

In diesem Abschnitt betrachten wir den Fall, dass der zulässige Bereich C eine konvexe Menge ist, d.h. wir nehmen an, dass $g_1, \dots, g_p$ konvex und $h_1, \dots, h_q$ affin sind. Also ist C eine abgeschlossene konvexe Menge. Wir haben in Satz 3.1.11 gesehen, dass es zu jedem $x \in \mathbb{R}^n$ einen eindeutigen Punkt $P_C x \in C$ gibt, der den Abstand zu x minimiert.

Definition 5.1.1. Es sei $C \subset \mathbb{R}^n$ eine abgeschlossene konvexe Menge. Die Funktion

$$\mathbb{R}^n \rightarrow \mathbb{R}^n, \quad x \mapsto P_C x := \operatorname{argmin}\{\|x - z\|: z \in C\}$$

heißt *metrische Projektion auf C* .

Damit wir das Konzept des stationären Punkts auf Probleme mit Nebenbedingungen übertragen können, betrachten wir den Tangentialkegel einer Teilmenge des $\mathbb{R}^n$.

Definition 5.1.2. Für $C \subset \mathbb{R}^n$ und $\xi \in C$ heißt die Menge

$$\begin{aligned} T(C; \xi) := \{z \in \mathbb{R}^n: \exists (\lambda_k)_{k \in \mathbb{N}} \exists (x_k)_{k \in \mathbb{N}} \text{ mit } \lambda_k \geq 0, x_k \in C, \\ \lim_{k \rightarrow \infty} x_k = \xi, \lim_{k \rightarrow \infty} \lambda_k (x_k - \xi) = z\} \end{aligned}$$

heißt *Tangentialkegel von C in ξ* .

Satz 5.1.3. Für eine nichtleere Menge $C \subset \mathbb{R}^n$ und $\xi \in C$ ist der Tangentialkegel $T(C; \xi)$ ein nicht-leerer abgeschlossener Kegel.

Beweis. Wir zeigen zuerst, dass $T(C; \xi)$ ein nicht-leerer Kegel ist. Mit $x_k = \xi$ und $\lambda_k = 1$ für alle $k \in \mathbb{N}$ erhalten wir, dass $0 \in T(C; \xi)$ und damit $T(C; \xi) \neq \emptyset$. Sei nun $z \in T(C; \xi)$ und $\mu > 0$. Da $z \in T(C; \xi)$ gibt es $(\lambda_k)_{k \in \mathbb{N}}$ und $(x_k)_{k \in \mathbb{N}}$ mit $\lambda_k \geq 0$, $x_k \in C$, $\lim_{k \rightarrow \infty} x_k = \xi$ und $\lim_{k \rightarrow \infty} \lambda_k(x_k - \xi) = z$. Wegen

$$\lambda_k \mu \geq 0 \quad \text{und} \quad \lim_{k \rightarrow \infty} \lambda_k \mu(x_k - \xi) = \mu z$$

ist $\mu z \in T(C; \xi)$ und daher $T(C; \xi)$ ein Kegel.

Um zu zeigen, dass $T(C; \xi)$ abgeschlossen ist, sei $z_k \in T(C; \xi)$ und $z_k \rightarrow z \in \mathbb{R}^n$. Wir zeigen nun, dass $z \in T(C; \xi)$ ist. Durch Übergang zu einer Teilfolge falls nötig, können wir erreichen, dass $\|z_k - z\| \leq \frac{1}{k}$ für alle $k \in \mathbb{N}$ gilt. Da $z_k \in T(C; \xi)$ ist, gibt es Folgen $(\lambda_{k,j})_{j \in \mathbb{N}}$ und $(x_{k,j})_{j \in \mathbb{N}}$ mit $\lambda_{k,j} \geq 0$, $x_{k,j} \in C$, $\lim_{j \rightarrow \infty} x_{k,j} = \xi$ und $\lim_{j \rightarrow \infty} \lambda_{k,j}(x_{k,j} - \xi) = z_k$. Wir wählen nun $j_k \in \mathbb{N}$ groß genug, dass

$$\|x_{k,j_k} - \xi\| \leq \frac{1}{k} \quad \text{und} \quad \|\lambda_{k,j_k}(x_{k,j_k} - \xi) - z_k\| \leq \frac{1}{k}$$

für alle $j \geq j_k$. Damit ist

$$\|x_{k,j_k} - \xi\| \leq \frac{1}{k} \quad \text{und} \quad \|\lambda_{k,j_k}(x_{k,j_k} - \xi) - z\| \leq \frac{2}{k}.$$

nach der Dreiecksungleichung und damit $z \in T(C; \xi)$. □

Wir betrachten das Minimierungsproblem

$$\begin{aligned} \min \quad & f(x) \\ & g_i(x) \leq 0, \quad 1 \leq i \leq p \\ & h_j(x) = 0, \quad 1 \leq j \leq q \end{aligned} \tag{5.2}$$

mit stetig differenzierbaren Funktionen $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$, $1 \leq i \leq p$ und $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$, $1 \leq j \leq q$, wobei annehmen, dass f und die g_i alle konvex und die h_j alle affin sind. Wir setzen

$$C := \{x \in \mathbb{R}^n : g_i(x) \leq 0, \quad h_j(x) = 0 \text{ für } i = 1, \dots, p \text{ und } h_j(x) = 0 \text{ für } j = 1, \dots, q\}$$

und erhalten eine konvexe abgeschlossene Menge.

Definition 5.1.4. In der obigen Situation nennt man $\xi \in C$ einen *stationären Punkt* von (5.2), falls für alle $z \in T(C; \xi)$ die Ungleichung

$$\nabla f(\xi)^T z \geq 0$$

erfüllt.

Wir zeigen als erstes, dass jede Minimallösung von (5.2) ein stationärer Punkt im obigen Sinne ist.

Satz 5.1.5. *Es sei f stetig differenzierbar und ξ ein Minimum von f auf C . Dann gilt*

$$\nabla f(\xi)^T z \geq 0$$

für alle $z \in T(C; \xi)$.

Beweis. Es sei $z \in T(C; \xi)$ sowie $(\lambda_k)_{k \in \mathbb{N}}$ und $(x_k)_{k \in \mathbb{N}}$ die zugehörigen Folgen aus der Definition des Tangentialkegels. Da f in ξ ihr Minimum auf C annimmt, gilt $f(\xi) \leq f(x_k)$ für all $k \in \mathbb{N}$. Da f konvex ist, gilt

$$f(\xi) \geq f(x_k) + \langle \nabla f(x_k), \xi - x_k \rangle$$

für $k \in \mathbb{N}$. Da $\lambda_k \geq 0$ ist, gilt

$$\nabla f(x_k)^T \lambda_k (x_k - \xi) \geq \lambda_k (f(x_k) - f(\xi))$$

und daher

$$\nabla f(\xi)^T z \geq 0$$

für $k \rightarrow \infty$. □

Bemerkung 5.1.6. Die Definition des Tangentialkegels und auch von stationären Punkten macht auch für nicht-konvexe Nebenbedingungen und nicht-konvexe Zielfunktionen Sinn. Auch kann man mit einem leicht anderen Beweis die obige Aussage für lokale Minima nicht-konvexer Funktionen beweisen.

Wir betrachten in diesem Abschnitt Verfahren der folgenden Form.

Algorithmus 5.1.7 (Allgemeines Projektionsverfahren). Wir betrachten eine stetig differenzierbare konvexe Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ sowie eine konvexe abgeschlossene Menge $C \subset \mathbb{R}^n$ und suchen ein Minimum von f auf C .

Eingabe: Einen Startpunkt $x_0 \in C$

Ausgabe: Ein stationärer Punkt von f auf C .

Durchführung: Wir setzen $k = 0$ und fixieren $\beta, \gamma \in (0, 1)$.

(1) Falls x_k ein stationärer Punkt von f auf C ist, geben wir x_k zurück.

(2) Anderenfalls setzen wir

$$v_k = -\frac{\nabla f(x_k)}{\|\nabla f(x_k)\|}$$

und wählen das größte $\alpha_k \in \{\beta^m : m \in \mathbb{N}_0\}$ so, dass

$$f(P_C(x_k + \alpha_k v_k)) - f(x_k) \leq \gamma \langle \nabla f(x_k), P_C(x_k + \alpha_k v_k) - x_k \rangle.$$

Damit setzen wir

$$x_{k+1} = P_C(x_k + \alpha_k v_k).$$

5 Verfahren zur konvexen Optimierung mit Nebenbedingungen

(3) Wir ersetzen k durch $k + 1$ und gehen zurück zu Schritt (1).

Bevor wir zeigen, dass ein solches α_k immer existiert, wollen wir eine Reihe von Eigenschaften der metrischen Projektion untersuchen.

Satz 5.1.8. *Es sei $C \subset \mathbb{R}^n$ eine abgeschlossene konvexe Menge. Wir betrachten die metrische Projektion P_C auf C .*

(i) P_C ist ein monotoner Operator, d.h.

$$\langle P_C y - P_C x, y - x \rangle \geq \|P_C y - P_C x\|^2 \geq 0$$

gilt für alle $x, y \in \mathbb{R}^n$.

(ii) P_C ist nicht-expansiv, d.h.

$$\|P_C x - P_C y\| \leq \|x - y\|$$

für alle $x, y \in \mathbb{R}^n$.

Beweis. Wir starten mit der Beobachtung, dass nach Satz 3.1.11 die Ungleichungen

$$\langle x - P_C x, P_C y - P_C x \rangle \leq 0 \quad \text{und} \quad \langle y - P_C y, P_C x - P_C y \rangle \leq 0$$

für alle $x, y \in \mathbb{R}^n$ gelten.

(i) Aus den obigen Ungleichungen erhalten wir

$$0 \geq \langle x - y, P_C y - P_C x \rangle + \langle P_C y - P_C x, P_C y - P_C x \rangle,$$

und damit

$$\langle y - x, P_C y - P_C x \rangle \geq \|P_C y - P_C x\|^2$$

was die behauptete Monotonie beweist.

(ii) Aus der Monotonie und der Cauchy-Schwarz-Ungleichung erhalten wir

$$\|P_C x - P_C y\|^2 \leq \langle y - x, P_C y - P_C x \rangle \leq \|x - y\| \|P_C x - P_C y\|$$

und durch Division durch $\|P_C x - P_C y\|$ die Ungleichung

$$\|P_C x - P_C y\| \leq \|x - y\|,$$

die beweist, dass P_C nicht-expansiv ist.

□

Lemma 5.1.9. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine stetig differenzierbare Funktion und $C \subset \mathbb{R}^n$ eine abgeschlossene konvexe Menge. Weiters sei $\xi \in C$ und $v = -\frac{\nabla f(\xi)}{\|\nabla f(\xi)\|}$. Gibt es ein $\alpha > 0$ mit*

$$\langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle \geq 0,$$

so ist ξ ein stationärer Punkt von f auf C .

Beweis. Wir verwenden, dass nach Satz 3.1.11 die Ungleichung

$$0 \geq \langle \xi + \alpha v - P_C(\xi + \alpha v), z - P_C(\xi + \alpha v) \rangle$$

für alle $z \in C$ erfüllt ist. Damit haben wir insbesondere, dass

$$\langle \xi + \alpha v - P_C(\xi + \alpha v), \xi - P_C(\xi + \alpha v) \rangle \leq 0.$$

Ist

$$\langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle \geq 0$$

so ist also

$$\langle \xi + \alpha v - P_C(\xi + \alpha v) + \lambda \nabla f(\xi), \xi - P_C(\xi + \alpha v) \rangle \leq 0$$

für alle $\lambda \geq 0$. Aus

$$\begin{aligned} \xi - P_C(\xi + \alpha v) &= -\xi + \xi - \alpha v + (-P_C(\xi + \alpha v) + \xi + \alpha v) \\ &= -\alpha v + (-P_C(\xi + \alpha v) + \xi + \alpha v) \\ &= \xi + \alpha v - P_C(\xi + \alpha v) + \frac{\alpha}{\|\nabla f(\xi)\|} \nabla f(\xi) \end{aligned}$$

erhalten wir zusammen mit dem obigen, dass

$$\|\xi - P_C(\xi + \alpha v)\|^2 \leq 0$$

und folglich $\xi = P_C(\xi + \alpha v)$. Wenden wir darauf wieder Satz 3.1.11 an, so erhalten wir, dass

$$0 \geq \langle \xi + \alpha v - \xi, z - \xi \rangle = \alpha \langle v, z - \xi \rangle$$

für alle $z \in C$. Folglich ist

$$\langle \nabla f(\xi), z - \xi \rangle \geq 0$$

für alle $z \in C$ und da diese Ungleichung durch Multiplikation mit nicht-negativen Zahlen und durch Grenzwerte erhalten bleibt, ist ξ ein stationärer Punkt von f . $\square$

Lemma 5.1.10. *Es sei $C \subset \mathbb{R}^n$ eine abgeschlossene konvexe Menge und $\xi, v \in \mathbb{R}^n$, $v \neq 0$. Dann ist die Funktion*

$$\Phi: (0, \infty) \rightarrow [0, \infty), \quad \alpha \mapsto \frac{\|P_C(\xi + \alpha v) - \xi\|}{\alpha}$$

monoton fallend.

Beweis. Es seien $\alpha > \beta > 0$ gegeben. Ist $P_C(\xi + \alpha v) = P_C(\xi + \beta v)$, haben wir die Ungleichung $\Phi(\alpha) < \Phi(\beta)$. Wir nehmen also $P_C(\xi + \alpha v) \neq P_C(\xi + \beta v)$ an. Aus Satz 3.1.11 erhalten wir, dass

$$\langle P_C(\xi + \beta v) - (\xi + \beta v), P_C(\xi + \alpha v) - P_C(\xi + \beta v) \rangle \geq 0$$

5 Verfahren zur konvexen Optimierung mit Nebenbedingungen

gilt. Damit haben wir

$$\begin{aligned} & \langle P_C(\xi + \beta v) - (\xi + \beta v) + \beta v, P_C(\xi + \alpha v) - P_C(\xi + \beta v) \rangle \\ & \geq \beta \langle v, P_C(\xi + \alpha v) - P_C(\xi + \beta v) \rangle \\ & \geq \frac{\beta}{\alpha - \beta} \|P_C(\xi + \alpha v) - P_C(\xi + \beta v)\|^2 > 0. \end{aligned}$$

aus Satz 5.1.8. Aus Aufgabe (5.6) erhalten wir damit

$$\frac{\|P_C(\xi + \alpha v) - \xi\|}{\|P_C(\xi + \beta v) - \xi\|} \leq \frac{\alpha \langle v, P_C(\xi + \alpha v) - P_C(\xi + \beta v) \rangle}{\beta \langle v, P_C(\xi + \alpha v) - P_C(\xi + \beta v) \rangle} = \frac{\alpha}{\beta},$$

was wir auf

$$\Phi(\alpha) \leq \Phi(\beta)$$

umformen können. □

Satz 5.1.11. *Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine stetig differenzierbare Funktion und $C \subset \mathbb{R}^n$ eine abgeschlossene konvexe Menge. Weiters sei $\xi \in C$, $v = -\frac{\nabla f(\xi)}{\|\nabla f(\xi)\|}$ und $\gamma \in (0, 1)$. Ist ξ kein stationärer Punkt von f in C , so gibt es ein $\delta > 0$ so, dass*

$$f(P_C(\xi + \alpha v)) - f(\xi) \leq \gamma \langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle$$

für alle $\alpha \in [0, \delta]$.

Beweis. Falls $\xi + \alpha v \in C$ für ein $\alpha > 0$ folgt die Aussage aus Satz 4.1.2. Wir können also $\xi + \alpha v \notin C$ für alle $\alpha > 0$ annehmen. Für $\alpha = 0$ ist die behauptete Ungleichung erfüllt. Wir können also ab jetzt $\alpha > 0$ annehmen.

Da ξ kein stationärer Punkt von f auf C ist, erhalten wir aus Lemma 5.1.9, dass

$$\langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle < 0$$

für jedes $\alpha > 0$. Weiters haben wir im Beweis, des Lemmas gesehen, dass in diesem Fall $P_C(\xi + \alpha v) \neq \xi$ ist. Da f in ξ differenzierbar ist, gibt es zu jedem $\varepsilon > 0$ ein $\delta > 0$ mit

$$|f(x) - f(\xi) - \langle \nabla f(\xi), x - \xi \rangle| \leq \varepsilon \|x - \xi\|$$

für alle $x \in \mathbb{R}^n$ mit $\|x - \xi\| < \delta$. Für $\alpha \in (0, \delta)$ gilt also

$$|f(P_C(\xi + \alpha v)) - f(\xi) - \langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle| \leq \varepsilon \|P_C(\xi + \alpha v) - \xi\|,$$

da $\|P_C(\xi + \alpha v) - \xi\| = \|P_C(\xi + \alpha v) - P_C \xi\| \leq \alpha \|v\| = \alpha < \delta$ ist. Wir setzen

$$\varepsilon := (1 - \gamma) \|\nabla f(\xi)\| \|P_C(\xi + v) - \xi\| > 0$$

und erhalten damit ein $\delta \in (0, 1)$ und damit

$$\begin{aligned}
 f(P_C(\xi + \alpha v)) - f(\xi) &\leq \langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle + \varepsilon \|P_C(\xi + \alpha v) - \xi\| \\
 &\leq \langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle \\
 &\quad + (1 - \gamma) \|\nabla f(\xi)\| \frac{\|P_C(\xi + v)\|}{1} \|P_C(\xi + \alpha v) - \xi\| \\
 &\leq \langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle + \\
 &\quad + \frac{1 - \gamma}{\alpha} \|\nabla f(\xi)\| \|P_C(\xi + \alpha v) - \xi\|^2 \\
 &\leq \langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle - (1 - \gamma) \langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle \\
 &= \gamma \langle \nabla f(\xi), P_C(\xi + \alpha v) - \xi \rangle
 \end{aligned}$$

aus Lemma 5.1.10 und der Monotonie von P_C aus Satz 4.1.2 für alle $\alpha \in (0, \delta)$. $\square$

Als nächstes zeigen wir, dass das Projektionsverfahren auch tatsächlich gegen einen stationären Punkt von f in C konvergiert.

Satz 5.1.12. *Es sei $C \subset \mathbb{R}^n$ eine konvexe abgeschlossene Menge und $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine stetig differenzierbare konvexe Funktion, die auf C nach unten beschränkt ist. Weiters sei $x_0 \in C$ ein Startpunkt, für den die Menge $\{x \in C: f(x) \leq f(x_0)\}$ kompakt ist. Dann besitzt die Folge $(x_k)_{k \in \mathbb{N}}$, die von Algorithmus 5.1.7 erzeugt wird, mindestens einen Häufungspunkt und jeder Häufungspunkt ist ein stationärer Punkt von f auf C .*

Beweis. Nach Konstruktion des Verfahrens und Lemma 5.1.9 ist

$$f(x_{k+1}) - f(x_k) \leq \gamma \langle \nabla f(x_k), P_C(x_k + \alpha_k v_k) - x_k \rangle < 0$$

und daher $f(x_{k+1}) < f(x_k)$ für alle $k \in \mathbb{N}_0$ für die x_k nicht stationär ist. Folglich liegen alle Folgenglieder in der kompakten konvexen Menge $\{x \in C: f(x) \leq f(x_0)\}$ und daher besitzt die Folge $(x_k)_{k \in \mathbb{N}}$ Häufungspunkte. Bricht das Verfahren nach endlich vielen Schritten ab, ist der letzte Punkt ein stationärer Punkt von f in C . Wir müssen also nur noch den Fall betrachten, dass kein x_k ein stationärer Punkt ist.

Sei x^* ein solcher Häufungspunkt. Dann gibt es eine Teilfolge $(x_{k_j})_{j \in \mathbb{N}}$, die gegen x^* konvergiert. Nach Satz 3.1.11 erhalten wir

$$\langle x_{k_j+1} - (x_{k_j} + \alpha_{k_j} v_{k_j}), x_{k_j+1} - z \rangle \leq 0$$

für alle $z \in C$. Da wir $\langle x_{k_j+1} - x_{k_j}, x_{k_j+1} - x_{k_j} \rangle \geq 0$ auf

$$\langle x_{k_j+1} - x_{k_j}, x_{k_j+1} \rangle \geq \langle x_{k_j+1} - x_{k_j}, x_{k_j} \rangle$$

umformen können, erhalten wir aus dem obigen

$$\begin{aligned}
 \frac{\alpha_{k_j}}{\|\nabla f(x_{k_j})\|} \langle \nabla f(x_{k_j}), x_{k_j+1} - z \rangle &\leq \langle x_{k_j+1} - x_{k_j}, z - x_{k_j+1} \rangle \\
 &\leq \langle x_{k_j+1} - x_{k_j}, z - x_{k_j} \rangle \\
 &\leq \|x_{k_j+1} - x_{k_j}\| \|z - x_{k_j}\|
 \end{aligned}$$

5 Verfahren zur konvexen Optimierung mit Nebenbedingungen

für alle $z \in C$. Damit erhalten wir

$$\begin{aligned} \langle \nabla f(x_{k_j}), x_{k_j} - z \rangle &= \langle \nabla f(x_{k_j}), x_{k_j} - x_{k_j+1} \rangle + \langle \nabla f(x_{k_j}), x_{k_j+1} - z \rangle \\ &\leq \langle \nabla f(x_{k_j}), x_{k_j} - x_{k_j+1} \rangle + \|\nabla f(x_{k_j})\| \frac{\|x_{k_j+1} - x_{k_j}\|}{\alpha_{k_j}} \|x_{k_j} - z\|. \end{aligned}$$

Aus der Konstruktion des Verfahrens und der Monotonie der metrischen Projektion, siehe Satz 5.1.8, erhalten wir, dass

$$\begin{aligned} f(x_{k_{j+1}}) - f(x_{k_j}) &\leq f(x_{k_{j+1}}) - f(x_{k_j}) \leq \gamma \langle \nabla f(x_{k_j}), x_{k_{j+1}} - x_{k_j} \rangle \\ &\leq -\gamma \|\nabla f(x_{k_j})\| \frac{\|x_{k_j} - x_{k_{j+1}}\|^2}{\alpha_{k_j}} \leq 0 \end{aligned}$$

ist. Also muss nach Einschließungskriterium

$$\lim_{j \rightarrow \infty} \langle \nabla f(x_{k_j}), x_{k_{j+1}} - x_{k_j} \rangle = 0 \quad \text{und} \quad \lim_{j \rightarrow \infty} \|\nabla f(x_{k_j})\| \frac{\|x_{k_j} - x_{k_{j+1}}\|^2}{\alpha_{k_j}} = 0$$

gelten, da $f(x_{k_{j+1}}) - f(x_{k_j}) \rightarrow 0$ für $j \rightarrow \infty$. Also besitzt mindestens einer der Folgen $\|\nabla f(x_{k_j})\|$ oder $\frac{\|x_{k_j} - x_{k_{j+1}}\|^2}{\alpha_{k_j}}$ eine Teilfolge, die gegen Null konvergiert. Wir verwenden wieder die gleiche Notation für diese Teilfolge. Wir betrachten den Fall, dass $\|\nabla f(x_{k_j})\| \geq c$ für ein $c > 0$ und

$$\lim_{j \rightarrow \infty} \frac{\|x_{k_j} - x_{k_{j+1}}\|^2}{\alpha_{k_j}} = 0$$

gilt und nehmen an, wir hätten ein $\varepsilon > 0$ und eine unendliche Menge $J \subset \mathbb{N}$ mit

$$\|x_{k_j} - x_{k_{j+1}}\| \geq \varepsilon \alpha_{k_j}$$

für alle $j \in J$. Dann gilt

$$\frac{\|x_{k_j} - x_{k_{j+1}}\|^2}{\alpha_{k_j}} \geq \varepsilon \|x_{k_j} - x_{k_{j+1}}\| \geq \varepsilon^2 \alpha_{k_j}$$

für alle $j \in J$ und daher

$$\lim_{j \rightarrow \infty} \alpha_{k_j} = 0 \quad \text{und} \quad \lim_{j \rightarrow \infty} \|x_{k_j} - x_{k_{j+1}}\|.$$

Also gilt für j groß genug, dass $\alpha_{k_j} = \beta^{m_{k_j}}$ mit $m_{k_j} > 0$ ist. Aus der Armijo-Bedingung erhalten wir also

$$f(P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j})) - f(x_{k_j}) > \gamma \langle \nabla f(x_{k_j}), P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j}) - x_{k_j} \rangle \quad (5.3)$$

und aus Lemma 5.1.10, dass

$$\begin{aligned}
 \frac{\|x_{k_j} - x_{k_j+1}\|^2}{\alpha_{k_j}} &\geq \alpha_{k_j} \frac{\|x_{k_j} - P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j})\|}{\beta^{m_{k_j}-1}} \frac{\|x_{k_j} - x_{k_j+1}\|}{\alpha_{k_j}} \\
 &\geq \alpha_{k_j} \varepsilon \beta \frac{\|x_{k_j} - P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j})\|}{\alpha_{k_j}} \\
 &= \varepsilon \beta \|x_{k_j} - P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j})\|
 \end{aligned}$$

und daher

$$\begin{aligned}
 \langle \nabla f(x_{k_j}), x_{k_j} - P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j}) \rangle &\geq \langle \nabla f(x_{k_j}), x_{k_j} - x_{k_j+1} \rangle \\
 &\geq c \varepsilon \beta \|x_{k_j} - P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j})\| > 0.
 \end{aligned}$$

Da die Folge in der Mitte gegen Null konvergiert, konvergiert auch

$$\|x_{k_j} - P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j})\| \rightarrow 0.$$

Da ∇f auf der kompakten Menge $\{x \in C: f(x) \leq f(x_0)\}$ gleichmäßig stetig ist, folgt aus der obigen Ungleichung

$$\frac{f(x_{k_j}) - f(P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j}))}{\langle \nabla f(x_{k_j}), x_{k_j} - P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j}) \rangle} \rightarrow 1$$

für $j \rightarrow \infty$, im Widerspruch zu

$$\frac{f(x_{k_j}) - f(P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j}))}{\langle \nabla f(x_{k_j}), x_{k_j} - P_C(x_{k_j} + \beta^{m_{k_j}-1} v_{k_j}) \rangle} \leq \gamma < 1$$

nach (5.3). Also muss jedenfalls

$$\lim_{j \rightarrow \infty} \|\nabla f(x_{k_j})\| \frac{\|x_{k_j} - x_{k_j+1}\|}{\alpha_{k_j}} = 0$$

gelten. Aufgrund der Stetigkeit von ∇f folgt

$$\langle \nabla f(x^*), z - x^* \rangle \geq 0$$

für alle $z \in C$. Also ist, analog zum Beweis von Lemma 5.1.9, x^* ein stationärer Punkt von f in C . $\square$

Da wir als Startpunkt unseres Verfahrens ein $x_0 \in C$, d.h. einen zulässigen Punkt, benötigen, müssen wir als erstes folgendes Problem lösen: Finde ein

$$x_0 \in \bigcap_{i=1}^p \{x \in \mathbb{R}^n: g_i(x) \leq 0\} \cap \bigcup_{j=1}^q \{x \in \mathbb{R}^n: h_j(x) = 0\}.$$

5 Verfahren zur konvexen Optimierung mit Nebenbedingungen

Da es sich bei $\{x \in \mathbb{R}^n : g_i(x) \leq 0\}$ und $\{x \in \mathbb{R}^n : h_j(x) = 0\}$ um konvexe abgeschlossene Menge handelt, können wir obiges Problem ein Spezialfall des folgenden Problems auffassen: Gegeben konvexe abgeschlossene Mengen $C_1, \dots, C_m$ mit nicht-leerem Durchschnitt finde einen Punkt

$$x_0 \in \bigcap_{i=1}^m C_i.$$

In der englischsprachigen Literatur wird dieses Problem oft als *convex feasibility problem* bezeichnet. Wir wollen hier nur kurz darauf eingehen. Manchmal ist die Projektion auf die einzelnen Mengen leichter zu bestimmen als die Projektion auf den Durchschnitt. Ein Extremfall dieser Situation ist, wenn alle C_i Halbräume sind, da wir dafür die Projektion durch eine einfache Formel angeben können, siehe Aufgabe (4.7).

Satz 5.1.13. *Es seien $C_1, \dots, C_m$ abgeschlossene konvexe Mengen mit nicht-leerem Durchschnitt, d.h. $C := \bigcap_{i=1}^m C_i \neq \emptyset$ und $x_0 \in \mathbb{R}^n$. Wir setzen*

$$x_{k+1} = P_{C_m} P_{C_{m-1}} \cdots P_{C_1} x_k$$

für $k \in \mathbb{N}$. Dann konvergiert x_k gegen einen Punkt in C .

Beweis. Für $z \in C_i$ und $x \in \mathbb{R}^n$ haben wir

$$\begin{aligned} \|x - z\|^2 &= \langle x - P_{C_i}x + P_{C_i}x - z, x - P_{C_i}x + P_{C_i}x - z \rangle \\ &= \|x - P_{C_i}x\|^2 + 2\langle x - P_{C_i}x, P_{C_i}x - z \rangle + \|P_{C_i}x - z\|^2 \\ &\geq \|x - P_{C_i}x\|^2 + \|P_{C_i}x - z\|^2 \end{aligned}$$

nach Satz 3.1.11 was wir auf

$$\|P_{C_i}x - z\|^2 \leq \|x - z\|^2 - \|x - P_{C_i}x\|^2$$

umformen können. Damit ist also

$$\|P_{C_2} P_{C_1} x - z\|^2 \leq \|x - z\|^2 - \|x - P_{C_1}x\|^2 - \|P_{C_1}x - P_{C_2} P_{C_1}x\|^2$$

und induktiv

$$\|P_{C_m} \cdots P_{C_1} x - z\|^2 \leq \|x - z\|^2 - \sum_{k=1}^m \left\| \prod_{i=1}^{k-1} P_{C_i} x - \prod_{i=1}^k P_{C_i} x \right\|^2 \leq \|x - z\|^2 \quad (5.4)$$

wobei Gleichheit genau dann gilt, wenn $x \in C$ ist.

Da $C \neq \emptyset$, gibt es ein $z \in C$ und nach der obigen Ungleichung liegen alle Folgenglieder in der Kugel $\bar{B}(z, \|z - x_0\|)$. Also besitzt die Folge eine Teilfolge $(x_{k_j})_{j \in \mathbb{N}}$ mit $x_{k_j} \rightarrow x^* \in \mathbb{R}^n$. Aus (5.4) und Satz 5.1.8 erhalten wir $\|x_{k+1} - z\|^2 \leq \|x_k - z\|^2$ und folglich

$$\|P_{C_m} \cdots P_{C_1} x^* - z\| = \|x^* - z\|,$$

woraus wir mit der obigen Beobachtung $x^* \in C$ erhalten. Sei $\tilde{x} \neq x^*$ ein weiterer Häufungspunkt der Folge $(x_k)_{k \in \mathbb{N}}$, d.h. $x_{i_l} \rightarrow \tilde{x}$ für eine geeignete Teilfolge $(i_l)_{l \in \mathbb{N}}$, und $\varepsilon = \|\tilde{x} - x^*\|$. Dann gibt es ein $K \in \mathbb{N}$ so, dass

$$\|x_{k_j} - x^*\| < \frac{\varepsilon}{2} \quad \text{und} \quad \|x_{i_l} - \tilde{x}\| < \frac{\varepsilon}{2}$$

für alle $j, l \geq K$. Also ist

$$\varepsilon = \|\tilde{x} - x^*\| \leq \|\tilde{x} - x_{i_l}\| + \|x_{i_l} - x^*\| \leq \|\tilde{x} - x_{i_l}\| + \|x_{k_j} - x^*\| < \varepsilon$$

nach (5.4) da $x^* \in C$, ein Widerspruch. Also ist x^* der einzige Häufungspunkt der beschränkte Folge $(x_k)_{k \in \mathbb{N}}$ und folglich gilt $x_k \rightarrow x^* \in C$. $\square$

Bemerkung 5.1.14. Sind die Mengen $C_1, \dots, C_m$ nicht nur abgeschlossene konvexe Mengen, sondern affine Unterräume, so kann man zeigen, dass die Folge der alternierten Projektionen nicht nur gegen eine Punkt im Durchschnitt konvergiert, sondern sogar gegen die Projektion auf den Durchschnitt.

5.2 Straffunktionen und Penalty-Verfahren

Wir betrachten wieder das Minimierungsproblem

$$\begin{aligned} \min f(x) \quad & \text{unter} \\ g_i(x) & \leq 0 \text{ für } i = 1, \dots, p \\ h_j(x) & = 0 \text{ für } j = 1, \dots, q \end{aligned} \tag{5.5}$$

für Funktionen $f, g_i, h_j: \mathbb{R}^n \rightarrow \mathbb{R}$ für $i = 1, \dots, p$ und $j = 1, \dots, q$. Die grundlegende Vorgehensweise in diesem Abschnitt ist es das obige Problem in ein Problem ohne Nebenbedingungen umzuwandeln, dessen Minimalpunkte auch Minima des ursprünglichen Problems sind. Wir setzen

$$l(x) := \sum_{i=1}^p (\max\{g_i(x), 0\})^\alpha + \sum_{j=1}^q |h_j(x)|^\alpha$$

mit einem $\alpha > 0$. Damit erhalten wir eine nicht-negative Funktion $l: \mathbb{R}^n \rightarrow \mathbb{R}$ mit $l(x) = 0$ genau für zulässige $x \in \mathbb{R}^n$. Da die Funktion nicht-zulässige Punkte x mit einem positiven Wert „bestraft“, nennt man l manchmal auch *Straffunktion*. Damit definieren wir nun die *Penalty-Funktion*

$$p: \mathbb{R}^n \times (0, \infty) \rightarrow \mathbb{R}, \quad (x, r) \mapsto f(x) + rl(x)$$

und betrachten für einen fix gewählten *Strafparameter* $r > 0$ das Minimierungsproblem

$$\min p(x, r)$$

ohne Nebenbedingungen.

5 Verfahren zur konvexen Optimierung mit Nebenbedingungen

Bemerkung 5.2.1. Sind die Funktionen $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, p$, konvex, die Funktionen $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$, $j = 1, \dots, q$ affin und $\alpha \geq 1$, so ist für fixes $r > 0$ die Funktion

$$\mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto p(x, r)$$

ebenfalls konvex. Sind die Funktionen alle differenzierbar und $\alpha > 1$ so, ist auch die Penalty-Funktion p , als Funktion von x , differenzierbar. Analog überträgt sich auch zweifache Differenzierbarkeit, falls $\alpha > 2$ ist. Wir können also die Verfahren aus Kapitel 4 anwenden, sofern f , g_i und h_j deren Voraussetzungen erfüllen.

Algorithmus 5.2.2 (Allgemeines Penalty-Verfahren). Wir betrachten stetige Funktionen $f, g_i, h_j: \mathbb{R}^n \rightarrow \mathbb{R}$ für $i = 1, \dots, p$ und $j = 1, \dots, q$ und suchen eine Minimallösung von (5.5).

Eingabe: Einen Startpunkt $x_0 \in \mathbb{R}^n$ und ein $r_0 > 0$

Ausgabe: Eine Minimallösung von (5.5).

Durchführung: Wir setzen $k = 0$.

- (1) Bestimme eine Minimallösung x_{k+1} von $p(\cdot, r_k)$ mit Startwert x_k .
- (2) Falls $g_i(x_{k+1}) \leq 0$ für $i = 1, \dots, p$ und $h_j(x_{k+1}) = 0$ für $j = 1, \dots, q$ ist, stoppen wir und geben x_{k+1} zurück.
- (3) Ansonsten wählen wir $r_{k+1} > 2r_k$, ersetzen k durch $k + 1$ und gehen zu (1).

Satz 5.2.3. Es seien $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$ für $i = 1, \dots, p$ und $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$ für $j = 1, \dots, q$ stetige Funktionen und die Menge der zulässigen Punkte

$$\{x \in \mathbb{R}^n: g_i(x) \leq 0 \text{ für } i = 1, \dots, p \text{ und } h_j(x) = 0 \text{ für } j = 1, \dots, q\}$$

sei nicht leer. Weiters sei die Folge $(r_k)_{k \in \mathbb{N}}$ streng monoton wachsend und die Funktion $p(\cdot, r_k)$ nehme ihr Minimum in x_k an. Dann ist jeder Häufungspunkt von $(x_k)_{k \in \mathbb{N}}$ eine Lösung von (5.5).

Beweis. Da x_k nach Voraussetzung ein Minimum von $p(\cdot, r_k)$ ist, erhalten wir

$$\begin{aligned} p(x_k, r_k) &\leq p(x_{k+1}, r_k) = f(x_{k+1}) + r_k l(x_{k+1}) \\ &< f(x_{k+1}) + r_{k+1} l(x_{k+1}) = p(x_{k+1}, r_{k+1}) \end{aligned}$$

aus $r_{k+1} > r_k$. Also ist die Folge $(p(x_k, r_k))_{k \in \mathbb{N}}$ streng monoton wachsend. Damit gilt also

$$\begin{aligned} r_k l(x_k) + r_{k+1} l(x_{k+1}) &= p(x_k, r_k) - f(x_k) + p(x_{k+1}, r_{k+1}) - f(x_{k+1}) \\ &\leq p(x_{k+1}, r_k) - f(x_{k+1}) + p(x_k, r_{k+1}) - f(x_k) \\ &= r_k l(x_{k+1}) + r_{k+1} l(x_k) \end{aligned}$$

was wir auf

$$(r_{k+1} - r_k) l(x_{k+1}) \leq (r_{k+1} - r_k) l(x_k)$$

umformen können. Wegen $r_{k+1} > r_k$ muss also $l(x_{k+1}) \leq l(x_k)$ gelten. Folglich ist

$$\begin{aligned} 0 &\leq p(x_{k+1}, r_k) - p(x_k, r_k) = f(x_{k+1}) - f(x_k) + r_k(l(x_{k+1}) - l(x_k)) \\ &\leq f(x_{k+1}) - f(x_k). \end{aligned}$$

Wir haben also gezeigt, dass die Folge $(l(x_k))_{k \in \mathbb{N}}$ monoton fallend und die Folgen $(p(x_k, r_k))_{k \in \mathbb{N}}$ und $(f(x_k))_{k \in \mathbb{N}}$ monoton wachsend sind. Da der zulässige Bereich nach Voraussetzung nicht leer ist, können wir einen zulässigen Punkt $z \in \mathbb{R}^n$ wählen. Für diesen Punkt gilt,

$$f(x_0) + r_k l(x_k) \leq f(x_k) + r_k l(x_k) = p(x_k, r_k) \leq p(z, r_k) = f(z),$$

d.h.

$$r_k l(x_k) \leq f(z) - f(x_0)$$

woraus wir aus $r_k l(x_k) \geq 0$ und $r_k \rightarrow \infty$ schließen können, dass $l(x_k) \rightarrow 0$ gilt. Sei nun $x^* \in \mathbb{R}^n$ ein Häufungspunkt der Folge $(x_k)_{k \in \mathbb{N}}$ und $(x_{k_j})_{j \in \mathbb{N}}$ eine Teilfolge von $(x_k)_{k \in \mathbb{N}}$, die gegen den Punkt x^* konvergiert. Aus dem obigen erhalten wir

$$l(x^*) = \lim_{k \rightarrow \infty} l(x_{k_j}) = 0,$$

d.h. x^* ist ein zulässiger Punkt. Für $j \in \mathbb{N}$ erhalten wir

$$f(x_{k_j}) \leq p(x_{k_j}, r_{k_j}) \leq p(x, r_{k_j}) = f(x)$$

und damit

$$f(x^*) = \lim_{j \rightarrow \infty} f(x_{k_j}) \leq f(x)$$

für jeden zulässigen Punkt $x \in \mathbb{R}^n$. Also ist x^* eine Lösung von (5.5). $\square$

Definition 5.2.4. Wir betrachten ein restringiertes Minimierungsproblem

$$\min\{f(x) : x \in C\}$$

für eine Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und eine nicht-leere Menge $C \subset \mathbb{R}^n$. Eine Funktion $s: \mathbb{R}^n \rightarrow \mathbb{R}$ heißt *Straffunktion* zum obigen Problem, falls

$$\begin{aligned} s(x) &= 0 \text{ für } x \in C \\ s(x) &> 0 \text{ für } x \in \mathbb{R}^n \setminus C \end{aligned}$$

gilt. Wir setzen wieder

$$p(x, r) := f(x) + rs(x)$$

und nennen die Straffunktion s exakt, falls es sein $R > 0$ so gibt, dass für $r \geq R$ jedes zulässige lokale Minimum von f auch ein lokales Minimum von $p(\cdot, r)$ ist.

5 Verfahren zur konvexen Optimierung mit Nebenbedingungen

Satz 5.2.5. *Es seien $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$ für $i = 1, \dots, p$ konvexe Funktionen und $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$ für $j = 1, \dots, q$ affine Funktionen so, dass (5.5) eine Lösung besitzt. Weiters sei die Slater Bedingung erfüllt, d.h. es gibt ein $\xi \in \mathbb{R}^n$ mit $g_i(\xi) < 0$ für $i = 1, \dots, p$ und $h_j(\xi) = 0$ für $j = 1, \dots, q$. Dann ist die Straffunktion*

$$l(x) = \sum_{i=1}^p \max\{g_i(x), 0\} + \sum_{j=1}^q |h_j(x)|$$

exakt. Genauer gibt es ein $R > 0$ so, dass $x^ \in \mathbb{R}^n$ genau dann eine Lösung von (5.5) ist, wenn es ein Minimum von $p(\cdot, r)$ für $r > R$ ist.*

Beweis. Um zu zeigen, dass die Straffunktion exakt ist, sei x^* eine Lösung von (5.5). Da die Nebenbedingungen die Slater-Bedingung erfüllen, gibt es nach Satz 3.2.8 ein $y^* \in D$ mit $D = \{y \in \mathbb{R}^{p+q}: y_i \geq 0 \text{ für } i = 1, \dots, p\}$ so, dass (x^*, y^*) ein Sattelpunkt der Lagrange-Funktion

$$L(x, y) = f(x) + \sum_{i=1}^p y_i g_i(x) + \sum_{j=1}^q y_{p+j} h_j(x)$$

ist, d.h. es gilt

$$L(x, y^*) \geq L(x^*, y^*) \geq L(x^*, y) \quad \text{und} \quad f(x^*) = L(x^*, y^*)$$

für alle $x \in \mathbb{R}^n$ und alle $y \in D$. Wir setzen

$$R := \max\{|y_k^*|: k = 1, \dots, p+q\}$$

und bemerken, dass für $r > R$ und $x \in \mathbb{R}^n$ die Ungleichungen

$$\begin{aligned} p(x^*, r) &= f(x^*) + \sum_{i=1}^p \max\{g_i(x^*), 0\} + \sum_{j=1}^q h_i(x^*) = f(x^*) = L(x^*, y^*) \\ &\leq L(x, y^*) = f(x) + \sum_{i=1}^p y_i^* g_i(x) + \sum_{j=1}^q y_{p+j}^* h_j(x) \\ &\leq f(x) + \sum_{i=1}^p y_i^* \max\{g_i(x), 0\} + \sum_{j=1}^q |y_{p+j}^*| |h_j(x)| \\ &\leq f(x) + r \left(\sum_{i=1}^p \max\{g_i(x), 0\} + \sum_{j=1}^q |h_j(x)| \right) \\ &= p(x, r) \end{aligned}$$

gelten. Also ist x^* ein Minimum von $p(\cdot, r)$.

Sei umgekehrt x^* ein Minimum von $p(\cdot, r)$ für ein $r > R$. Nach Voraussetzung gibt es eine Lösung $\bar{x}$ von (5.5). Angenommen x^* wäre nicht zulässig, so gäbe es ein

$i \in \{1, \dots, p\}$ mit $g_i(x^*) > 0$ oder ein $j \in \{1, \dots, q\}$ mit $|h_j(x^*)| > 0$. Nach den obigen Ungleichungen gilt also $p(\bar{x}, r) < p(x^*, r)$ was im Widerspruch zur Annahme steht, dass x^* diese Funktion minimiert. Also ist

$$f(x^*) = p(x^*, r) \leq p(\bar{x}, r) = f(\bar{x})$$

und x^* daher eine Lösung von (5.5). $\square$

5.3 Literatur und Ausblick

Kapitel 5.1 basiert zu großen Teilen auf dem Anfang von Kapitel 11 in [7]. Satz 5.2.3 ist im wesentlichen Satz 18.2 in [14, p. 115] und der Beweis folgt dem dort gegebenen. Der Beweis von Satz 5.2.5 folgt im wesentlichen dem Beweis von Satz 11.1.7 in [7, p. 338]. Die Diskussion der Konvergenz der alternierenden Projektionsmethode, d.h. Satz 5.1.13, basiert auf der Darstellung der Eigenschaften von Fejér-monotonen Folgen in [4].

5.4 Aufgaben

(5.1) ABSTAND ZU KONVEXEN MENGEN: Es sei $C \subset \mathbb{R}^n$ eine abgeschlossene konvexe Menge und $d(x, C) := \inf\{\|x - z\| : z \in C\}$ für $x \in \mathbb{R}^n$ der Abstand von x zu C .

a) Zeigen Sie, dass die Funktion

$$\mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto d(x, C)$$

konvex und nicht-expansiv ist.

b) Verwenden Sie (a), um zu zeigen, dass diese Funktion fast überall differenzierbar ist.

(5.2) METRISCHE PROJEKTIONEN: Wir wollen die metrische Projektion auf eine Reihe weiterer Mengen betrachten.

a) Wir betrachten die Menge $C_+ = \{x \in \mathbb{R}^n : x \geq 0\}$. Zeigen Sie, dass

$$P_C x = x^+ := \max\{x, 0\},$$

wobei hier das komponentenweise Maximum gemeint ist.

b) Es sei $\bar{B}(y, r)$ mit die abgeschlossene Kugel um $y \in \mathbb{R}^n$ mit Radius $r > 0$. Zeigen Sie, dass

$$P_{\bar{B}(y, r)} x = \begin{cases} x & \text{falls } \|x - y\| \leq r \\ y + \frac{r}{\|x - y\|} (x - y) & \text{sonst} \end{cases}.$$

5 Verfahren zur konvexen Optimierung mit Nebenbedingungen

- c) Es seien $C_i \subset \mathbb{R}^{n_i}$ für $i = 1, \dots, m$ abgeschlossene konvexe Mengen mit zugehöriger Projektion $P_{C_i}: \mathbb{R}^{n_i} \rightarrow \mathbb{R}^{n_i}$. Zeigen Sie, dass

$$\mathbb{R}^{n_1+\dots+n_m} \rightarrow \mathbb{R}^{n_1+\dots+n_m}, \quad x \mapsto (P_{C_1}x_1, \dots, P_{C_m}x_m)$$

die metrische Projektion auf $C_1 \times \dots \times C_m$ ist.

- d) Verwenden Sie (c), um die metrische Projektion auf den Quader

$$\prod_{i=1}^n [a_i, b_i]$$

mit $a_i < b_i$ für $i = 1, \dots, n$ zu bestimmen.

- (5.3) MEHR ZU ITERIERTEN METRISCHEN PROJEKTIONEN: Wir betrachten die Mengen

$$C_1 := \{x \in \mathbb{R}^2: \|x\|_1 \leq 1\} \quad \text{und} \quad C_2 := \{x \in \mathbb{R}^2: x_1 = 0\}.$$

- Zeigen Sie, dass C_1 und C_2 abgeschlossene konvexe Mengen sind.
- Bestimmen Sie P_{C_1} und P_{C_2} .
- Bestimmen Sie $P_{C_1 \cap C_2}$.
- Bestimmen Sie $P_{C_i}x$ für $i = 1, 2$ sowie $P_{C_1 \cap C_2}x$ für $x = (-2, 2)$. Überprüfen Sie, ob

$$(P_{C_1}P_{C_2})^n x \rightarrow P_{C_1 \cap C_2}x \quad \text{bzw.} \quad (P_{C_2}P_{C_1})^n x \rightarrow P_{C_1 \cap C_2}x$$

für $n \rightarrow \infty$ gilt.

- (5.4) IMPLEMENTIERUNG PROJEKTIONSVERFAHREN: Wir wollen nun Projektionsverfahren implementieren und deren numerisches Verhalten untersuchen.

- Implementieren Sie Algorithmus 5.1.7 in einer Programmiersprache Ihrer Wahl, vorzugsweise Python.
- Bestimmen Sie die KKT-Punkte und die Lösung von

$$\min f(x) \quad \text{unter} \\ g(x) \leq 0$$

mit

$$f(x, y) = (x - 1)^2 + (y + 1)^2 \quad \text{und} \quad g(x, y) = x^2 + y^2 - 1$$

- Verwenden Sie Ihre Implementierung des Projektionsverfahrens, um das Minimum zu finden. Verwenden Sie aus Gründen der Vergleichbarkeit die Startpunkte $(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2})$ und $(-\frac{1}{2}, 0)$. Plotten Sie Niveaulinien der Funktion f , den zulässigen Bereich und die Schritte des Verfahrens.

(5.5) TANGENTIALKEGEL UND NORMALENKEGEL EINER KONVEXEN MENGE: Es sei $C \subset \mathbb{R}^n$ eine abgeschlossene konvexe Menge

a) Zeigen Sie, dass für $x \in C$ der *Normalenkegel von C in x*

$$N_C(x) = \{y \in \mathbb{R}^n : \langle y, z - x \rangle \leq 0 \text{ für alle } z \in C\}$$

ein abgeschlossener konvexer Kegel ist.

b) Zeigen Sie, dass

$$T(C; x) = \overline{\text{KK}(C - x)}$$

gilt, wobei $C - x = \{z - x : z \in C\}$.

c) Bestimmen Sie $T(C; x)$ und $N_C(x)$ für $C = [-1, 1] \times [-1, 1]$ und $x = (1, 1)$.

d) Zu einem Kegel $K \subset \mathbb{R}^n$ nennt man die Menge

$$K^\circ = \{x \in \mathbb{R}^n : \langle x, z \rangle \leq 0 : \text{ für alle } z \in K\}$$

den zu K *polaren Kegel*. Zeigen Sie, dass

$$N_C(x)^\circ = T(C; x) \quad \text{und} \quad T(C; x)^\circ = N_C(x)$$

gilt.

Hinweis: Bidualsatz aus Lineare Algebra 2.

e) Zeigen Sie, dass $z = P_C x$ genau dann wenn $x - z \in N_C(z)$ ist.

(5.6) UNGLEICHUNGEN FÜR DAS SKALARPRODUKT: Es seien $x, y, z \in \mathbb{R}^n$.

a) Zeigen Sie, dass für x, y mit $\langle y, x - y \rangle > 0$ die Ungleichung

$$\frac{\|x\|}{\|y\|} \leq \frac{\langle x, x - y \rangle}{\langle y, x - y \rangle}$$

gilt.

b) Zeigen Sie, dass die folgenden Aussagen äquivalent sind

$$(i) \quad \langle x - y, z - y \rangle \leq 0$$

$$(ii) \quad \langle z - x, y - x \rangle \geq \|x - y\|^2$$

$$(iii) \quad \|z - y\|^2 \leq \|z - x\|^2 - \|y - x\|^2$$

(5.7) GLEICHMÄSSIGE FRÉCHET-DIFFERENZIERBARKEIT: Es sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine stetig differenzierbare Funktion. Weiters sei $\Omega \subset \mathbb{R}^n$ eine offene konvexe Menge auf der der Gradient ∇f gleichmäßig stetig ist. Zeigen Sie, dass es zu jedem $\varepsilon > 0$ ein $\delta > 0$ so gibt, dass

$$|f(x) - f(y) - \langle \nabla f(y), x - y \rangle| \leq \varepsilon \|x - y\|$$

für alle $x, y \in \Omega$ mit $\|x - y\| < \delta$ gilt.

5 Verfahren zur konvexen Optimierung mit Nebenbedingungen

(5.8) EXAKTHEIT VS. DIFFERENZIERBARKEIT: Wir betrachten das Minimierungsproblem

$$\begin{aligned} \min f(x) \quad & \text{unter} \\ g_i(x) &\leq 0; \text{ für } i = 1, \dots, p \\ h_j(x) &= 0 \text{ für } j = 1, \dots, q \end{aligned}$$

mit stetig differenzierbaren konvexen $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$ für $i = 1, \dots, p$ sowie affinen $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$ für $j = 1, \dots, q$. Wir nehmen an, dass das Problem einen KKT-Punkt $(x^*, y^*) \in \mathbb{R}^{n+p+q}$ besitzt, aber $\nabla f(x^*) \neq 0$ ist. Wir betrachten die Penalty-Funktion

$$p(x, r) = f(x) + rs(x)$$

für eine Straffunktion s (siehe Definition 5.2.4).

- a) Schließen Sie aus Sätzen der Vorlesung, dass x^* eine Lösung des obigen Minimierungsproblems ist.
- b) Wir nehmen an, dass es ein $R > 0$ so gibt, dass

$$p(x^*, r) = \min\{p(x, r) : x \in \mathbb{R}^n\}$$

für alle $r > R$ ist. Zeigen Sie, dass s (und damit $p(\cdot, r)$) in x^* nicht differenzierbar ist.

(5.9) UNGESCHICKTE STRAFFUNKTIONEN: Wir betrachten das Minimierungsproblem

$$\begin{aligned} \min x^3 \quad & \text{unter} \\ -x &\leq 0 \\ x - 1 &\leq 0 \end{aligned}$$

Und verwenden die Straffunktion

$$l(x) := \max\{-x, 0\} + \max\{x - 1, 0\}$$

- a) Zeigen Sie, dass $l(x) = 0$ genau dann wenn $x \in [0, 1]$.
- b) Zeigen Sie, dass $p(x, r) = x^3 + rl(x)$ für kein $r > 0$ ein globales Minimum hat.
- c) Wie ändert sich die Situation wenn man stattdessen

$$l(x) := \max\{-x, 0\}^\alpha + \max\{x - 1, 0\}^\alpha$$

mit $\alpha > 3$ verwendet?

(5.10) IMPLEMENTIERUNG DES PENALTY-VERFAHRENS:

- a) Implementieren Sie Algorithmus 5.2.2 in einer Programmiersprache Ihrer Wahl, vorzugsweise Python.
- b) Verwenden Sie Ihre Implementierung, um folgendes Minimierungsproblem zu lösen.

$$\begin{array}{ll} \min & -x - y \quad \text{unter} \\ & 1 - x^2 - y^2 = 0 \end{array}$$

Plotten Sie Niveaulinien und die Schritte des Verfahrens.

Bonus: Vergleichen Sie das Verhalten bei $\alpha = 2$ und $\alpha = 1$, falls Sie geeignete Minimierungsverfahren zur Verfügung haben.

- c) Verwenden Sie Ihre Implementierung, um folgendes Minimierungsproblem zu lösen.

$$\begin{array}{ll} \min & 1000 - x^2 - 2y^2 - z^2 - xy - xz \quad \text{unter} \\ & x^2 + y^2 + z^2 - 25 = 0 \\ & 8x + 14y + 7z - 56 = 0 \end{array}$$

Verwenden Sie den Startpunkt $x_0 = (3, \frac{2}{10}, 3)$ und Verwenden Sie als Abbruchkriterium, dass $\|h(x_k)\| = \|(h_1(x_k), h_2(x_k))\| < 10^{-4}$ ist.

(5.11) DIFFERENZIERBARKEIT VON POTENZEN VON NORMEN: Wir wollen die Frage untersuchen, wann Potenzen von Normen differenzierbar sind.

- a) Wir betrachten die p -Norm

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}.$$

auf $\mathbb{R}^n$ für $p \in (1, \infty)$. Zeigen Sie, dass für $\alpha \in (0, \infty)$ die Funktion

$$\mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto \|x\|_p^\alpha$$

genau dann stetig differenzierbar ist, wenn $\alpha \geq p$ ist.

- b) Gibt es ein $\alpha > 1$ für das die Funktion

$$\mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto \|x\|_1^\alpha$$

differenzierbar ist?

6 Dualität

Wir betrachten in diesem Kapitel Dualitätsbegriffe für verschiedene Optimierungsprobleme.

6.1 Dualität in linearen Programmen

Definition 6.1.1. Wir betrachten das lineare Programm

$$\min \left\{ c^T x : Ax = b, x \geq 0 \right\} \quad (\text{LP})$$

mit $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Das lineare Programm

$$\max \{ b^T y : A^T y \leq c \} \quad (\text{DLP})$$

nennt man das dazu *duale Programm*.

Wir wollen nun untersuchen wie diesen beiden linearen Programme zusammenhängen.

Satz 6.1.2 (Schwacher Dualitätssatz). *Es sei $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Für alle $y \in \mathbb{R}^m$ mit $A^T y \leq c$ und alle $x \in \mathbb{R}^n$ mit $Ax = b$ und $x \geq 0$ gilt $b^T y \leq c^T x$.*

Beweis. Es seien $x \in \mathbb{R}^n$ und $y \in \mathbb{R}^m$ wie in der Behauptung. Dann ist

$$b^T y - c^T x = x^T A^T y - c^T x = x^T (A^T y - c) \leq 0$$

und daher

$$b^T y \leq c^T x$$

wie behauptet. □

Der Zusammenhang der beiden Programme ist aber weit enger als der schwache Dualitätssatz vermuten lässt.

Satz 6.1.3 (Dualitätssatz der linearen Optimierung). *Es seien $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Wir verwenden die Konventionen $\min \emptyset = \infty$ und $\max \emptyset = -\infty$. Dann gilt*

$$\min \left\{ c^T x : Ax = b, x \geq 0 \right\} = \max \{ b^T y : A^T y \leq c \}$$

sofern mindestens eines der beiden linearen Programme einen nicht-leeren zulässigen Bereich hat.

6 Dualität

Beweis. Wir verwenden die Notationen

$$P_{\inf} = \inf\{c^T x : Ax = b, x \geq 0\} \quad \text{und} \quad D_{\sup} = \sup\{b^T y : A^T y \leq c\}.$$

Besitzen sowohl (LP) als auch (DLP) zulässige Punkte $x \in \mathbb{R}^n$ bzw. $y \in \mathbb{R}^m$, so gelten nach Satz 6.1.2 die Ungleichungen

$$b^T y \leq D_{\sup} \leq P_{\inf} \leq c^T x.$$

Daraus erhalten wir direkt, dass $c^T x$ nach unten beschränkt ist, wenn (DLP) zulässige Punkte besitzt und dass $b^T y$ nach oben beschränkt ist, wenn (LP) zulässige Punkte besitzt. Wir nehmen nun an, dass sowohl (LP) als auch (DLP) zulässige Punkte haben und zeigen, dass die Optimalwerte der beiden Programme übereinstimmen. Nach Satz 2.3.6 terminiert also der Simplexalgorithmus angewandt auf (LP) in einer Optimallösung x^* . Wir stoppen dabei in einem Tableau

$$\begin{array}{c|c} A_B^{-1}A & A_B^{-1}b \\ \hline c^T - c_B^T A_B^{-1}A & -c_B^T A_B^{-1}b \end{array}$$

mit $c^T - c_B^T A_B^{-1}A \geq 0$ und es ist $x_B^* = A_B^{-1}b$ und $x_K^* = 0$. Um eine Optimallösung von (DLP) zu erhalten, setzen wir $y^* = (c_B^T A_B^{-1})^T$. Damit ist

$$c^T x^* = c_B^T x_B^* = c_B^T A_B^{-1}b = b^T (c_B^T A_B^{-1})^T = b^T y^*.$$

Wir müssen also nur noch zeigen, dass y^* ein zulässiger Punkt von (DLP) ist. Es ist

$$A^T y^* = A^T (c_B^T A_B^{-1})^T = (c_B^T A_B^{-1}A)^T \leq (c^T)^T = c,$$

da $c^T - c_B^T A_B^{-1}A \geq 0$ und y^* daher zulässig.

Es bleibt daher nur noch zu zeigen, dass wenn nur eines der beiden Programme einen leeren Zulässigkeitsbereich hat, das andere Programm unbeschränkt ist. Wir nehmen also an, dass der Zulässigkeitsbereich von (LP) leer ist. Aus dem Lemma von Farkas (Satz 1.3.4) erhalten wir, dass es ein $z \in \mathbb{R}^m$ mit $A^T z \geq 0$ und $b^T z < 0$ gibt. Da nach Annahme der Zulässigkeitsbereich von (DLP) nicht leer ist, können wir ein $y \in \mathbb{R}^m$ mit $A^T y \leq c$ finden. Für $\lambda > 0$ setzen wir $y_\lambda := y - \lambda z$ und erhalten

$$A^T y_\lambda = A^T y - \lambda A^T z \leq c \quad \text{und} \quad b^T y_\lambda = b^T y - \lambda b^T z \rightarrow \infty$$

für $\lambda \rightarrow \infty$. Also ist (DLP) nach oben unbeschränkt. Der Beweis, dass (LP) unbeschränkt ist, wenn der zulässige Bereich von (DLP) leer ist, geht analog, wenn man eine äquivalente Form des Lemmas von Farkas verwendet—siehe Aufgabe (6.1). $\square$

Bemerkung 6.1.4. Man kann den Dualitätssatz auch ohne Verwendung des Simplex-Algorithmus nur mit (Varianten des) Lemmas von Farkas beweisen.

Wir können nun die Charakterisierung der Optimallösungen von (LP) und (DLP) als ein Korollar formulieren.

Korollar 6.1.5. Es sei $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Es seien $x \in \mathbb{R}^n$ und $y \in \mathbb{R}^m$ zulässige Punkte, d.h. $Ax = b$, $x \geq 0$ und $A^\top y \leq c$. Dann sind folgende Aussagen äquivalent.

(i) x und y sind Lösungen von (LP) bzw. (DLP).

(ii) $c^\top x = b^\top y$

(iii) $(c^\top - y^\top A)x = 0$

Beweis. Die Äquivalenz von (i) und (ii) ist gerade Satz 6.1.3.

Für den Beweis der Äquivalenz von (ii) und (iii) bemerken wir zuerst, dass wir (iii) auf $c^\top x = y^\top Ax$ umformen können. Aus der Zulässigkeitsannahme für x erhalten wir aber $Ax = b$ und folglich $c^\top x = y^\top b$, d.h. (iii) impliziert (ii). Umgekehrt erhalten wir aus der Zulässigkeitsannahme für x , dass $b^\top y = (Ax)^\top y = x^\top A^\top y = y^\top A^\top x$ und daraus mit (ii), dass $c^\top x = y^\top A^\top x$, d.h. $(c^\top - y^\top A^\top)x = 0$ also (iii). $\square$

Die Bedingung in (iii) nennt man manchmal *komplementärer Schlupf*. Wir formulieren sie nun etwas um und erhalten

$$0 = x^\top (A^\top y - c) = \sum_{i=1}^n x_i (A_{i-}^\top y - c_i).$$

Setzen wir $g_i(y) = A_{i-}^\top y - c_i$ so erhalten wir eine affine und damit insbesondere konvexe Funktion und der zulässige Bereich des dualen Programms ist durch die Ungleichungen $g_i(y) \leq 0$ für $i = 1, \dots, n$ definiert. Wir setzen weiters $f(y) := -b^\top y$, da wir ein Maximum suchen, und erhalten damit die KKT-Bedingungen

$$\begin{aligned} -b + \sum_{i=1}^n x_i^* A_{i-} &= 0 \\ A_{i-}^\top y^* &\leq c_i \\ x_i^* &\geq 0 \\ x_i^* (A_{i-}^\top y^* - c_i) &= 0 \end{aligned}$$

für das duale Problem. Die erste Bedingung können wir auf

$$b = \sum_{i=1}^n x_i^* A_{i-} = Ax^*$$

umformen. Insgesamt können wir die KKT-Bedingungen also auf die Form

$$\begin{aligned} Ax^* &= b \\ A^\top y^* &\leq c \\ x^* &\geq 0 \\ x_i^* (A_{i-}^\top y^* - c_i) &= 0 \quad \text{für } i = 1, \dots, n \end{aligned}$$

bringen. Das Paar $(y^*, x^*) \in \mathbb{R}^{m+n}$ ist also genau dann ein KKT-Punkt von (DLP) wenn x^* ein zulässiger Punkt von (LP), y^* ein zulässiger Punkt von (DLP) ist und die Bedingung $x_i^*(A_i^\top y^* - c_i) = 0$ für $i = 1, \dots, n$ erfüllt ist. Aus Korollar 6.1.5 erhalten wir, dass diese Bedingung dafür notwendig ist, dass sowohl x^* und y^* Lösungen des entsprechenden linearen Programms sind. Dies hätten wir auch aus Satz 3.2.5 erhalten, da dort bewiesen wurde, dass jeder KKT-Punkt ein Minimum definiert. Für den Beweis der umgekehrten Implikation in Satz 3.2.5 haben wir aber die Slater-Bedingung verwendet, die im Allgemeinen nicht erfüllt sein muss.

Bemerkung 6.1.6. Man kann Satz 3.2.5 auch unter schwächeren Bedingungen an die Nebenbedingungen beweisen, die die obigen Situation umfassen. Die dazu passende Bedingung ist die folgende *Abadie-Bedingung*. Wir betrachten die Menge

$$C := \{x \in \mathbb{R}^n : g_i(x) \leq 0 \text{ für } i = 1, \dots, p, \text{ und } h_j(x) = 0 \text{ für } j = 1, \dots, q\}$$

mit stetig differenzierbaren Funktionen $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, p$, und $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$ für $j = 1, \dots, q$. Für $\xi \in C$ bezeichnen wir die Menge

$$T_{\text{lin}}(C; \xi) := \{z \in \mathbb{R}^n : \langle \nabla h_j(\xi), z \rangle = 0 \text{ für } j = 1, \dots, q \text{ und} \\ \langle \nabla g_i(\xi), z \rangle \leq 0, \text{ falls } g_i(\xi) = 0\}$$

als den *linearisierten Tangentialkegel* an C in ξ . Ein Punkt $\xi \in C$ erfüllt die Abadie-Bedingung, falls $T(C; \xi) = T_{\text{lin}}(C; \xi)$ gilt.

Wir zeigen nun die Behauptung direkt für die Situation von linearen Programmen in Dualität, ohne allgemein zu beweisen, dass die Minimalität von x zusammen mit der Abadie-Bedingung für die Existenz eines KKT-Punkts ausreicht.

Satz 6.1.7 (Satz von starken komplementären Schlupf). *Es sei $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Wenn sowohl (LP) als auch (DLP) einen nicht-leeren zulässigen Bereich haben, existieren Optimalpunkte $x^* \in \mathbb{R}^n$ von (LP) und $y^* \in \mathbb{R}^m$ von (DLP) mit*

$$x_i^*(A_i^\top y^* - c_i) = 0$$

für $i = 1, \dots, n$.

Beweis. Im Beweis von Satz 6.1.3 haben wir gesehen, dass wir $y^* = (c_B^\top A_B^{-1})^\top$ mit einer geeigneten Basismenge $B \subset \{1, \dots, n\}$ setzen können. Damit ist

$$x_i^*(A_i^\top y^* - c_i) = x_i^*(c_B^\top A_B^{-1} A_{-i} - c_i) = x_i^*(c_B^\top A_B^{-1} A - c^\top)_i = 0,$$

da $x_i^* = 0$ für $i \notin B$ und $(c^\top - c_B^\top A_B^{-1} A)_i = 0$ für alle $i \in B$ ist. $\square$

6.2 Lagrange-Dualität

Wir betrachten das konvexe Minimierungsproblem

$$\begin{aligned} \min f(x) \quad & \text{unter} \\ g_i(x) &\leq 0 \quad i = 1, \dots, p \\ h_j(x) &= 0 \quad j = 1, \dots, q \end{aligned} \quad (\text{MP})$$

mit konvexen Funktionen $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$ für $i = 1, \dots, p$ sowie affinen Funktionen $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$ für $j = 1, \dots, q$.

Definition 6.2.1. Das Maximierungsproblem

$$\begin{aligned} \max \Theta(y) := \inf \left\{ f(x) + \sum_{i=1}^p y_i g_i(x) + \sum_{j=1}^q y_{p+j} h_j(x) : x \in \mathbb{R}^n \right\} \quad & \text{unter} \\ y_i &\geq 0 \quad \text{für } i = 1, \dots, p \end{aligned} \quad (\text{DP})$$

nennt man das zu (MP) *Lagrange-duale Optimierungsproblem*.

Bemerkung 6.2.2. In der Literatur wird manchmal die Bezeichnung $\Theta(u, v)$ mit

$$u = (y_1, \dots, y_p) \quad \text{und} \quad v = (y_{p+1}, \dots, y_{p+q})$$

verwendet. Dies hat die Vorteile, dass die Indizes in der Summe einfacher und die Nebenbedingung als $u \geq 0$ geschrieben werden kann. Vergleicht man Θ mit der Lagrange-Funktion aus Definition 3.2.7, so sieht man, dass

$$\Theta(y) = \inf \{ L(x, y) : x \in \mathbb{R}^n \}.$$

Dies erklärt auch die Bezeichnung *Lagrange-Dualität*.

Satz 6.2.3 (Schwacher Dualitätssatz). *Sei $x \in \mathbb{R}^n$ ein zulässiger Punkt von (MP) und $y \in \mathbb{R}^{p+q}$ ein zulässiger Punkt von (DP). Dann ist $f(x) \geq \Theta(y)$.*

Beweis. Da $x \in \mathbb{R}^n$ und $y \in \mathbb{R}^{p+q}$ zulässig sind, haben wir

$$\begin{aligned} f(x) &\geq f(x) + \sum_{i=1}^p y_i g_i(x) + \sum_{j=1}^q y_{p+j} h_j(x) \\ &\geq \inf \left\{ f(z) + \sum_{i=1}^p y_i g_i(z) + \sum_{j=1}^q y_{p+j} h_j(z) : z \in \mathbb{R}^n \right\} = \Theta(y), \end{aligned}$$

d.h. die behauptete Ungleichung. □

Analog zum linearen Fall erhalten wir direkt eine Reihe von Folgerungen.

Korollar 6.2.4. *Es seien $x \in \mathbb{R}^n$ und $y \in \mathbb{R}^{p+q}$ zulässige Punkte von (MP) bzw. (DP) mit $f(x) = \Theta(y)$. Dann ist x eine Optimallösung von (MP) und y eine Optimallösung von (DP).*

Korollar 6.2.5. Falls f auf dem zulässigen Bereich nach unten unbeschränkt ist, so ist $\Theta(y) = -\infty$ für alle zulässigen $y \in \mathbb{R}^{p+q}$.

Satz 6.2.6 (Starker Dualitätssatz). Geben seien konvexe Funktionen $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$ für $i = 1, \dots, p$ sowie affine Funktionen $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$ für $j = 1, \dots, q$, so, dass die Slater-Bedingung erfüllt ist. Dann gilt

$$\inf\{f(x): x \in \mathbb{R}^n \text{ mit } g_i(x) \leq 0 \text{ für } i = 1, \dots, p \text{ und } h_j(x) = 0 \text{ für } j = 1, \dots, q\} \\ = \sup\{\Theta(y): y_i \geq 0 \text{ für } i = 1, \dots, p\}.$$

Ist die linke Seite endlich, so nimmt die Funktion Θ ihr Maximum in einem zulässigen Punkt $y^* \in \mathbb{R}^{p+q}$ an. Nimmt f ihr Minimum in einem zulässigen Punkt $x^* \in \mathbb{R}^n$ an, so gilt $y_i^* g_i(x^*) = 0$ für $i = 1, \dots, p$.

Beweis. Ist f auf dem zulässigen Bereich nach unten unbeschränkt, so folgt die behauptete Identität aus Korollar 6.2.5. Nach Satz 3.2.8 müssen wir nur den Fall zeigen, dass das f auf dem zulässigen Bereich nach unten beschränkt ist, ihr Minimum aber nicht annimmt. Wir gehen so vor wie im Beweis von Satz 3.2.5, vgl. auch Aufgabe (3.11) und setzen

$$\gamma := \inf\{f(x): g_i(x) \leq 0 \text{ für } i = 1, \dots, p \text{ und } h_j(x) = 0 \text{ für } j = 1, \dots, q\}$$

sowie

$$C := \{a \in \mathbb{R}^{p+q+1}: \exists x \in \mathbb{R}^n \text{ mit } a_0 \geq f(x) - \gamma, \ a_i \geq g_i(x) \text{ für } 1 \leq i \leq p \\ \text{und } a_{j+p} = h_j(x) \text{ für } 1 \leq j \leq q\}$$

und stellen fest, dass es sich dabei um eine nicht-leere, abgeschlossene, konvexe Menge handelt, da f und alle g_i konvex sind. Nach Definition von γ ist $f(x) > \gamma$ für alle zulässigen Punkte $x \in \mathbb{R}^n$ und folglich $0 \notin C$. Also gibt es nach Satz 3.1.7 ein $y \in \mathbb{R}^{p+q+1} \setminus \{0\}$ mit $y^\top z \geq 0$ für alle $z \in C$ und damit insbesondere

$$0 \leq y_0(f(x) - \gamma) + \sum_{i=1}^p y_i g_i(x) + \sum_{j=1}^q y_{p+j} h_j(x) \quad (6.1)$$

für alle $x \in \mathbb{R}^n$. Analog zum Beweis von Satz 3.2.5 erhalten wir aus der Definition von x , dass $y_i \geq 0$ für $i = 0, \dots, p$.

Wir verwenden nun die Slater-Bedingung um zu zeigen, dass $y_0 \neq 0$ ist. Wieder nehmen wir das Gegenteil, d.h. $y_0 = 0$ an. Nach Voraussetzung gibt es also ein $x' \in \mathbb{R}^n$ mit $h_j(x') = 0$ und $g_i(x') < 0$ für $i = 1, \dots, p$ und alle $j = 1, \dots, q$. Für diesen Punkt erhalten wir in (6.1), dass

$$0 \leq \sum_{i=1}^p y_i g_i(x')$$

und folglich $y_i = 0$ für $i = 1, \dots, p$ gelten muss. Da nach Voraussetzung $y \neq 0$ ist, gibt es j mit $y_{p+j} \neq 0$. Da h_j affin ist, gibt es $a_j \in \mathbb{R}^n$ und $b_j \in \mathbb{R}$ mit

$$h_j(x) = a_j^\top x - b_j$$

für $j = 1, \dots, q$. Wir nehmen der Einfachheit an, dass $a_1, \dots, a_q$ linear unabhängig sind. Dann können wir aufgrund der Stetigkeit der g_i , siehe Satz 3.1.3, und der h_j für $r > 0$ klein genug ein $\tilde{x} \in \mathbb{R}^n$ mit

$$g_i(\tilde{x}) < 0 \quad \text{für } i = 1, \dots, p \quad \text{und} \quad h_j(\tilde{x}) = -ry_{p+j} \quad \text{für } j = 1, \dots, q$$

finden. Damit ist aber

$$0 \leq \sum_{j=1}^q y_{p+j} h_j(\tilde{x}) = -r \sum_{j=1}^q y_{p+j}^2 < 0,$$

ein Widerspruch. □

Bemerkung 6.2.7. Die Annahme, dass $a_1, \dots, a_q$ zu $h_j(x) = a_j^\top x - b_j$ linear unabhängig sind, ist nicht automatisch erfüllt. Man kann dies aber durch weglassen von geeigneten h_j erreichen, ohne den zulässigen Bereich zu verändern.

Die Annahme, dass die Slater-Bedingung erfüllt sein muss, kann nicht ersatzlos weggelassen werden.

Definition 6.2.8. Es seien $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$ für $i = 1, \dots, p$ konvexe Funktionen sowie $h_j: \mathbb{R}^n \rightarrow \mathbb{R}$ für $j = 1, \dots, q$ affine Funktionen. Wir bezeichnen mit

$$p^* := \inf \{f(x) : g_i(x) \leq 0 \text{ für } i = 1, \dots, p \text{ und } h_j(x) = 0 \text{ für } j = 1, \dots, q\}$$

und

$$d^* := \sup \{\Theta(y) : y \in \mathbb{R}^m, y_i \geq 0 \text{ für } i = 1, \dots, p\}$$

die Optimalwerte von (MP) und des Lagrange-dualen Optimierungsproblems. Die Differenz $p^* - d^*$ bezeichnet man als *Dualitätslücke* von (MP)

6.3 Literatur und Ausblick

Für die Vorbereitung dieses Abschnitts wurden die Bücher [7, 10, 3, 1] verwendet.

6.4 Aufgaben

(6.1) LEMMA VON FARKAS UND DUALITÄTSSATZ: Es seien $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$.

- (a) Zeigen Sie mit Hilfe des Lemma von Farkas (Satz 1.3.4), dass das lineare Ungleichungssystem $Ax \leq b$ genau dann eine Lösung hat, wenn jede nicht-negative Lösung $y \in \mathbb{R}^m$ von $A^T y = 0$ die Ungleichung $b^T y \geq 0$ erfüllt.
- (b) Verwenden Sie (a), um zu zeigen, dass ein lineares Programm unbeschränkt ist, wenn das dazu duale lineare Programm einen leeren Zulässigkeitsbereich hat.

(6.2) DUALES PROGRAMM ZUM DUALEN PROGRAMM: Es seien $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$.

- (a) Bringen Sie das duale Programm

$$\max\{b^T y : A^T y \leq c\}$$

in Standardform und bestimmen Sie das dazu duale Programm.

- (b)

(6.3) DUALITÄTSLÜCKE: Wir betrachten das Minimierungsproblem

$$\begin{aligned} \min e^{x_2} \quad & \text{unter} \\ \|x\| - x_1 & \leq 0 \end{aligned}$$

- (a) Zeigen Sie, dass Zielfunktion und Nebenbedingung konvexe Funktionen sind.
- (b) Bestimmen Sie den (Minimal-)wert des Problems und eine Lösung, falls eine solche Existiert.
- (c) Bestimmen Sie das dazu Lagrange-duale Problem.
- (d) Bestimmen Sie (Maximal-)wert des dualen Problems und eine Lösung, falls eine solche existiert.
- (e) Gibt es eine Dualitätslücke?

7 Kombinatorische Optimierung

Wir betrachten in diesem Kapitel lineare Programme der folgenden Form

$$\min\{c^T x : Ax \leq b, x \in \mathbb{Z}^n\}$$


für $A \in \text{Mat}_{m,n}(\mathbb{Z})$, $b \in \mathbb{Z}^m$ und $c \in \mathbb{R}^n$.

Zur Veranschaulichung betrachten wir folgendes zweidimensionales ganzzahliges Minimierungsproblem.

Beispiel 7.0.1. Wir betrachten

$$A = \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 2 & 1 \\ 1 & 3 \end{pmatrix}, \quad b = \begin{pmatrix} 0 \\ 0 \\ 3 \\ 5 \end{pmatrix} \quad \text{und} \quad c = \begin{pmatrix} -3 \\ -1 \end{pmatrix}.$$

In der folgenden Graphik sind der Zulässigkeitsbereich des ganzzahligen Problems sowie des linearen Programms $\min\{c^T x : Ax \leq b\}$.



In rot ist die Lösung des linearen Programms und in grün die des ganzzahligen Programms markiert. Man sieht, dass die Lösung des ganzzahligen Programms nicht unbedingt der zur Lösung des linearen Programms nächstgelegene zulässige Vektor in $\mathbb{Z}^2$ sein muss.

7.1 Lösbarkeit ganzzahliger linearer Ungleichungssysteme

Wir starten mit ein paar einfachen Beobachtungen.

Bemerkung 7.1.1. Statt $A \in \text{Mat}_{m,n}(\mathbb{Z})$ und $b \in \mathbb{Z}^m$ können wir auch äquivalenterweise $A \in \text{Mat}_{m,n}(\mathbb{Q})$ und $b \in \mathbb{Q}^m$ annehmen, da wir durch Multiplikation mit positiven ganzen Zahlen ganzzahlige Koeffizienten in den Ungleichungen erreichen können, ohne den dadurch den zulässigen Bereich zu verändern.

Ist der zulässige Bereich beschränkt und enthält ganzzahlige Punkte, so enthält er endlich viele ganzzahlige Punkt, deren konvexe Hülle ist ein Polytop und die Zielfunktion nimmt ihr Minimum in einer Ecke an. Dies motiviert die folgende Definition.

Definition 7.1.2. Ein Polyeder $P \subset \mathbb{R}^n$ heißt *rationales Polyeder*, falls

$$P = P(A, b)$$

mit $A \in \text{Mat}_{m,n}(\mathbb{Q})$ und $b \in \mathbb{Q}^m$ ist. Für ein Polyeder P bezeichnen wir mit

$$P_{\mathbb{Z}} = \text{Konv}(P \cap \mathbb{Z}^n)$$

die *ganzzahlige Hülle* von P .

Bemerkung 7.1.3. Aus der Konvexität von P und $P \cap \mathbb{Z}^n \subset P$ erhalten wir $P_{\mathbb{Z}} \subset P$.

Ist P ein Polytop, so ist $P \cap \mathbb{Z}^n$ endlich und $P_{\mathbb{Z}}$ ist trivialerweise auch ein Polytop. Der folgende Satz zeigt, dass dies für rationale Polyeder auch im unbeschränkten Fall noch stimmt.

Satz 7.1.4. *Es sei $P \subset \mathbb{R}^n$ ein rationales Polyeder. Dann ist auch dessen ganzzahlige Hülle $P_{\mathbb{Z}}$ ein rationales Polyeder.*

Beweis. Nach Annahme gibt es $A \in \text{Mat}_{m,n}(\mathbb{Q})$ und $b \in \mathbb{Q}^m$ mit $P = P(A, b)$. Wir betrachten den rationalen Kegel

$$C_P := \{(x, t) \in \mathbb{R}^{n+1} : Ax - tb \leq 0, t \geq 0\}$$

vgl. Beispiel 1.1.11. Da sich um einen polyedrischen Kegel handelt, ist er nach Satz 1.1.13 endlich erzeugt. Durch Multiplikation mit geeigneten positiven Zahlen, können wir annehmen, dass

$$C_P = \text{KK}(\{(x_1, 1), \dots, (x_k, 1), (y_1, 0), \dots, (y_l, 0)\})$$

mit $x_1, \dots, x_k \in \mathbb{Q}^n$ und $y_1, \dots, y_l \in \mathbb{Z}^n$ ist, da wir die Erzeuger im Beweis von Satz 1.1.13 als Lösungen linearer Gleichungssysteme erhalten haben, die in der aktuellen Situation nur rationale Koeffizienten haben. Wir betrachten das Polytop

$$Q = \left\{ \sum_{i=1}^k \lambda_i x_i + \sum_{j=1}^l \mu_j y_j : \lambda_i \geq 0, \sum_{i=1}^k \lambda_i = 1, 0 \leq \mu_j \leq 1 \right\}$$

und bemerken, dass $Q \subset P$ ist. Wir bezeichnen mit $z_1, \dots, z_p$ die ganzzahligen Punkte von Q , d.h. $Q \cap \mathbb{Z}^n = \{z_1, \dots, z_p\}$.

Nach Aufgabe (1.8) gibt es $\tilde{A} \in \text{Mat}_{q,n}(\mathbb{Q})$ und $\tilde{b} \in \mathbb{Q}^q$ mit

$$\begin{aligned} \text{KK}(\{(y_1, 0), \dots, (y_l, 0), (z_1, 1), \dots, (z_p, 1)\}) \\ = \{(x, t) \in \mathbb{R}^{n+1} : \tilde{A}x - t\tilde{b} \leq 0, t \geq 0\}. \end{aligned}$$

7.1 Lösbarkeit ganzzahliger linearer Ungleichungssysteme

Wir zeigen nun, dass $P_{\mathbb{Z}} = P(\tilde{A}, \tilde{b})$.

Wir starten mit der Inklusion $P_{\mathbb{Z}} \subset P(\tilde{A}, \tilde{b})$. Zu $z \in P \cap \mathbb{Z}^n$ ist nach Konstruktion $(z, 1) \in C_P$ und daher

$$z = \sum_{i=1}^k \lambda_i x_i + \sum_{j=1}^l \mu_j y_j$$

mit $\lambda_i, \mu_j \geq 0$ für $i = 1, \dots, k$ und $j = 1, \dots, l$ sowie $\sum_{i=1}^k \lambda_i = 1$. Wir setzen

$$c := \sum_{j=1}^l \lfloor \mu_j \rfloor y_j \in \mathbb{Z}^n$$

und bemerken, dass

$$z - c = \sum_{i=1}^k \lambda_i x_i + \sum_{j=1}^l (\mu_j - \lfloor \mu_j \rfloor) y_j \in Q \cap \mathbb{Z}^n$$

ist, d.h. es ist $z - c = z_i$ für ein $i \in \{1, \dots, p\}$. Also ist

$$\begin{aligned} (z, 1) &= (c, 0) + (z_1, 1) = \sum_{j=1}^l (\mu_j - \lfloor \mu_j \rfloor) (y_j, 0) + (z_i, 1) \\ &\in \text{KK}(\{(y_1, 0), \dots, (y_l, 0), (z_1, 1), \dots, (z_p, 1)\}) \end{aligned}$$

und daher $\tilde{A}z - \tilde{b} \leq 0$, was die Behauptete Inklusion beweist.

Sei nun umgekehrt $x \in \mathbb{R}^n$ mit $\tilde{A}x \leq \tilde{b}$. Dann ist nach

$$x = \sum_{i=1}^p \lambda_i z_i + \sum_{j=1}^l \mu_j y_j$$

mit $\lambda_1, \dots, \lambda_p, \mu_1, \dots, \mu_l \geq 0$ und $\sum_{i=1}^p \lambda_i = 1$ nach Konstruktion von $\tilde{A}$ und $\tilde{b}$. Wir nehmen ohne Einschränkung der Allgemeinheit an, dass $\lambda_1 > 0$ ist. Wir wählen nun eine Zahl $R \in \mathbb{N}$ groß genug, dass

$$\sum_{j=1}^l \mu_j \leq \lambda_1 R$$

ist. Wir erhalten

$$x = \left(\lambda_1 - \sum_{j=1}^l \frac{\mu_j}{R} \right) z_1 + \lambda_2 z_2 + \dots + \lambda_p z_p + \sum_{j=1}^l \frac{\mu_j}{R} (R y_j + z_1)$$

und müssen wegen $Q \subset P$ nur noch zeigen, dass $(R y_j + z_1) \in P$ gilt. Dies folgt aber aus der Darstellung $P = \text{Konv}(\{x_1, \dots, x_k\}) + \text{KK}(\{y_1, \dots, y_l\})$, vgl. Beweis von Satz 1.1.12. $\square$

7 Kombinatorische Optimierung

Bemerkung 7.1.5. Wir haben also gezeigt, dass für

$$P = \text{Konv}(\{x_1, \dots, x_k\}) + \text{KK}(\{y_1, \dots, y_l\})$$

mit $x_1, \dots, x_k, y_1, \dots, y_l \in \mathbb{Q}^n$ die ganzzahlige Hülle die Darstellung

$$P_{\mathbb{Z}} = \text{Konv}(\{z_1, \dots, z_p\}) + \text{KK}(\{y_1, \dots, y_l\})$$

für geeignete $z_1, \dots, z_p \in P \cap \mathbb{Z}^n$ hat.

Aus dieser Beobachtung erhalten wir mit Satz 1.4.1 direkt folgenden Zusammenhang zwischen linearem Programm und ganzzahligem Programm.

Satz 7.1.6. *Es sei $A \in \text{Mat}_{m,n}(\mathbb{Q})$, $b \in \mathbb{Q}^m$ und $c \in \mathbb{R}^n$. Wir betrachten $P = P(A, b)$ und nehmen an, dass sowohl P als auch die ganzzahlige Hülle $P_{\mathbb{Z}}$ nicht-leer ist. Dann ist die Funktion $x \mapsto c^{\top}x$ auf P genau dann nach unten unbeschränkt, wenn sie auf der ganzzahligen Hülle $P_{\mathbb{Z}}$ nach unten unbeschränkt ist.*

Das folgende sehr einfache Beispiel zeigt, dass $P_{\mathbb{Z}}(A, b) := (P(A, b))_{\mathbb{Z}}$ leer sein kann auch wenn $P(A, b)$ nicht-leer ist.

Beispiel 7.1.7. Das Ungleichungssystem

$$\begin{aligned} 2y &\leq 1 \\ -2y &\leq -1 \end{aligned}$$

definiert ein unbeschränktes Polyeder in $\mathbb{R}^2$, dessen ganzzahlige Hülle leer ist.

7.2 Branch and Bound

Wir betrachten ein Verfahren zur Lösung von ganzzahligen linearen Programmen. Genauer gesagt, wir betrachten das Problem

$$L_{A,b,c} := \min\{c^{\top}x : Ax \leq b, x \in \mathbb{Z}^n\}$$

mit $A \in \text{Mat}_{m,n}(\mathbb{Z})$, $b \in \mathbb{Z}^m$ und $c \in \mathbb{R}^n$. Dazu betrachten wir das *relaxierte Problem*

$$\bar{L}_{A,b,c} := \min\{c^{\top}x : Ax \leq b\},$$

d.h. das gleiche Problem ohne die Ganzzahligkeitsbedingung.

Algorithmus 7.2.1. Wir betrachten das Problem

$$L_{A,b,c} := \min\{c^{\top}x : Ax \leq b, x \in \mathbb{Z}^n\}$$

mit $A \in \text{Mat}_{m,n}(\mathbb{Z})$, $b \in \mathbb{Z}^m$ und $c \in \mathbb{R}^n$.

Eingabe: A, b, c

Ausgabe: Eine Lösung von $L_{A,b,c}$ oder die Information, dass keine Lösung existiert.

Durchführung: Wir setzen $S := \infty$, $k = 0$, $A_0 = A$, $b_0 = b$ und $\mathcal{K} := \{L_{A_0, b_0, c}\}$.

- (1) Ist $\mathcal{K} = \emptyset$, stoppen wir. Ist $C = \infty$, so gibt es keine Lösung, anderenfalls ist x^* eine Lösung von $L_{A,b,c}$.
- (2) Ist $\mathcal{K} \neq \emptyset$, wählen wir $L_{A_j,b_j,c} \in \mathcal{K}$.
- (3) Wir lösen das Problem $\bar{L}_{A_j,b_j,c}$. Existiert keine Lösung, entfernen wir $L_{A_j,b_j,c}$ aus $\mathcal{K}$ und gehen zu (1).
- (4) Anderenfalls sei $\bar{x}$ die erhaltene Lösung von $\bar{L}_{A_j,b_j,c}$.
- (5) Ist $c^\top \bar{x} \geq C$, entfernen wir $L_{A_j,b_j,c}$ aus $\mathcal{K}$ und gehen zu (1).
- (6) Ist $c^\top \bar{x} \leq C$ und $\bar{x} \in \mathbb{Z}^n$, setzen wir $C = c^\top \bar{x}$, $x^* = \bar{x}$. Wir entfernen $L_{A_j,b_j,c}$ aus $\mathcal{K}$ und gehen zu (1).
- (7) Ist $c^\top \bar{x} \leq C$ und $\bar{x} \notin \mathbb{Z}^n$, wählen wir ein $i \in \{1, \dots, n\}$ mit $\bar{x}_i \notin \mathbb{Z}$ und setzen

$$A_{k+1} = \begin{pmatrix} A_j \\ e_i^\top \end{pmatrix}, \quad b_{k+1} = \begin{pmatrix} b_j \\ \lfloor \bar{x}_i \rfloor \end{pmatrix}, \quad A_{k+2} = \begin{pmatrix} A_j \\ -e_i^\top \end{pmatrix} \text{ und } b_{k+2} = \begin{pmatrix} b_j \\ -\lceil \bar{x}_i \rceil \end{pmatrix}.$$

Wir fügen $L_{A_{k+1},b_{k+1},c}$ und $L_{A_{k+2},b_{k+2},c}$ zu $\mathcal{K}$ hinzu, ersetzen k durch $k+2$ und gehen zu (1).

Bemerkung 7.2.2. Die Idee hinter (7) ist die folgende: $\bar{x}$ ist eine Lösung von $\bar{L}_{A_j,b_j,c}$, aber nicht ganzzahlig. Wir teilen, daher „Branch“ in Branch and Bound, das Problem in zwei Probleme: in einem Problem fügen wir die Ungleichung $x_i \leq \lfloor \bar{x}_i \rfloor$ hinzu, im anderen die Ungleichung $x_i \leq \lceil \bar{x}_i \rceil$.

Wir zeigen nun, dass Algorithmus 7.2.1 in endlicher Zeit terminiert, falls der Zulässigkeitsbereich beschränkt ist.

Satz 7.2.3. *Es seien $A \in \text{Mat}_{m,n}(\mathbb{Z})$, $b \in \mathbb{Z}^m$ und $c \in \mathbb{R}^n$ so, dass der zulässige Bereich von*

$$L_{A,b,c} := \min\{c^\top x : Ax \leq b, x \in \mathbb{Z}^n\}$$

beschränkt ist. Dann stoppt Algorithmus 7.2.1 nach endlich vielen Schritten.

Beweis. Da der zulässige Bereich von $L_{A,b,c}$ beschränkt ist, gibt es ein $T \in \mathbb{N}$ mit

$$-T \leq x_i \leq T$$

für jedes zulässige $x \in \mathbb{Z}^n$. Die einzigen Ungleichungen, die in Schritt (7) hinzugefügt werden können, sind also

$$\begin{aligned} x_i &\geq \tau_+ & \tau_+ &\in \{-T+1, \dots, T\} \\ x_i &\leq \tau_- & \tau_- &\in \{-T, \dots, T-1\}, \end{aligned}$$

d.h. es gibt maximal $4nT$ Ungleichungen, die aufgenommen werden können. Wir betrachten die Menge

$$\{L_{A_j,b_j,c} : j \in J\}$$

der ganzzahligen linearen Programme, die von Algorithmus 7.2.1 in einem Durchlauf betrachtet werden. Wir können diese Menge als binären Baum auffassen, in dem die Programme $L_{A_j, b_j, c}$ und $L_{A_k, b_k, c}$ genau dann durch eine Kante verbunden sind, falls $L_{A_k, b_k, c}$ durch Hinzufügen von Ungleichungen zu $L_{A_j, b_j, c}$ in Schritt (7) definiert ist (oder umgekehrt).

Wir zeigen nun, dass J endlich ist. Die Höhe des Baums ist maximal $2nT$, da sonst die Ungleichungen widersprüchlich werden. Also ist $|J| \leq 2^{2nT+1}$, da ein binärer Baum von Höhe $2nT$ maximal 2^{2nT+1} Ecken hat.

Wir müssen also noch zeigen, dass Algorithmus 7.2.1 tatsächlich eine Lösung liefert von korrekterweise die Information liefert, dass es keine Lösung gibt. Ist $C = \infty$, so wurde im ganzen Durchlauf kein einziger zulässiger ganzzahliger Punkt gefunden. Wir betrachten nun Schritt (7) genauer. Sei $L_{A_j, b_j, c}$ mit nicht-ganzzahliger Lösung $\bar{x}$ gegeben und wir erzeugen die neuen Programme $L_{A_{k+1}, b_{k+1}, c}$ und $L_{A_{k+2}, b_{k+2}, c}$ durch Hinzunahme von einer der Ungleichungen

$$x_i \leq \lfloor \bar{x}_i \rfloor \quad \text{und} \quad x_i \geq \lceil \bar{x}_i \rceil.$$


Damit sind aber alle ganzzahligen zulässigen Punkte von $L_{A_j, b_j, c}$ auch zulässige Punkte von einem der neuen Programme. Erreichen wir irgendwann Schritt (6), so haben wir eine ganzzahlige Lösung eines Programms $L_{A_j, b_j, c}$ gefunden. Es kann also keinen dafür zulässigen ganzzahligen Punkt geben, auf dem die Zielfunktion kleiner ist. Eine weitere Unterteilung macht hier also keinen Sinn. Auch wenn wir mit einem Programm $L_{A_j, b_j, c}$ Schritt (5) erreichen, macht eine weitere Unterteilung keinen Sinn, da auf jedem zulässigen Punkt davon und damit auch auf allen ganzzahligen darunter die Zielfunktion einen größeren Wert als auf einem bereits gefundenen Punkt x^* annimmt.

Haben wir also $\mathcal{K} = \emptyset$ erreicht, ist keine weitere Teilung mehr sinnvoll und wir haben also eine Lösung gefunden oder es gibt keine. $\square$

Beispiel 7.2.4. Wir betrachten Minimierungsproblem aus Beispiel 7.0.1, d.h.

$$A = \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 2 & 1 \\ 1 & 3 \end{pmatrix}, \quad b = \begin{pmatrix} 0 \\ 0 \\ 3 \\ 5 \end{pmatrix} \quad \text{und} \quad c = \begin{pmatrix} -3 \\ -1 \end{pmatrix}.$$

Als Lösung des nicht-ganzzahligen Problems erhalten wir $\bar{x} = (3/2, 0)$ und betrachten dann die beiden Programme, die wir erhalten wenn einer der Ungleichungen $x_1 \leq 1$ und $x_1 \leq 2$ aufnehmen. Das zweite dieser Programme hat einen leeren zulässigen Bereich und das erste liefert als Lösung den Punkt $x^* = (1, 1)$. Dies ist in folgender Graphik illustriert.



Bemerkung 7.2.5. Sowohl Algorithmus 7.2.1 als auch der Beweis von Satz 7.2.3 funktionieren völlig analog, wenn wir nur für manche der Variablen verlangen, dass die Einträge ganzzahlig sind. Solche Minimierungsprobleme nennt man *gemischt-ganzzahlige lineare Minimierungsprobleme*.

7.3 Literatur und Ausblick

Der Beweis von Satz 7.1.4, den wir hier geben ist im wesentlichen der Beweis von Satz 5.1 in [8, p. 110]. Die Darstellung des Branch-and-Bound-Algorithmus sowie der Beweis, dass dieser nach endlich vielen Schritten terminiert, folgt im wesentlichen der Darstellung in Abschnitt 21.4 von [3].

8 Innere Punkte Verfahren: ein Ausblick

Wir betrachten nun noch ein effizientes Verfahren zur Lösung von linearen Optimierungsproblemen, das auch für manche konvexe Probleme gut funktioniert. Wir betrachten es zur Motivation nur für lineare Programme, d.h. wir suchen eine Lösung von

$$\min\{c^T x : Ax = b, x \geq 0\}$$

mit $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$. Die Grundidee der Inneren-Punkte-Verfahren ist ähnlich zu den Penalty-Verfahren, aber der entscheidende Unterschied ist, dass wir uns hier der Lösung nicht von Außen sondern von Innen nähern. Für gegebenes $\mu > 0$ setzen wir

$$f_\mu(x) = c^T x - \mu \sum_{i=1}^n \log x_i$$

und betrachten das Minimierungsproblem

$$\begin{array}{ll} \min f_\mu & \text{unter} \\ Ax = b \end{array}$$

das nur noch Gleichheitsnebenbedingungen hat. Wir nehmen ab jetzt $\text{Rang}(A) = m$ an und können also die Lagrange-Multiplikatorregel verwenden und erhalten, dass es zu jeder Lösung $x \in \mathbb{R}^n$ des linearen Programms ein $y \in \mathbb{R}^m$ so gibt, dass

$$\begin{array}{l} \nabla f_\mu(x) - \sum_{j=1}^m A_j^T y_j = 0 \\ Ax = b. \end{array}$$

Die erste Bedingung können wir auf

$$A^T y = \nabla f_\mu(x) = c - \mu \begin{pmatrix} \frac{1}{x_1} \\ \vdots \\ \frac{1}{x_n} \end{pmatrix} =: c - s$$

umformen, wobei wir $s \in \mathbb{R}^n$ durch

$$s \geq 0 \quad \text{und} \quad (s_1 x_1, \dots, s_n x_n) = \mu \mathbf{1}^T$$

8 Innere Punkte Verfahren: ein Ausblick

charakterisieren können. Wir kommen insgesamt also auf das System

$$\begin{aligned} Ax &= b \\ A^\top y + s &= c \\ s_i x_i &= \mu \quad \text{für } i = 1, \dots, n \\ x &\geq 0 \\ s &\geq 0 \end{aligned} \tag{8.1}$$

Die zweite Bedingung bedeutet zusammen mit der letzten Bedingung insbesondere, dass $A^\top y \leq c$ sein muss, d.h. y muss für das duale Programm zulässig sein. Die einzige nicht-lineare Bedingung im obigen ist die dritte Bedingung.

In anderen Worten suchen wir also $x, s \geq 0$ und $y \in \mathbb{R}^m$ mit

$$\begin{aligned} Ax - b &= 0 \\ A^\top y + s - c &= 0 \\ Sx - \mu \mathbf{1} &= 0, \end{aligned}$$

mit $S = \text{diag}(s_1, \dots, s_n)$, d.h. wir suchen Nullstellen der Funktion

$$\Psi: \mathbb{R}^{2n+m} \rightarrow \mathbb{R}^{m+2n}, \quad (x, s, y) \mapsto \begin{pmatrix} Ax - b \\ A^\top y + s - c \\ Sx - \mu \mathbf{1} \end{pmatrix}$$

mit $x, s \geq 0$. Die Jacobi-Matrix dieser Abbildung ist

$$\Psi'(x, s, y) = \begin{pmatrix} A & 0 & 0 \\ 0 & I_n & A^\top \\ S & X & 0 \end{pmatrix} \in \text{Mat}_{2n+m, 2n+m}(\mathbb{R})$$

wobei wir die Notation $X = \text{diag}(x_1, \dots, x_n)$ verwendet haben.

Satz 8.0.1. *Es seien $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$, $c \in \mathbb{R}^n$ und $x, s \in \mathbb{R}^n$ mit $x, s > 0$ und $\text{Rang}(A) = m$. Dann ist die Matrix*

$$\begin{pmatrix} A & 0 & 0 \\ 0 & I_n & A^\top \\ S & X & 0 \end{pmatrix}$$

invertierbar.

Beweis. Wir zeigen, dass der Lösungsraum der Matrix Null ist und betrachten Vektoren $u, v \in \mathbb{R}^n$ und $w \in \mathbb{R}^m$ mit

$$\begin{pmatrix} A & 0 & 0 \\ 0 & I_n & A^\top \\ S & X & 0 \end{pmatrix} \begin{pmatrix} u \\ v \\ w \end{pmatrix} = 0.$$

In anderen Worten haben wir

$$\begin{aligned} Au &= 0 \\ v + A^\top w &= 0 \\ Su + Xv &= 0. \end{aligned}$$

Also ist

$$u^\top v = -u^\top A^\top w = -(Au)^\top w = 0.$$

Womit wir gemeinsam mit $u = -S^{-1}Xv$ die Gleichung

$$0 = u^\top v = -v^\top (S^{-1}X)^\top v$$

und folglich $u = v = 0$, da $S^{-1}X$ positiv definit ist. Also ist $A^\top w = 0$ und damit erhalten wir aus $\text{Rang} A = m$, dass $w = 0$ ist. Insgesamt haben wir damit gezeigt, dass der Lösungsraum der Matrix trivial und die Matrix daher invertierbar ist. $\square$

Damit macht es also Sinn Nullstellen von Ψ auf $(0, \infty)^{2n} \times \mathbb{R}^m$ mittels des Newton-Verfahrens zu suchen. Wir müssen dabei aber sicherstellen, dass das Newton-Verfahren die Menge $(0, \infty)^{2n} \times \mathbb{R}^m$ nicht verlässt.

Bevor wir uns dieses Problems genauer widmen, betrachten wir die dritte Bedingung in (8.1) etwas genauer. Im Fall $\mu = 0$ erhalten wir die Bedingung

$$s_i x_i = 0 \quad \text{für } i = 1, \dots, n$$

was wegen $s, x \geq 0$ zu

$$s^\top x = 0$$

äquivalent ist. Aus der zweiten Bedingung erhalten wir

$$0 = s^\top x = (c - A^\top y)^\top x = c^\top x - y^\top Ax = c^\top x - y^\top b = c^\top x - b^\top y,$$

d.h. die Werte des untersuchten linearen Programms und seines dualen Programms stimmen überein. Nach Korollar 6.1.5 bedeutet dies aber gerade, dass x eine Lösung des linearen Programms (und y eine Lösung des dualen Programms) ist.

Diese Beobachtung legt nahe mit einem $\mu > 0$ zu starten und dann μ gegen Null zu schicken und dabei iterativ mit dem Newton-Verfahren Nullstellen der Funktion Ψ zu suchen.

Satz 8.0.2. *Es seien $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$, $c \in \mathbb{R}^n$ mit $\text{Rang}(A) = m$ so, dass es ein $x \in \mathbb{R}^n$ mit $Ax = b$ und $x > 0$ und ein $y \in \mathbb{R}^m$ mit $A^\top y < c$ gibt. Dann hat das System (8.1) für jedes $\mu > 0$ eine eindeutige Lösung*

$$(x^*(\mu), y^*(\mu), s^*(\mu)) \in (0, \infty)^n \times \mathbb{R}^m \times (0, \infty)^n.$$

Darüber hinaus ist $x^*(\mu)$ das eindeutige Minimum von f_μ auf der Menge

$$\{x \in \mathbb{R}^n : Ax = b, x > 0\}.$$

8 Innere Punkte Verfahren: ein Ausblick

Beweis. Es sei $\mu > 0$ gegeben. Wir zeigen als erstes, dass für jedes $\tilde{x} \in \mathbb{R}^n$ mit $A\tilde{x} = b$, $\tilde{x} > 0$ die Menge

$$P_{\tilde{x}} := \{x \in \mathbb{R}^n : Ax = b, x > 0, f_{\mu}(x) \leq f_{\mu}(\tilde{x})\}$$

kompakt ist. Es sei $\tilde{y} \in \mathbb{R}^m$ mit $A^T \tilde{y} < c$ und wir setzen $\tilde{s} = c - A^T \tilde{y} > 0$. Damit ist

$$\begin{aligned} f_{\mu}(x) &= c^T x - \mu \sum_{i=1}^n \log x_i \\ &= c^T x - \tilde{y}^T (Ax - b) - \mu \sum_{i=1}^n \log x_i \\ &= (c^T - \tilde{y}^T A)x + \tilde{y}^T b - \mu \sum_{i=1}^n \log x_i \\ &= \tilde{s}^T x + \tilde{y}^T b - \mu \sum_{i=1}^n \log x_i \\ &= \tilde{y}^T b - \sum_{i=1}^n (\mu \log x_i - \tilde{s}_i x_i) \end{aligned}$$

für alle $x \in \mathbb{R}^n$ mit $Ax = b$ und $x > 0$.

Wir betrachten die Funktion

$$h_{\alpha} : (0, \infty) \rightarrow \mathbb{R}, \quad \xi \mapsto \xi \mapsto \mu \log \xi - \alpha \xi$$

und bemerken, dass die Ableitung

$$h'_{\alpha}(\xi) = \frac{\mu}{\xi} - \alpha$$

die eindeutige Nullstelle $\xi = \frac{\mu}{\alpha}$ hat. Dieser Punkt ist das eindeutige Maximum von h_{α} und insbesondere ist h_{α} nach oben beschränkt. Insbesondere ist

$$f_{\mu}(x) \geq \tilde{y}^T b - \sum_{i=1}^n \mu \left(\log \frac{\mu}{\tilde{s}_i} - 1 \right)$$

und f_{μ} damit nach unten beschränkt. Da $h_{\alpha}(\xi) \rightarrow -\infty$ für $\xi \searrow 0$ und $\xi \rightarrow \infty$ (lineare Funktionen wachsen schneller als der Logarithmus), ist für alle $C \in \mathbb{R}$ die Menge

$$\{\xi \in (0, \infty) : h_{\alpha}(\xi) \geq C\}$$

beschränkt, d.h. es gibt ein kompaktes Intervall $I_{\alpha, C}$, das diese Menge enthält. Zu $\tilde{x}$ setzen wir

$$C := \tilde{y}^T b - f_{\mu}(\tilde{x}) \quad \text{und} \quad C_i := C - \sum_{j \neq i} \mu \left(\log \frac{\mu}{\tilde{s}_j} - 1 \right) \quad \text{für } i = 1, \dots, n.$$

Damit erhalten wir aus dem obigen, dass

$$\begin{aligned}
& \{x \in \mathbb{R}^n : Ax = b, x > 0, f_\mu(x) \leq f_\mu(\tilde{x})\} \\
&= \left\{x \in \mathbb{R}^n : Ax = b, x > 0, \sum_{i=1}^n (\mu \log x_i - \tilde{s}_i x_i) \geq C\right\} \\
&\subset \left\{x \in \mathbb{R}^n : x > 0, \mu \log x_i - \tilde{s}_i x_i \geq C_i \text{ für } i = 1, \dots, n\right\} \\
&\subset \prod_{i=1}^n I_{\tilde{s}_i, C_i}
\end{aligned}$$

und die Menge daher beschränkt ist. Wir wollen zeigen, dass $P_{\tilde{x}}$ abgeschlossen ist. Sei dazu $(z_k)_{k \in \mathbb{N}}$ eine Folge in $P_{\tilde{x}}$, die gegen ein $z \in \mathbb{R}^n$ konvergiert. Da die Menge $\{x \in \mathbb{R}^n : Ax = b\}$ abgeschlossen ist und die Menge

$$\{x \in (0, \infty)^n : f_\mu(x) \leq f_\mu(\tilde{x})\} \subset (0, \infty)^n$$

relativ abgeschlossen ist, reicht aus $z > 0$ nachzuweisen, um zu zeigen, dass $z \in P_{\tilde{x}}$ ist. Da $f_\mu(x)$ beliebig groß wird, wenn sich eine Komponente von x Null nähert, erhalten wir, dass $f_\mu(z_k) \rightarrow \infty$ gelten müsste, wenn es ein $z_i = 0$ geben würde. Dies steht aber im Widerspruch zu $f_\mu(z_k) \leq f_\mu(\tilde{x})$. Also ist $z > 0$ und daher in $P_{\tilde{x}}$.

Aus der Kompaktheit von $P_{\tilde{x}}$ und der Stetigkeit von f_μ erhalten wir, dass f_μ ihr Minimum in einem $x^* \in P_{\tilde{x}}$ annimmt. Aus der Lagrange-Multiplikator-Regel erhalten wir, dass es Punkte $s^* \in \mathbb{R}^n$ mit $s^* \geq 0$ und $y^* \in \mathbb{R}^m$ gibt, die zusammen mit x^* die Bedingungen in (8.1) erfüllen. Damit erhalten wir aus $s_i^* x_i^* = \mu$ und $x_i^* > 0$ auch $s_i^* > 0$. Die Eindeutigkeit folgt aus der Beobachtung, dass f_μ eine strikt konvexe Funktion ist. $\square$

Die Menge

$$\{(x^*(\mu), y^*(\mu), s^*(\mu)) : \mu > 0\}$$

heißt *primal-dualer zentraler Pfad*. Wir betrachten nun einen Algorithmus, der in der Nähe dieses Pfads bleibt und eine Lösung des linearen Programms zu gegebener Toleranz $\varepsilon > 0$ approximiert.

Algorithmus 8.0.3 (Kurz-Schritt-Algorithmus). Wir lösen ein lineares Programm in Standardform

$$\min\{c^\top x : Ax = b, x \geq 0\}$$

mit $A \in \text{Mat}_{m,n}(\mathbb{R})$, $b \in \mathbb{R}^m$ und $c \in \mathbb{R}^n$.

Eingabe: Ein Startpunkt x_0 , ein dualer Startpunkt y_0 , μ_0 und eine Toleranz $\varepsilon > 0$. Wir nehmen an, dass die Anfangsdaten folgende Bedingungen erfüllen:

$$Ax_0 = b, \quad x_0 > 0, \quad A^\top y_0 < c \quad \text{und} \quad \|X_0(c - A^\top y_0) - \mu_0 \mathbf{1}\|_2 \leq \frac{\mu_0}{2}$$

Ausgabe: Eine Lösung des obigen Programms.

Durchführung: Wir setzen $k = 0$, $s_0 = c - A^\top y_0$ und $r_0 = X_0 s_0 - \mu_0 \mathbf{1}$.

8 Innere Punkte Verfahren: ein Ausblick

- (1) Bestimme x_{k+1} , y_{k+1} und s_{k+1} aus

$$\begin{aligned} \begin{pmatrix} x_{k+1} \\ s_{k+1} \\ y_{k+1} \end{pmatrix} &= \begin{pmatrix} x_k \\ s_k \\ y_k \end{pmatrix} - \Psi'(x_k, s_k, y_k)^{-1} \Psi(x_k, s_k, y_k) \\ &= \begin{pmatrix} x_k \\ s_k \\ y_k \end{pmatrix} - \begin{pmatrix} A & 0 & 0 \\ 0 & I_n & A^\top \\ S_k & X_k & 0 \end{pmatrix}^{-1} \begin{pmatrix} Ax_k - b \\ A^\top y_k + s_k - c \\ S_k x_k - \mu_k \mathbb{1} \end{pmatrix} \\ &= \begin{pmatrix} x_k \\ s_k \\ y_k \end{pmatrix} - \begin{pmatrix} A & 0 & 0 \\ 0 & I_n & A^\top \\ S_k & X_k & 0 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0 \\ r_k \end{pmatrix} \end{aligned}$$

mit $r_k := X_k s_k - \mu_k \mathbb{1}$.

- (2) Wir setzen $\mu_{k+1} := \mu_k(1 - \frac{1}{6\sqrt{n}})$.
- (3) Wir ersetzen k durch $k + 1$.
- (4) Ist $\mu_k \leq \frac{\varepsilon}{n}$, stoppen wir und geben (x_k, y_k, s_k) zurück. Anderenfalls gehen wir zu (1).

Um zu zeigen, dass wir den Algorithmus durchführen können, müssten wir zeigen, dass $x_{k+1} > 0$ und $s_{k+1} > 0$ in (1) gilt, falls $x_k, s_k > 0$ ist. Wir lassen diesen Beweis aus Zeitgründen aus und erwähnen nur das folgende Resultat.

Satz 8.0.4. Sei $\beta \in [0, \frac{1}{2}]$. Gilt $\|r_k\|_2 \leq \beta \mu_k$ in Algorithmus 8.0.3, so ist

$$\|X_{k+1} s_{k+1} - \mu_k \mathbb{1}\|_2 \leq \beta^2 \mu_k$$

und $x_{k+1} > 0$ sowie $s_{k+1} > 0$.

Beweis. Siehe beispielsweise der Abschnitt 4.3 in [7, pp. 79–80]. □

Mit diesen Hilfsmitteln können wir nun zeigen, dass Algorithmus 8.0.3 nach endlich vielen Schritten eine Näherungslösung zur gegebenen Toleranz liefert.

Satz 8.0.5. Algorithmus 8.0.3 stoppt nach höchstens $6\sqrt{n} \log \frac{n\mu_0}{\varepsilon}$ Iterationen mit (strikt) zulässigen Näherungslösungen x und y , die

$$c^\top x - b^\top y \leq 2\varepsilon$$

erfüllen.

Beweis. Wir zeigen als erstes, dass die Voraussetzung von Satz 8.0.4 mit $\beta = \frac{1}{2}$ in jedem Iterationsschritt erfüllt bleibt. Im Schritt $k = 0$ ist die Bedingung nach

Annahme erfüllt. Wir nehmen nun also an, dass für gegebenes $k \in \mathbb{N}_0$ die Bedingung $\|r_k\| \leq \frac{\mu_k}{2}$ erfüllt ist. Dann ist

$$\begin{aligned} r_{k+1} &= X_{k+1}s_{k+1} - \mu_{k+1}\mathbb{1} = (X_{k+1}s_{k+1} - \mu_k\mathbb{1}) + (\mu_k - \mu_{k+1})\mathbb{1} \\ &= (X_{k+1}s_{k+1} - \mu_{k+1}\mathbb{1}) + \frac{\mu_k}{6\sqrt{n}}\mathbb{1} \end{aligned}$$

und folglich

$$\|r_{k+1}\| \leq \|X_{k+1}s_{k+1} - \mu_k\mathbb{1}\| + \frac{\mu_k}{6\sqrt{n}}\|\mathbb{1}\| \leq \frac{\mu_k}{4} + \frac{\mu_k}{6\sqrt{n}}\sqrt{n} = \frac{5}{12}\mu_k \leq \frac{\mu_{k+1}}{2},$$

nach Satz 8.0.4, da $(1 - \frac{1}{6\sqrt{n}}) \geq (1 - \frac{1}{6}) = \frac{5}{6}$ ist. Das Abbruchkriterium $\mu_k \leq \frac{\varepsilon}{n}$ ist aufgrund der Monotonie des Logarithmus äquivalent zu $\log \mu_k \leq \log \frac{\varepsilon}{n}$. Aus der Definition von $\mu_k = (1 - \frac{1}{6\sqrt{n}})\mu_{k-1}$ erhalten wir $\mu_k = (1 - \frac{1}{6\sqrt{n}})^k \mu_0$ und

$$\log \mu_k = \log \left(1 - \frac{1}{6\sqrt{n}}\right)^k \mu_0 = k \log \left(1 - \frac{1}{6\sqrt{n}}\right) + \log \mu_0,$$

d.h. Abbruch, falls

$$k \log \left(1 - \frac{1}{6\sqrt{n}}\right) \leq \log \frac{\varepsilon}{n} - \log \mu_0 = \log \frac{\varepsilon}{n\mu_0}$$

woraus wir unter Verwendung von $\log t \leq t - 1$ die Ungleichung

$$\log \frac{n\mu_0}{\varepsilon} \leq k \log \frac{1}{1 - \frac{1}{6\sqrt{n}}} \leq k \left(\frac{1}{1 - \frac{1}{6\sqrt{n}}} - 1 \right) = k \frac{\frac{1}{6\sqrt{n}}}{1 - \frac{1}{6\sqrt{n}}} = \frac{k}{6\sqrt{n} - 1}$$

erhalten. Also braucht das Verfahren weniger als $6\sqrt{n} \log \frac{n\mu_0}{\varepsilon}$ Iterationen. Für die erhaltenen Näherungslösungen gilt

$$\begin{aligned} c^\top x - b^\top y &= c^\top x - y^\top (Ax) = s^\top x = \mathbb{1}^\top (Xs) = \mathbb{1}^\top (\mu\mathbb{1} + r) \leq n\mu_k + \|r\|_1 \\ &\leq \left(n + \frac{\sqrt{n}}{2}\right) \mu_k \leq 2\varepsilon, \end{aligned}$$

wie behauptet. □

Zur Bestimmung der Startpunkte, die bereits nahe genug am primal-dualen zentralen Pfad liegt, gibt es verschiedene Optionen. Man kann wieder analog zum Simplex-Algorithmus ein „Phase I-Problem“ angeben, für das man einfach eine strikt zulässige Startlösung finden kann oder man kann das Problem umgehen, indem man auf sogenannte „selbstduale lineare Programme“ übergeht. Aus Zeitgründen lassen wir hier das Problem eine Anfangslösung zu finden aus.

8.1 Ausblick und Literatur

Dieses Kapitel basiert auf Teilen von Kapitel 4 von [7] und Kapitel 7.2. in [10]. Insbesondere ist Satz 8.0.1 im wesentlichen Satz 4.2.6 in [7, p. 82] und Satz 8.0.2 im wesentlichen Lemma 7.2.1 in [10, p. 121] und die Beweise folgen den dort gegebenen. Satz 8.0.5 ist Satz 4.4.2 in [7, p. 81].

Literaturverzeichnis

- [1] Amir Beck. *Introduction to nonlinear optimization*, volume 19 of *MOS-SIAM Series on Optimization*. Society for Industrial and Applied Mathematics (SIAM), Philadelphia, PA; Mathematical Optimization Society, Philadelphia, PA, 2014. Theory, algorithms, and applications with MATLAB.
- [2] Robert G. Bland. New finite pivoting rules for the simplex method. *Math. Oper. Res.*, 2(2):103–107, 1977.
- [3] Karl Heinz Borgwardt. *Optimierung, Operations Research, Spieltheorie: mathematische Grundlagen*. Birkhäuser, 2001.
- [4] Andrzej Cegielski. *Iterative methods for fixed point problems in Hilbert spaces*, volume 2057 of *Lecture Notes in Mathematics*. Springer, Heidelberg, 2012.
- [5] H. S. M. Coxeter. *Regular polytopes*. Dover Publications, Inc., New York, third edition, 1973.
- [6] Carl Geiger and Christian Kanzow. *Theorie und Numerik restringierter Optimierungsaufgaben*. Springer, 2002.
- [7] Florian Jarre and Josef Stoer. *Optimierung*. Springer Spektrum, second edition, 2019.
- [8] Bernhard Korte and Jens Vygen. *Kombinatorische Optimierung. Theorie und Algorithmen*. Heidelberg: Springer Spektrum, 2012.
- [9] Olvi L. Mangasarian. *Nonlinear programming*, volume 10 of *Classics in Applied Mathematics*. Society for Industrial and Applied Mathematics (SIAM), Philadelphia, PA, 1994. Corrected reprint of the 1969 original.
- [10] Jiří Matoušek and Bernd Gärtner. *Understanding and Using Linear Programming*. Springer Berlin, Heidelberg, 2007.
- [11] Franz Pauer. Lineare Optimierung. Schriftliche Unterlagen zur Vorlesung im Wintersemester 2003/04, 2003.
- [12] R. Tyrrell Rockafellar. *Convex analysis*. Princeton Mathematical Series, No. 28. Princeton University Press, Princeton, N.J., 1970.
- [13] N. Z. Shor. *Minimization methods for nondifferentiable functions*, volume 3 of *Springer Series in Computational Mathematics*. Springer-Verlag, Berlin, 1985. Translated from the Russian by K. C. Kiwiel and A. Ruszczyński.

- [14] Michael Ulbrich and Stefan Ulbrich. *Nichtlineare Optimierung*. Title Mathematik Kompakt. Birkhäuser, Basel, 2012.
- [15] Günter M. Ziegler. *Lectures on polytopes*, volume 152 of *Graduate Texts in Mathematics*. Springer-Verlag, New York, 1995.